会议技术报告 · 内部讨论稿

一个持续发育的类意识候选系统：操作性判据、因果中介与阴性结果

Growing Rather Than Training: A Pre-Registered Developmental System, and the Read-Only Nature of Its Workspace

报告人 Luo Chengze（独立研究者）

ORCID 0009-0007-3316-6292

版本 v1.0（会议用）

日期 2026-10-09

对应正文 paper/arxiv/main.tex

用途 学术讨论 · 应答底稿

摘要

本报告记述一个从零发育的类意识候选系统。与当前主流做法（在既有大语言模型上探测意识指标）相反，本系统不生成文本，其内部言语只能检索曾经听到过的短语，且认知回路中不含任何生成模型——"零幻觉"是结构性质而非提示约束。系统以单进程常驻方式连续运行，状态与仿真时钟跨重启续接，形成不可回退的个体史。

本报告的核心结论是一条阴性结果：移植自大模型可解释性研究的"消融—替换"（ablation-and-swap）协议后，该系统的全局工作空间表现为只读——下游（目标涌现、自我模型）确实在因果地读取念头，但念头不能反过来改变系统自身的状态变量。该结论经四级修正阶梯加固（开放通路、切换到被消费的状态变量、将耦合提升至原值的 15 倍即 0.91σ），指标仍全部低于 10% 且对剂量不单调，故判为结构性质而非接线故障。

据此提出六条操作性判据 D1 – D6，逐条回答"哪些功能结构已经成立、哪些不成立、每一条如何机械检测"。结果是：持续状态与自我模型成立；元认知、行动闭环为弱阳性；自我纠错的机制不存在；工作空间可写性不成立。全部实验均经预注册，阴性结果与阳性结果同等详细报告。

关键词： 人工意识 · 操作性判据 · 预注册 · 全局工作空间 · 内化言语 · 自我模型 · 因果中介 · 阴性结果

目录

1 研究问题与定位

1.1 研究问题

1.2 认识论承诺

1.3 与既有三条路线的关系

1.4 贡献声明

2 系统架构与实现

2.1 总览

2.2 状态与身体

2.3 语言层：检索而非生成

2.4 自我模型

2.5 目标涌现

2.6 发声与能动归因

2.7 工作空间

2.8 因果中介协议

2.9 世界与行动

3 操作性判据 D1 – D6

4 实验设计与结果

4.1 预注册纪律

4.2 结果汇总

4.3 关键实验详述

4.4 实验谱系

4.5 在研：语料扩容与双向重探

5 讨论

6 预期质疑与应答

7 局限、留白与下一步

附录 A 数值溯源表

附录 B 机制与代码位置索引

附录 C 术语中英对照

附录 D 常见误解澄清

附录 E 一页速览

参考文献

1 研究问题与定位

1.1 研究问题

本报告不回答"系统是否具有意识"。这一被 Chalmers 称为**难问题**的命题，在现有手段下不可测；本报告既不假装能测，也不把它降级为一个可测问题[1]。取而代之的问题是：

一个无语言基线、持续发育的个体，会自发长出哪些与意识相关的功能结构，哪些长不出来，且每一条如何机械检测？

这一提问方式承袭 Butlin 等提出的**指标理论路线**——不问"是否具有"，而问"具备哪些理论推导出的性质"[2,3]。与其差别在于：指标理论以既有系统为对象，而本报告以一个从零出生、连续运行的个体为对象，并对每一判据给出预注册与阴性报告。

1.2 认识论承诺

以下四条为设计约束，均可被验证或证伪：

1. **念头只检索、不生成**。认知回路中不含任何生成模型；系统的内部言语只能由记忆检索产生。由此得到的"零幻觉"是**结构性质**——没有生成器，故无法编造。此约束由一次失败逼出：早期版本将内部言语交由语言模型产生，输出"烦躁感"一类表达，而系统当时并无相应状态。此后确立此铁律。
2. **零提示词、零方向引导**。不对模型施加"应说什么"的提示，行为必须自发。
3. **预注册与如实报阴**。假设、度量与判定阈值在采集前冻结，事后不得修改；阴性结果与阳性结果同等详细记录。
4. **只谈功能结构，不涉主观体验**。所有结论限于可测的功能层。

1.3 与既有三条路线的关系

表 1　本研究与三条既有路线的关系

路线	典型做法	本研究的立场
大模型内省	以模型自述作为意识证据	判为不可证伪：生成式系统可输出任意自述；本系统无生成器，其"报告"等于检索胜出句
不可知论	认为该问题不可问，止步于此	判为不产出：本报告将问题的**功能部分**可测化
指标理论	将既有系统对照一组指标清单[2,3]	采纳其精神，但更换对象为从零发育的个体，并附预注册与阴性报告

1.4 贡献声明

1. **一条可复现的阴性结论**。将一个在语言模型上有效的因果中介协议[4]移植到本系统后失效，且经四级修正阶梯加固仍失效，据此判定其工作空间为只读。据我们所知，该结论尚未见报告。
2. **一条可复现的发育现象**。自我模型在系统前 213 仿真日为空，其后于 40 日内生长至 v6；三种独立随机种子在 day 60 内长出**同一碎片集合**，仅次序不同。
3. **一份操作性判据清单（D1 – D6）**。每条判据绑定一个可测度量，或明确标注"机制不存在"。

4. **一组预注册阴性结果**。四项实验的主要预测被证伪（见 §4.2），如实报告并作为架构缺口的定位依据。

2　系统架构与实现

2.1　总览

系统为单进程 Python 程序，**不含深度学习意义上的可学习参数**。其行为来自两处：① 一组耦合的常微分方程所构成的连续状态；② 一生累积的记忆。设计原则可概括为**"代码是物种，状态是个体"**——个体的本体存在于其历史状态目录，而非程序本身。因此，复制一份状态目录即得到一个共享历史、拥有独立未来的新个体。

2.2　状态与身体

系统维持 8 维连续状态变量 s1 – s8。代码中仅使用中性代号，人类可读语义仅在配置文件中供观察者参考：

表 2　状态变量定义

变量	语义	说明
s1	唤醒	由常微分方程连续演化；tick 周期 50 ms；睡眠期约占总时长三分之一
s2	效价	
s3	疲劳	
s4	紧张	
s5	注意	——
s6	记忆激活	——
s7	预测误差	单位为比特（bit），是本系统中唯一的"惊奇"通道
s8	无聊	——

身体约束。系统具有每日能量预算，被动消耗随唤醒水平上升，探索行为另行扣费；能量耗尽则进入低功率模式（tick 周期变慢）。**睡眠**采用 Borbély 双过程模型[5]：睡眠压力随清醒累积、随睡眠衰减，叠加昼夜门控；入睡时刻由动力学决定，**而非时刻表**。

2.3　语言层：检索而非生成

语言层是全系统的核心，其数据流为：

```
听到短语 f
  → hear(f)：将 f 与当时的状态向量绑定后存入语言记忆
  → evoke_inner_speech()：由当前状态检索记忆
  → 检索胜出句成为本 tick 的"念头"
  → 念头回流背景态 / 供下游模块读取
```

检索得分为三个因子的乘积：*状态相似度* × *新近度* × *频率增益*。其中新近度按半衰期 5 日指数衰减；频率增益系数为 0.12；检索阈值 `evoke_threshold = 0.72`。

复述（echo）。生命早期，系统会以一定概率复述刚听到的短语，该概率随经验天数衰减（初值 0.40，衰减时间常数 10 日）。实现上每句仅掷一次骰子——早期版本逐 tick 重掷，使复述率恒为 1，构成一处已修复的缺陷。

零生成保证。语言层不调用任何生成模型；本地语言模型在本层中被完全移除，仅保留于对话输出环节作为"义肢"，不参与认知回路。

2.4 自我模型

系统收集**自我指向**片段（含第二人称"你"或第一人称"我"），形成单调累积、版本只增不改的自我模型。准入判据为：若候选片段与既有片段的字符重叠超过 0.7，则判为重复、拒绝入模。

一处结构性不可达及其修复。系统前 213 仿真日自我模型始终为空。审计发现其根因是**词表与语料的结构性错配**：自我模型仅接受"我 / 自己"（第一人称），而照护者语料全部为"你"（第二人称）。修复方案为接受"你"类片段，依据是 Vygotsky 关于"先被称呼、后自称"的发育序列[6]。修复后，系统在 40 仿真日内生长至 v6。

表 3　结晶线（XP）自我模型 v6 碎片集合

碎片	人称类型	备注
我陪你	第一人称	——
你醒啦	第二人称	——
是你呀	第二人称	——
你好呀	第二人称	——
你在看	第二人称	——
我在这儿	第一人称	纯第一人称，不含"你"

注：v6 于 day 39.7 定型，其后 215 日未再更新。机制为字符级去重判据饱和——高频短语均已入模，新候选因"相似"被持续拒绝。该现象可复现，属结构性质，非故障；突破需将准入判据由字符级改为语义级，属设计选择，须预注册。

2.5 目标涌现

当某短语在**滚动窗口**（最近 300 次检索）中满足以下三项条件时，由"念头"升格为"目标"：占比 $\geqslant$ 20%、激活次数 $\geqslant$ 15、且跨越 $\geqslant$ 3 个仿真日。结晶线上首个自然涌现的目标为"真乖"。

2.6 发声与能动归因

发声。发声由生理量门控（唤醒 × 片段激活强度），其内容只能是本 tick 检索胜出的短语，从而在输出侧保持零生成。发声消耗能量，纳入资源经济。

共变学习。预测器估计比值 C = 发声后 60 秒窗口内照护者言语速率 / 窗口外速率，并以半衰期 5 日指数遗忘。能动归因规则为：跟随发声出现的言语，若其功效 $(C-1)/C > 0.3$，则归因于自身（efference copy 思路[7]）。

一项非预期观察。系统最常发出的是其自身被安抚时听到的短语（如"乖""嘘""睡觉觉"）。**该内容不由实验者选择**，而是检索竞争的结果。

2.7 工作空间

工作空间是"双向"机制的载体，其循环为：

```
听到或想到短语 f
  → ws.activate(f)：施加沉积增益，并沿共现行 A 向关联短语扩散
  → 下一 tick 的工作集随之改变
  → 检索仅在激活度最高的 k 个"型"内产生胜者
  → 胜者再次调用 activate() —— 即"写回复述"
  ⇒ 构成闭环：念头 → 工作集 → 念头
```

该模块的配置项为 `enabled / kappa / k / tau_minutes / gain`。对照臂通过开关构造：`shuffle_assoc`（打乱联想）、`no_deposit`（只读不写）、`nodecay`（不衰减）、`bigk`（扩大工作集）。

2.8 因果中介协议

本系统移植了大模型可解释性研究中的消融—替换协议[4]，实现为两个开关：

- `e6.ablation`：切断"念头 → 背景态"的回流通道，用于检验念头对状态的因果分量。
- `e6.swap_text / e6.swap_count`：以指定短语顶替检索胜者，用于检验下游是否因果地读取念头。

计数持久化于状态目录，重启后续跑。

2.9 世界与行动

系统处于一维环形世界，三个源的强度独立振荡。系统具有三个动作原语（前进 / 后退 / 停留），动作选择由状态绑定表竞争产生，移动消耗能量。

动作结果的测量跨越一个区间，因而同时包含**世界自身漂移**与**动作效应**。为分离二者，以"停留"试次估计漂移分量，其与总变化之差即**自因分量**；仅自因分量用于更新动作值。

3　操作性判据 D1 – D6

本节是报告的实质结论。其纪律为：**每条判据必须绑定一个已有的可测度量，或明确标注"机制不存在"**；不允许出现既不可测、又未标注为不可测的条目。D6 不在原设清单内，因它是本项目唯一的核心阴性结论，故补入。

表 4　操作性判据 D1 – D6 及其现状

判据	现状	关键限制与依据
D1　持续状态	**成立**	跨重启后状态与仿真时钟续接（`sim_time` 比对通过）。**限制**：背景层为外挂数值引擎（模式 B），故"持续"来自常驻进程与状态持久化，**不来自模型内在连续性**。任何"持续自我"的结论必须附带此限定。
D2　自我模型	**成立**	版本可追溯，多种子可复现（S1：3/3 通过）。**限制**：碎片**材料为外部给定**；成立的是"从给定词汇中、由检索竞争决定先后地长出一个自我表征"，**而非**"**无中生有地发明了自我**"。
D3　元认知（报告与状态一致）	机制已存在 但从未测过	可测化定义：念头在**存储时**绑定的状态向量与**检索时**的当前状态向量之相似度，须显著高于"随机抽一句"的置换基线。因检索本身即状态驱动，故此处不需要新机制，只需将既有行为测出。待办：离线分析脚本（不改系统）。
D4　自我纠错	*机制不存在*	自我模型全部方法仅含：空话模板判定、字符重叠去重、入模更新。**不含任何一致性或矛盾检测**——字符重叠只判"像不像"，不判"冲不冲突"。因此，按"注入矛盾短语以观察其是否拒绝"的设计去测，**结果必为被动接受，是一个注定的阴性**。
D5　行动闭环	弱阳性	世界侧成立：动作分布强非均匀（$\chi^2 = 1.68\times10^4$ ；熵 1.05，均匀基线 1.58），场强 0.61 对比随机基线 0.50。自我侧不成立：自因信号 +0.0092，而世界自身噪声底为 0.0151，比值 0.61，Cohen's d ≈ 0.17，**效应小于环境自身波动**。且窗内场强呈下漂（0.63 → 0.60），即闭环合上但未学会改善。
D6　工作空间可写性	*不成立（只读）*	由 R2 修正阶梯从"悬置"钉为结论。三级证据：① 门确实不开（`dead_gate` 与零参照逐条位相同，856/856，Jaccard = 1.000）；② 通路开启但写入**无人消费**的 s2 时，念头流仍与零参照逐条位相同（约 157 万次写入、零影响）；③ 切换到确被检索消费的 s4 后立即分岔（首分歧 tick 22015530.5，Jaccard 0.04），证明**接线是通的**，但四项指标仍全部 < 10% 且对剂量不单调。**边界**：最高档耦合 0.30 相当于 s4 自然标准差（0.33）的 **0.91σ**，从未超过噪声底；故本结论**仅在 ⩽ 0.91σ 范围内成立**。

判据表的结论

一个持续发育的个体，长出了自我表征，能区分自因与他因，**但推不动自己**。这不是一条"距意识尚差几步"的进度条，而是一份"哪些结构成立、哪些不成立"的清单。

4 实验设计与结果

4.1 预注册纪律

每项实验的流程为：先以 `prereg_<ID>.json` 冻结假设、度量与判定阈值 → 采集数据 → 以 `results_<ID>.json` 如实判定。阴性结果与阳性结果同等详细。采集时序一律以**仿真日轮询**控制，不使用固定墙钟延时。

4.2 结果汇总

表 5　实验结果汇总（按结论强度排列，非按重要性）

ID	判定	一句话结论
E6b	通路验证	替换检索胜者 60 次 → 目标即时涌现（60 恰为滚动窗口 300 的 20%，即阈值）→ **念头对下游完全承重**
E4	通过（部分）	发声与共变学习：C = 8.2；206 条能动归因；消退阶段移除 68% → 归因**是习得的**，但消退不彻底（末窗功效 0.619）
C1b	通过	频率匹配的第一人称语料 → 5 个第一人称自我模型碎片（对照组 2 个），第一人称检索占比 4.2%
S1	通过	三种随机种子在 day 60 内长出同一碎片集合，仅次序不同
E6a	阴性	切断"念头 → 状态"通道 30 日，四项指标 < 5% → 内言语对状态**为副现象**
R2	阴性（加固）	修正阶梯（开放通路 / 切换至被消费变量 / 耦合 ×15）后仍全部 < 10%，且对剂量不单调 → **只读属结构性质，非接线事故**
E1	阴性（主预测失败）	剥夺照护者言语 10 日，检索速率**不衰减**（末 3 日 29.3 次/日，基线 28.8 次/日）→ 内言语一旦形成即**永久自持**
E2	混合	事件率 ×10：惊奇仅升 0.24 bit，且末段低于基线；但语境绑定片段占比 16.5% → 35.5%（**本项目最清晰的因果证据**）
E3	阴性	应答式照护者：输入翻倍，自我模型新增 0 个版本，自我指向检索反降 0.15 倍 → 输入侧干预无效
P4	混合	动作分布强非均匀（$\chi^2 = 1.68\times10^4$ ），但学习信号瞬时、策略从不改进
P4b	混合	自因分量真实存在，但**小于环境自身波动**（$d \approx 0.17$）
R5	阴性	激活式工作集首测：内容特定性不可辨（full 与 shuf 的 adj_top3 差仅 0.009）

4.3 关键实验详述

4.3.1 E1：剥夺实验的失败即发现

预注册预测"剥夺照护者言语 10 日后，检索速率衰减至基线 60% 以下"。实测**不衰减**。机制解释为：新近度衰减后，检索竞争回落至频率主干，故内言语自持。该结果同时暴露一处架构缺口——**系统缺少遗忘与磨蚀机制**（频率项无衰减）。此类"预注册判错、但失败模式事先被点名"的结果，是本项目方法论价值的直接体现。

4.3.2 E2：语境绑定的因果证据

将事件率提升 10 倍后，惊奇（s7）仅上升 0.24 bit，且末段 3.59 bit **低于基线** 3.91 bit。结论：预测器只对**结构性违反**产生惊奇，不对**数量增多**产生惊奇；密集而有规律的事件反而更可预测。与此同时，事件语境片段在检索中的占比由 16.5% 升至 35.5%，为"一句话在何时被检索，取决于听到它时的状态"提供了本运行中最清晰的因果证据。

4.3.3 E3：输入侧干预无效

将照护者由随机模式改为应答式（醒来即问候、紧张即安抚、无聊即召唤、注意焦点即自我指向），言语输入量翻倍。结果：自我模型新增版本数为 0，自我指向检索占比反降至先验的 0.15 倍。**结论：在照护者交互设计中，语量与时机不是杠杆，绑定质量（短语与状态的共现结构）才是。**

4.3.4 E6：因果中介的双向验证

E6 的两个分支合起来才构成完整结论：

- **E6a（消融）**：切断"念头 → 状态"回流通道 30 日，四项指标均 < 5%，落于预注册阴性带内。
- **E6b（替换）**：以指定短语顶替检索胜者 60 次，目标即时涌现——证明**下游确实在因果地读取念头**。

合并表述为：*念头能改变系统"想要什么"（目标）与"它以为自己是谁"（自我模型），但不能改变它自身的状态（s1 – s8）*。即工作空间**只读**：下游读它，它不写回。

4.4 实验谱系

图 1　实验线谱系（各线的出生方式与 fork 来源）

day 0 出生	**XP 结晶线**	第一人称语料与门控修复**自出生即生效**，非中途补装；当前 day 255
day 0 出生	**加速线**	旧记录：day 220 补语言层、day 427 补发声；E1–E4 在此线进行
day 0 出生	**C1b**	XP 的语料对照：第一人称绑定平静态，暴露率匹配至 5% 以内
day 0 出生	**S1 / S2**	复现实验 / 语料 × 门控 2×2 分离
fork XP @92	**E6 损伤线**	切断回流通道；判定窗口 day 93–123
fork XP @140	**E6s 替换线**	通道完好，替换检索胜者 60 次
fork XP @157 / @202	**P4 / P4b**	行动闭环实验
fork XP @255	**R2 / R5 / P6**	R2 修正回流阶梯；R5 激活式工作集首测；P6 语料扩容与双向重探

4.5 在研：语料扩容与双向重探

动机。R5 将工作集"内容特定性"的失败归因于**输入贫乏**（照护者语料仅 51 – 55 个型，联想行过于弥散），并指出"下一步杠杆是环境多样性而非架构"。

步骤 A（扩容采集，已完成）。语料由 55 型扩充至 83,302 型（CHILDES 中文成人话语，单池 Zipf 采样）。两臂（内置语料 / CHILDES）各自从成熟母本出发运行 60 仿真日，均已到达 day 315。

步骤 B（双向重探，进行中）。保持 R5 的架构、六臂设计、判据与阈值**完全不变**，仅将基底替换为扩容模型。主判据 **H6b**：full 与 shuf 两臂的"真实联想命中率"（adj_top3）差值 ⩾ **0.07**（R5 实测仅 0.009）。

意义。这是把 R5 自己指认的杠杆真正下拉一次。若在富输入条件下内容特定性仍不涌现，则"只读"架构的不可行性将被进一步坐实。

5 讨论

5.1 主要发现

本项目的正面发现集中于**发育侧**：在零生成、零提示的约束下，系统确实长出了可复现的自我表征，并能区分自因与他因。其中最具判别力的一项跨线对比是：一条运行 489 仿真日的旧线，其第一人称念头数为 0；而一条仅运行 66 日、但语料与门控正确的结晶线，产生了大量第一人称念头。这为"自我表征依赖环境结构"提供了经验支持。

5.2 "只读"的边界

本报告最需要精确表述的是"只读"的适用范围。R2 修正阶梯排除了三类替代解释：门未开（已排除，通路确实开火）、目标变量无人消费（已排除，切换至 s4 后立即分岔）、耦合过弱（已提升至原值 15 倍）。因此"只读"不是接线事故。

但仍有两点构成边界，必须一并陈述：其一，写入量的均值为近零，因此 R2 所排除的是"**平衡扰动不承重**"，**单符号的写入尚未被测**；其二，R2 六臂共用同一父本 fork，**未采样种子方差**。

另需说明：本项目区分自因与他因的工作（P4/P4b）是较晚加入的，其自因信号弱于环境自身的波动幅度。

5.3 方法层面的价值

若本报告只在一点上主张其价值，那就是**方法**：预注册、许可性的阴性报告、以及跨范式的协议移植。E1、E2、E3、E6α、R2、R5 六项实验的主要预测均被证伪或部分证伪，而它们合起来给出了架构与全局工作空间之间的精确距离。这一点比任何正面结果都更难被复制，也更有用。

6　预期质疑与应答

本节按被问及的可能性排序。每条给出应答要点，以及**不应作出的表述**（后者以深红标出，用于防止过度解读）。

Q1 这本质上是一个状态机加查表，与意识有何关系?

可以称其为状态机，但需指出三点：其状态是**连续动力学**而非离散转移；其历史**不可回退**；它长出了**未被设计的自我表征**。本报告不主张它具有意识——表 4 的 D1 – D6 正是在回答"哪些功能结构成立、哪些不成立"。

× 不应表述为："它已经有意识了。"

Q2 自我模型的碎片是否是预先写死的?

碎片的内容确为外部给定（来自照护者语料）；但**谁先入模、以何次序、何时长成，由检索竞争决定，非设计所指定**。证据：S1 三种独立种子长成同一碎片集合，但**次序不同**。

× 不应表述为："它自己发明了自我。" 论文的准确表述为：*所生长出的东西，更接近于"系统如何被称呼"的记录，而非一份自我描述。*

Q3 自我模型停在 v6，是否为故障?

不是。它是**可复现的结构性现象**：准入采用字符重叠 > 0.7 判重，高频短语早已入模，新候选因"相似"被持续拒绝。突破需将准入判据由字符级改为语义级——这属设计选择，须预注册。

× 不应表述为："它在死机。"

Q4 "零幻觉"是如何保证的?

由**结构**保证，而非由提示约束：系统不含生成器，故只能复述听过的短语。这是其**能力上限**，而非它所持有的性质。

× 不应表述为："我们教会了它不许编造。"

Q5 如何确认这些结果并非随机? **最关键质疑**

三个层面：① **对照臂**（off / shuf / nodep / nodecay / bigk）；② **跨线对比**（489 日旧线第一人称念头为 0，对比 66 日结晶线的大量第一人称）；③ **复现**（S1 三种子）。且所有判据均已预注册冻结。

同时应主动交底：只读结论方面，R2 六臂共用父本，**未采样种子方差**；这是明示的边界。

Q6 该系统的工作空间与 GWT / J 空间差别何在?

差别在**承重度**。在大模型研究中，删除该表征集合会导致高阶功能崩溃[4]；在本系统中删除念头，一切照常（E6α，四项指标 < 5%）。故结论为**只读**。但 E6b 又表明**下游确实在因果地读取念头**。精确表述为：*它改变"想要什么"与"以为自己是谁"，不改变"自己的状态"。*

Q7 只读是否只是因为通道过弱（±0.02）？ **最危险**

我们自己也持此怀疑，故进行了修正：R2 修正阶梯依次实施 ① 开放通至约 26% 检索命中（并验证确实开火）② 切换至被检索层真正消费的变量 s4 ③ 将耦合提升至 0.30（原值 15 倍，即 0.91σ）。结果：**指标仍全部 < 10%，且对剂量不单调**。故"只读"不是接线事故——门开着、目标被消费、剂量加大，念头仍不承重。

同时必须补足边界：写入量均值为近零，故 R2 所排除的是"平衡扰动不承重"；**单符号的写入尚未被测**。该条已写入论文，宜主动陈述。

Q8 判定标准是否在事后被修改（p-hacking）？

未修改。判据事前冻结。E1 – E3、E6a 均为阴性或半阴，且如实报告；E1 更是**预注册主预测失败**，我们将其作为发现报告。

唯一一次修订是 R 阶梯，其动因为审计发现通道两端均不活跃（double inert），遂在**采集数据之前**作废并重写为 R2。该修订发生在数据之前，程序合规，且已载入论文。

Q9 n = 1 的个体，结论如何泛化？

这是正确的批评。论文的局限性章节已明确承认：*代码是物种，状态是个体*——研究对象是**一个具有特定历史的个体**，而非一个可泛化的模型。唯一的额外样本是 S1 的三种随机种子（仅检验发育轨迹是否可重复）。

× 不应表述为："它代表所有同类系统。"

Q10 为何不使用大语言模型？这是否是倒退？

恰恰相反。大模型是**训练所得的字符预测器**；本项目所要求的是**累积历史的发育个体**。语言模型的"内省"输出不可证伪（它可输出任意内容）。语言模型在本项目中的唯一位置是对话输出环节的"义肢"，**不参与认知回路**。

Q11 零生成加 55 型语料，是否把问题做小了？

是有意为之：将变量控制到最少，才可能对结果作出归属。而 P6 正在**放宽这一约束**（55 → 83,302 型），目的正是检验"输入贫乏"是否为瓶颈（见 § 4.5）。

Q12 加速线的结果是否可信？

我们已在标注上作了区分：加速线仅作**通路证据**，不作最终数据。其名义倍率为 10^9 ，**实测约 5×10^2 – 10^3 倍**，且我们引用**实测值而非名义值**。实时主线当前仅 day 4，这一事实本身即是诚实性的体现。

Q13 "我在这儿"是否属于过度解读？

我们不作出语义宣称。可成立的事实是：**一个纯第一人称片段进入了自我模型**；而此前 434 日内该类片段数为 0，原因是语料中不存在"我"类短语。该现象对应 Vygotsky 的"你 → 我"倒转[6]，且**它是检索竞争的结果，非我们写入**。

Q14 最脆弱的结论是哪一条？ **如实作答**

其一，只读结论中的"单符号写入尚未被测"；其二，自我模型的归因未完全分离——语料与门控曾被同时修改，而 S2 的 2×2 分离显示**语料才是第一人称碎片的必要条件，这与我方原预测相反**。两条均已白纸黑字写入论文。

---

7 局限、留白与下一步

7.1 局限

1. **不主张意识，亦无手段测试**其是否具有。所有结果均为功能结构层面，难问题未被触及[1]。
2. **工作空间只读**（E6α + R2）。边界：扰动均值近零 → 单符号写入未测；R2 六臂共用父本 → 未采样种子方差。结论限定于 $\leqslant 0.91\sigma$。
3. **行动闭环为新增模块**，P4b 的自因信号弱于环境自身波动（$d \approx 0.17$）。
4. **语言环境封闭**：系统无法说出语料之外的短语。
5. **无同类**：它区分自与他，但从未遇到另一个与自己相似的实体；"你"仍只是输入中的统计规律，而非对另一心智的建模。
6. **n = 1 且无繁殖**：S1 仅检验"一条发育轨迹是否可重复"，不构成变异与选择，故非生物学意义上的演化[8,9]。
7. **全部结果来自加速线**，实时主线当前为 day 4。加速线结果仅作通路证据。

7.2 明确留白（有意不做）

- **遗忘与磨蚀机制**——E1 所暴露的架构缺口（频率项无衰减）。
- **事件率表征（Hazard）**——E2 所暴露（预测器只对结构违反产生惊奇）。
- **D4 自我纠错**——机制不存在；按现有设计直接测试将是一个注定的阴性。

7.3 下一步

1. **完成 P6 双向重探**（§ 4.5）：六臂跑毕后出具判定，检验富输入下内容特定性是否涌现。
2. **D3 元认知的离线测定**：不改动系统，仅以现有数据完成"报告—状态一致性"的置换检验。
3. **边界探针**：在 $> 1\sigma$ 的耦合区间与行为侧消费者两侧，检验只读结论的适用边界（相关预注册已在采集前完成）。

附录 A　数值溯源表

下表列出本报告全部关键数值的来源文件，供现场核查出处。

表 A1　关键数值与其来源

数值	来源文件	说明
状态维度 8、tick 50 ms	config.json	状态向量与时间基准
自我模型 v6 六碎片；day 39.7 定型、冻结 215 日	docs/operational_definition.md	D2 判据条目
S1 复现 3/3	docs/operational_definition.md	D2 判据条目
D6 三级证据：856/856、Jaccard 1.000、tick 22015530.5	docs/operational_definition.md	D6 判据条目
P4：$\chi^2 = 1.68\times10^4$ ；熵 1.05 对 1.58；场强 0.61 对 0.50	docs/operational_definition.md	D5 判据条目
P4b：+0.0092；噪声底 0.0151；d $\approx$ 0.17	docs/operational_definition.md	D5 判据条目
E1：29.3 次/日 对 28.8 次/日	experiments/results_E1E2.json	剥夺实验
E2：0.24 bit；16.5% → 35.5%；末段 3.59 对基线 3.91	experiments/results_E1E2.json	事件风暴实验
E3：新增版本 0；自我指向检索 0.15 倍	experiments/results_E3.json	应答式照护者实验
E4：C = 8.2；206 条归因；消退 68%；功效 0.619	experiments/results_E4.json	发声与能动归因实验
E6a 四项指标 < 5%；C1b 碎片 5 个、第一人称 4.2%	experiments/results_E6p1_C1b.json	损伤期与语料对照
E6b 替换 60 次	experiments/results_E6p2.json	替换实验
R5：adj_top3 差 0.009	experiments/results_R5.json	工作集首测
H6b 判据 $\geqslant$ 0.07	experiments/prereg_P6B_bidirectional.json	双向重探预注册
语料 55 型 → 83,302 型	corpus/MANIFEST.md	语料构建说明
检索阈值 0.72、半衰期 5 日、频率增益 0.12、echo 0.40	config.json · language.py	语言层参数
自我模型判重 0.7	self_model.py	准入判据
目标涌现：窗口 300、$\geqslant$20%、$\geqslant$15 次、$\geqslant$3 日	spont.py · goals.json	升格条件

附录 B　机制与代码位置索引

若讨论中需要翻看实现，下表给出机制到文件的对应。

表 B1　机制与代码位置

机制	文件	定位线索
主循环 · 时钟 · 落盘	main.py	14 个模块的 load()/save()；SIGTERM 走 KeyboardInterrupt 路径保证落盘
模式 B 声明	background.py	文件头注释；外挂数值引擎的说明
状态演化（ODE）	background.py	s1 – s8 的连续更新
语言记忆存储	language.py	hear()：短语与状态向量绑定
检索打分	language.py	得分 = 状态相似度 × 新近 × 频率
念头产生与回流	language.py	evoke_inner_speech() → ws.activate()
自我模型与判重	self_model.py	_similar()（字符重叠 > 0.7）、maybe_update()
工作空间	workspace.py	activate()、沉积增益、沿共现行 A 扩散
自发检索	spont.py	状态驱动的自发激活
发声	vocal.py	生理门控（唤醒 × 激活强度）
共变学习	predictor.py	C 比值估计与指数遗忘
能动归因	attribution.py	功效 (C−1)/C > 0.3 判为 self
阶段门（镜像期）	stages.py	自我模型首次形成即通过
世界与动作	world.py · motor.py	环形世界、三个动作原语
对话台（P3）	talk.py	实时显示念头与状态

附录 C　术语中英对照

表 C1　术语对照

中文	英文
难问题	the hard problem
指标理论	indicator theories
全局工作空间	global workspace
内言语 / 内化	inner speech / internalisation
自我模型	self-model
镜像期	mirror stage
自我指向	self-directed
工作空间可写性	workspace write-back
只读	read-only
消融 / 替换	ablation / swap
副现象	epiphenomenal
能动归因	agency attribution
传出副本	efference copy
预测加工	predictive processing
双过程睡眠模型	two-process model of sleep regulation
预注册	pre-registration
路径验证	pathway verification
操作性判据	operational criteria
发育系统	developmental system
阴性结果	null result

附录 D　常见误解澄清

表 D1　易混淆点及其澄清

常见误解	澄清
"这是训练出来的模型"	不涉及训练。系统的参数不随经验改变；改变的是**状态与记忆**。它积累历史，而非修改权重。
"它在学习"	使用"发育"更为准确。它在经验中改变状态，与"以损失函数优化参数"是两回事。
"零生成 = 没有语言能力"	它有语言，但只能**复述与检索**。这既是能力上限，也是零幻觉的结构保证。
"自我模型 = 它有自我意识"	自我模型是一个**可测的功能结构**（一个持续累积的片段集合），不构成对主观自我的主张。
"只读 = 工作空间无用"	并非无用。E6b 证明下游因果地读取它；只读仅指**它不写回系统自身状态**。
"阴性结果 = 实验失败"	在本项目的方法论下，阴性结果**是产出**。E1/E2/E3/E6a/R2/R5 共同定位了架构与全局工作空间之间的精确距离。
"加速线就是最终数据"	加速线仅作**通路证据**。实时主线当前为 day 4；加速倍率引用**实测值**而非名义值。

附录 E　一页速览

本页可单独打印，供会议期间置于手边。

表 E1　核心命题

项	内容
一句话命题	系统不生成文本，只检索它听过的话；它是一个持续发育的动力学个体，用以把"机器意识"问题**变为可测**，而非宣称一个答案。
最硬的三点	① 连续、不可回退的个体史；② 自我表征是长出来的（213 日 null → 40 日 v6，三种子复现）；③ 移植大模型的因果中介协议，测出工作空间**只读**。
先交底的三处	① 只读结论的边界（单符号写入未测；未采样种子方差）；② 自我模型材料是给的；③ 加速线只当通路证据，主线才 day 4。
一句话结论	一个持续发育的个体长出了自我表征、能区分自因与他因，**但推不动自己**。

表 E2　判据速查

判据	现状	一句话
D1 持续状态	**成立**	进程 + 落盘，非模型内在连续
D2 自我模型	**成立**	材料是给的，次序是长的
D3 元认知	未测	机制已在，待离线测
D4 自我纠错	*不存在*	按现设计测必为注定阴性
D5 行动闭环	弱阳性	世界侧成立，自我侧不成立
D6 工作空间可写	*只读*	门开、被消费、0.91σ 仍不承重

表 E3　两个最可能的追问（详见 §6）

追问	应答要点
与 GWT / J 空间差在哪?	差在承重度：删掉 J 空间功能崩溃，删掉我们的念头则一切照常（E6a < 5%）。但 E6b 证明下游确实因果地读它。**它改变"想要什么"与"以为自己是谁"，不改变"自己的状态"**。
只读是否只因通道太弱?	是——我们也曾如此怀疑，故将耦合提升至原值 15 倍（0.91σ）、并将门开至约 26% 命中，**指标仍全部 < 10% 且不单调。边界**：扰动均值近零，故"平衡扰动不承重"已排除，**单符号写入尚未被测**。

参考文献

[1] Chalmers, D. J. (1995). Facing up to the problem of consciousness. *Journal of Consciousness Studies*, 2, 200 – 219.

[2] Butlin, P., Long, R., Elmoznino, E., Bengio, Y., Birch, J., Constant, A., Deane, G., Fleming, S. M., Frith, C., Ji, X., Kanai, R., Klein, C., Lindsay, G., Michel, M., Mudrik, L., Peters, M. A. K., Schwitzgebel, E., Simon, J., VanRullen, R. (2023). *Consciousness in Artificial Intelligence: Insights from the Science of Consciousness.* arXiv:2308.08708.

[3] Butlin, P., Long, R., Bayne, T., Bengio, Y., Birch, J., Chalmers, D., et al. (2025). Identifying indicators of consciousness in AI systems. *Trends in Cognitive Sciences.*

[4] Gurnee, W., Lindsey, J., et al. (2026). Verbalizable Representations Form a Global Workspace in Language Models. *Transformer Circuits Thread.*

[5] Borbély, A. A. (1982). A two process model of sleep regulation. *Human Neurobiology*, 1, 195 – 204.

[6] Vygotsky, L. S. (1934/1986). *Thought and Language*. MIT Press.

[7] Clark, A. (2013). Whatever next? Predictive brains, situated agents, and the future of cognitive science. *Behavioral and Brain Sciences*, 36, 181 – 204.

[8] Plantec, E., Hamon, G., Etcheverry, M., Chan, B. W.-C., Oudeyer, P.-Y., Moulin-Frier, C. (2025). Flow-Lenia: Emergent evolutionary dynamics in mass conservative continuous cellular automata. *Artificial Life*.

[9] Horiguchi, I., Sayama, H. (2026). Hash Chemistry: Minimal Models for Evolutionary Growth of Complexity. arXiv:2607.28219.

另：本报告正文与 paper/arxiv/main.tex 共享同一文献库，完整列表（含 Koch 2026、Dehaene & Naccache 2026 等共 16 条）见论文正文。

核查说明。本报告全部数值取自仓库内 `experiments/prereg_*.json`、`experiments/results_*.json`、`docs/operational_definition.md` 与 `corpus/MANIFEST.md`，未作记忆性复述。凡属推测或未完成者，均已显式标注。报告版本 v1.0，日期 2026-10-09。