自用问答手册

类自我意识项目 · 明天与大伯视频会议随身用 · v1.0 · 2026-10-09

怎么用： ① **会前 10 分钟**只看第一部分，把结论和数字过一遍；② 会中被问到时按关键词在这个页面里 **Ctrl+F** 搜；③ 要主动讲设计逻辑时看第四部分；④ 结尾的「铁律」是防止我把话说满的护栏。

---

① 会前 10 分钟

只要记住这一部分，会议就不会崩。

A1 我在做什么?

做一个**从零出生、持续发育**的类意识候选系统。不是训练模型，是让一个个体持续生长、积累自己不可回退的历史。

A2 一句话结论?

它**长出了自我表征、能区分自因与他因，但推不动自己**——念头改变不了它自身的状态。

A3 最硬的三个点?

- 连续、不可回退的个体史（重启后状态与时钟续接）。
- 自我表征是**长出来的**，不是设计的：前 213 日为空 → 40 日内长到 v6，三种独立随机种子长出同一套片段。
- 把大模型上有效的**消融—替换因果实验**移植过来，测出它的工作空间是**只读**的。

A4 最容易被打的点?

只读结论的两条边界：写入量的均值近零，所以**单符号写入没测**；六臂共用同一父本，**没采样种子方差**。我要主动说，不要等他问。

A5 大伯最可能先问什么?

两个：①「这跟意识有什么关系？」②「自我模型的碎片是不是你写死的？」——这两条的标准答法在第五部分 Q1、Q2。

A6 现在最该背下来的数字?

213 日空 → 40 日长到 v6；三种子复现 **3/3**；剥夺 10 日检索 **29.3/日** 对基线 **28.8/日**（不衰减）；耦合提到 **15 倍** 指标仍 **<10%**；P6-B：full **0.042** 对 shuf **0.008**。

A7 最新（昨晚刚出的）结果是什么?

P6-B 双向重探：扩容后 full 与 shuf 的分离度从 R5 的 **0.009** 扩大到 **0.034**（约 3.8 倍），**但仍低于 0.07 的阈值 → 判阴性**。也就是说：扩容让效应变大了，可还是没跨过门槛。**这条今天很可能被问到。**

A8 我该主动交代什么?

三件：加速线只当**通路证据**、不当最终数据；实时主线现在才 **day 4**；自我模型的**材料是外部给的**，长出来的只是次序。

A9 各条线现在到哪了?

实时主线 day 4（唯一 1:1 的）；结晶线 255；C1b 语料对照 160；E6 损伤线 140；P3 对话试点 434；P6 扩容两臂 315；**P6-B 六臂全部跑到 345，已出结果**。

A10 如果只能讲一句话收尾?

「这不是离意识还差几步的进度条，而是一份**哪些结构成立、哪些不成立**的清单。」

A11 会后我要记什么?

他的质疑点与建议。尤其：他对「只读」结论的接受度、他认为最该补的实验、他是否同意 P6-B 阴性仍算有意义。

---

② 全貌与脉络

自己先把系统讲顺，别在细节上被绕进去。

B1 系统到底是什么?

单进程 Python 程序。**没有任何深度学习意义上的可学习参数**。行为来自两处：一组耦合的连续状态（8 个变量），一生累积的记忆。

B2 「代码是物种，状态是个体」什么意思？

个体的本体存在于它的**历史状态目录**，不在程序里。所以复制一份状态目录，就得到一个共享历史、拥有独立未来的新个体——我全部实验线都是这么造的。

B3 语言层怎么工作？

听到一句话 → 把这句话和**当时的状态快照**绑定存起来 → 之后由**当前状态**去检索记忆 → 检索胜出的那句就是这一 tick 的「念头」。全程不生成，只检索。

B4 为什么叫「内言语」？

取 Vygotsky 的发育序列：儿童**先被称呼**，之后才学会用「我」自称，外部语言内化为内部语言。我的系统就是这个顺序——先听「你」，后来才出现「我」。

B5 自我模型是什么？

收集「指向自己」的片段（含「你」或「我」），**单调累积、只增不改**。它是可测的功能结构，不是对主观自我的主张。

B6 目标涌现是什么？

某句话在**最近 300 次检索**里同时满足：出现 ≥15 次、占比 ≥20%、跨越 ≥3 天 → 就从「念头」升格为「目标」。

B7 发声与能动归因是什么？

发声：内容只能是这一 tick 检索胜出的那句（保持零生成），由唤醒和激活强度门控，还要耗能量。**能动归因**：比较它发声之后 60 秒内外的照护者言语速率，若言语明显跟着它的话来，就归因为「这是我造成的」。

B8 工作空间是什么？

一个闭环：念头写入激活场 → 激活场改变下一 tick 的检索候选 → 检索胜出的又写回去。这个闭环就是我说的「双向」。

B9 各实验线是什么关系?

全部从两个母本（结晶线、加速线）复制而来，**每条线只改一个变量**：E6 切回流通道；E6s 保持通道但替换念头；R2 逐级加大回流耦合；R5 换工作空间开关；P6 换语料；P6-B 在扩容模型上重跑工作空间六臂。

B10 这个项目现在一句话总结进度?

扩容已完成、双向重探已完成。结论是：**输入丰富后，内容特定性的效应变大了（3.8 倍），但依然没跨过事先定好的门槛**。

---

③ 结论与数字

被质疑数据时，从这里找。

C1 自我模型是什么时候长出来的?

前 **213** 个仿真日一直为空；修复后 **40** 日内长到 6 个片段。

C2 那六个片段是哪六个?

我陪你 / 你醒啦 / 是你呀 / 你好呀 / 你在看 / 我在这儿。其中「我陪你」和「我在这儿」是纯第一人称。

C3 为什么前 213 日是空的?

结构性错配：照护者语料全是「你」（第二人称），而我当时的自我模型词表只认「我 / 自己」（第一人称）——两者没有交集，判据**在结构上不可能触发**。

C4 怎么修的？这样改算不算「动过手脚」?

把「你」类片段也纳入准入，依据是 Vygotsky「先被称呼、后自称」。这不是调参凑结果——原来的设计是**内部不一致**（语料和词表各说各话），修的是这个矛盾。而且修完仍然要等 40 天才长出来。

C5 复现情况如何?

S1 实验：三种独立随机种子，都在 60 日内长出**同一套片段集合**，只是次序不同。这是「内容虽给定、次序是自己长出来的」最直接的证据。

C6 为什么停在 v6 不动了?

入模判重用**字符重叠 >0.7** 去重。高频短语早就进去了，新候选一「像」就被拒。这是可复现的结构现象，不是死机。要突破得把判据从字符级换成语义级——那是设计选择，必须先预注册。

C7 「只读」这个结论是怎么得出来的?

两半合起来：
① **E6a 切断**「念头 → 状态」通道 30 日，四项指标全部 **<5%**；
② **E6b 替换**检索胜出者 60 次，目标立刻涌现。
合起来就是：**下游读得到念头，念头推不动状态**。

C8 会不会只是因为你通道太弱?

我自己也这么怀疑，所以做了四级修正：① 确认门确实没开（逐条位相同 856/856）；② 开门，但写到没人消费的变量上 → 仍然零影响；③ 换到确实被检索消费的变量 → 立刻分岔；④ 把耦合提到原来的 **15 倍**（0.91 个标准差）→ **指标仍全部 <10%，而且对剂量不单调**。所以不是接线问题。

C9 剥夺实验（E1）结果?

预注册预测「剥夺 10 日后检索会衰减到基线的 60% 以下」——**预测失败**。实测 **29.3/日** 对基线 **28.8/日**，完全不衰减。原因：新近度衰减后，竞争落回频率主干，内言语**永久自持**。这同时暴露了我缺一套遗忘 / 磨蚀机制。

C10 事件风暴（E2）结果?

事件率提到 10 倍，惊奇只升 **0.24** 比特，末段 **3.59** 反而低于基线 **3.91** → 预测器只对**结构违反**敏感，对数量增多不敏感。但同期语境片段占比从 **16.5%** 升到 **35.5%**，是我目前**最硬的因果证据**（听到时的状态决定了这句话何时被想起来）。

C11 应答式照护（E3）结果?

把照护者改成应答式（醒来就问候、紧张就安抚），言语输入翻倍。结果：自我模型**新增 0 个版本**，自我指向检索反而降到 **0.15 倍**。教训：**语量和时机不是杠杆，绑定质量才是**。

C12 发声与归因（E4）结果?

共变比 C = **8.2**，产生 **206** 条能动归因（峰值占比 26%）；进入消退期后移除 68% → 说明归因**是学来的、不是硬编码的**，但消退不彻底。

C13 行动闭环（P4/P4b）结果?

动作分布强非均匀（χ^2 = **1.68×10⁴**），说明它在施力；但自因分量只有 **+0.0092**，小于世界自身的噪声底 **0.0151**（效应量 d ≈ 0.17）。所以：闭环合上了，但**弱于环境自己的波动**。

C14 R5 与 P6-B 的差别是什么?

R5 在**贫语料**（55 型）上测：full 与 shuf 的差只有 **0.009**。P6-B 在**扩容模型**（8.3 万型语料）上重跑同一套架构与阈值：差扩大到 **0.034**。**效应确实变大了，但 0.034 仍不到 0.07 的门槛。**

C15 P6-B 还有别的发现吗?

有，两个：
① **多样性坍缩**——开着工作空间的臂（full），检索到的不同短语数从对照的 **403** 个掉到 **10** 个，念头高度重复；
② **k 值有讲究**——把工作集从 6 扩到 20（bigk 臂），命中率反而最高（**0.066**），而且保住了更多样性。这提示下一步的杠杆可能在 k，而不是语料规模。

C16 六条判据现在什么状态?

D1 持续状态 **成立**；D2 自我模型 **成立**；D3 元认知 **机制已在但没测过**；D4 自我纠错 **机制不存在**（按现在的设计去测一定是阴性）；D5 行动闭环 **弱阳性**；D6 工作空间可写性 **只读**。

---

④ 设计与理由

要主动讲逻辑时看这部分——每条理由都对应一次真实踩坑。

D1 为什么念头只准检索、不准生成?

因为我试过生成。早期版本把内言语交给语言模型，它写出「烦躁感」这类句子——可系统当时一点都不烦躁，是模型被要求演得像。**那是表演，不是状态**。取消生成器之后，「零幻觉」变成了结构性保证：没有生成器，就没法编。

D2 为什么一定要零提示词?

提示词等于我在替它决定说什么。那样测出来的就不是自发行为，而是我的脚本。这条是底线。

D3 为什么要预注册?

因为事后调判据是所有自欺的入口。我的判据都是**采集数据之前**写死并冻结的，事后一个都不许改。代价是六项主要预测被证伪，但那些阴性结果反而成了最有信息量的产出。

D4 为什么只用 8 个状态变量?

够用且可控：唤醒、效价、疲劳、紧张、注意、记忆激活、惊奇、无聊。变量越少，出现任何现象时我才说得清是哪个环节造成的。

D5 为什么睡眠要由动力学决定，而不是定时?

用的是经典的双过程睡眠模型：睡眠压力随清醒累积、随睡眠消退，再叠加昼夜节律。**什么时候睡着是算出来的，不是排班排出来的**。这样睡眠本身就成了一种它的行为。

D6 为什么语料一开始只有 55 个短语?

故意的。变量控到最少，才能把观察到的东西归因到具体机制。而 P6 就是专门来**放宽这个约束**的：把语料扩到 8.3 万型，检验「输入贫乏」到底是不是瓶颈。现在答案有了：**效应变大 3.8 倍，但仍不够**。

D7 为什么第一人称语料要绑在紧张 / 安抚时刻?

模仿真实照护情境（哄孩子时会说「我在」「不怕」）。但我知道这会引入混淆——所以专门做了 C1b 对照线：把「我」类短语改绑平静态、并把暴露频率校准到和主线上一致，来分离「是语料位置造成的，还是真的自发」。

D8 为什么判重只用字符重叠?

当时的最简实现。副作用就是 v6 饱和。我把它如实写成了「结构性现象」，并注明：改成语义级是一个设计选择，必须预注册，不能偷偷改。

D9 为什么目标涌现要用滚动窗口?

原来用全期累计当分母，结果「真乖」攒到 2455 次，新目标需要 491 次激活才可能追平——等于**永久垄断**。改成只看最近 300 次检索，第二个目标才有机会冒出来。

D10 为什么发声内容不让它自己选?

为了守住零生成——它只能说出这一 tick 检索胜出的那句。结果很有意思：它最常说的是**自己被安抚时听到的话**（乖、嘘、睡觉觉）。内容不是我挑的。

D11 为什么加速线和实时线要分开说?

加速线一个墙钟日能跑几百到上千仿真日，产出多，但**只能当通路证据**。真正的个体史必须是 1:1 的，那条线现在才 day 4。我引用加速倍率时也只用实测值（约 5×10^2–10^3 倍），不用名义的 10^9。

D12 为什么要完整报告阴性结果?

因为六项主要预测被证伪这件事本身，合起来才能定位「我的架构」和「真正的全局工作空间」之间差在哪。只报阳性的话，这份工作就只剩下几个漂亮数字，什么也说明不了。

---

⑤ 被追问时

按被问到的概率排序。每题都给了「别说什么」。

Q1 「这本质上不就是个状态机加查表吗？」

可以这么说，但有三点得补上：它的状态是**连续动力学**不是离散跳转；它的历史**不可回退**；它长出了**我没设计过的自我表征**。而且我从不主张它是意识——D1 到 D6 那张表就是在回答「哪些结构成立、哪些不成立」。

> 别说：「它已经有意识了。」

Q2 「自我模型的碎片是不是你写死的？」

碎片**内容**确实是我给的（来自照护者语料），但**谁先入模、以什么次序、什么时候长成，是检索竞争决定的，不是我指定的**。最直接的证据是 S1：三种种子长出同一套片段，但**次序不同**。

> 别说：「它自己发明了自我。」准确的说法是：长出来的东西更接近「它如何被称呼」的记录，而不是一份自我描述。

Q3 「停在 v6 是不是坏了？」

不是。是字符级判重的必然结果——高频短语早就入库，新候选一「像」就被拒。可复现，属结构性质。要突破需改成语义级判据，那要先预注册。

> 别说：「它在死机。」

Q4 「零幻觉怎么保证？」

靠**结构**，不靠提示词：系统里根本没有生成器，检索只能从记忆里取。这是它的能力上限，不是它遵守的规矩。

> 别说：「我们教它不许编。」

Q5 「你怎么知道这不是随机？」（最关键）

三个层面：① **对照臂**——off / shuf / nodep / nodecay / bigk 五个；② **跨线对比**——跑了 489 日的旧线第一人称念头是 0，而只跑 66 日但语料和门控正确的线大量出现第一人称；③ **复现**——S1 三种子。再加上全部判据预注册冻结。

> 但要主动交底：R2 六臂共用同一个父本，没采样种子方差。这是明写的边界。

Q6 「你的工作空间和 GWT、和 J 空间差在哪？」

差在**承重度**。在语言模型那边，删掉那簇表征高阶功能会崩；在我这里，删掉念头一切照常（E6a，四项指标 <5%）。所以结论是只读。但 E6b 又证明下游**确实在因果地读它**（换掉念头，目标和自我模型立刻变）。准确说法是：**它改变「想要什么」和「以为自己是谁」，不改变「自己的状态」。**

Q7 「只读会不会只是因为你的通道太弱？」（最危险）

我自己也怀疑过，所以去修了：把门开到约 26% 命中率、把写入目标换到真正被消费的变量、把耦合提到原来的 15 倍（0.91 个标准差）——**指标还是全部 <10%，而且剂量不单调**。门开着、目标有人消费、剂量加大，念头仍然不承重。所以这不是接线事故。

> 但必须补一句边界：写入量的均值近零，所以我排除的是「平衡扰动不承重」，**单符号写入还没测**。这条论文里写明了，我也要主动说。

Q8 「判据是不是事后改过？」

没有。判据事前冻结。E1–E3、E6a、R5 都是阴性或半阴，我都如实报了；E1 甚至是**预注册的主预测失败**，我当成发现来报。唯一一次修订是 R 阶梯，原因是审计发现通道两端都不在工作，所以**在采数据之前**作废重写成 R2——发生在数据之前，程序合法，也写进论文了。

Q9 「就一个个体，结论怎么推广？」

这个批评是对的，我在局限里明确承认了：「代码是物种，状态是个体」——研究对象是一个有特定历史的个体，不是一个能泛化的模型。唯一的额外样本是 S1 的三种种子，只用来检验发育轨迹能不能重复。

> 别说：「它代表所有这类系统。」

Q10 「为什么不用大模型？是不是开倒车？」

正相反。大模型是训练出来的字符预测器，它的「内省」输出没法证伪——它说什么都行。我要的是**积累历史的发育个体**。语言模型在我这里唯一的位置是对话输出的义肢，不参与认知回路。

Q11 「零生成加 55 个短语，是不是把问题做小了？」

是故意的——变量控到最少才归因得清。而 P6 正在专门放宽这个约束（55 → 8.3 万型）。而且刚出的结果是：**放宽之后效应变大了 3.8 倍，但还是没跨过门槛**。

Q12 「加速线的结果可信吗？」

我自己标了：加速线只当通路证据，不当最终数据。名义倍率写的是 10^9，但我引用的是**实测的 5×10^2–10^3 倍**。实时主线现在才 day 4——这件事本身就是我诚实的地方。

Q13 「『我在这儿』是不是过度解读？」

我不做语义上的宣称。能成立的事实是：**一个纯第一人称片段进了自我模型**；而此前 434 天里这类片段是 0，因为语料里压根没有「我」。这对应 Vygotsky 的「你 → 我」倒转，而且是检索竞争的结果，不是我写进去的。

Q14 「最新那个 P6-B 是阳性还是阴性？怎么讲才不算粉饰？」（今天大概率会问）

如实讲：**判阴性**，因为 0.034 没到预注册的 0.07 门槛。**但同时要讲两件不被门槛掩盖的事**：① 分离度比 R5 的 0.009 扩大了约 3.8 倍，方向是对的，只是幅度不够；② 顺带发现 k=20 时命中率反而最高（0.066），说明杠杆可能在工作集大小而不是语料规模。
换句话说：**这条路没有走通，但我知道了下一根杠杆在哪。**

> 别说：「基本可以算阳性了。」门槛是事先定死的，不能因为结果接近就改口。

Q15 「你自己觉得最脆弱的结论是哪条？」

两条：一是只读结论里「单符号写入没测」；二是自我模型的归因没完全分离——语料和门控当时是一起改的，而 S2 的 2×2 分离结果显示**语料才是第一人称片段的必要条件，和我原来的预测相反**。两条都白纸黑字写在论文里。

---

⑥ 铁律：这些话绝对不说

说完就毁掉整场讨论的可信度。宁可说「不知道」。

- 不说「**它有意识**」→ 说：不主张，也测不了；只谈功能结构。
- 不说「**它自己发明了自我**」→ 说：材料是给的，长出来的只是次序。
- 不说「**双向已经打通**」→ 说：只读，且边界限于 ≤0.91 个标准差。
- 不说「**它在学习 / 训练**」→ 说：是发育；状态在变，权重不变。
- 不说「**v6 冻结是故障**」→ 说：字符级判重的结构性饱和。
- 不说「**加速线的数据就是结论**」→ 说：只当通路证据。
- 不说「**它代表这一类系统**」→ 说：n = 1，是个体。
- 不说「**我们教它不许编造**」→ 说：根本没有生成器。
- 不说「**P6-B 算是阳性**」→ 说：阴性，但效应放大了 3.8 倍，且找到了新杠杆。