生长而非训练：一个预注册的发育系统及其工作空间的只读性质

Growing Rather Than Training: A Pre-Registered Developmental System and the Read-Only Nature of Its Workspace

Luo Chengze

独立研究者 · ORCID 0009-0007-3316-6292

会议讨论稿 · 版本 v2.0 · 2026-10-09

摘要

当前关于机器意识的研究大多以既有大语言模型为对象，通过探测其内部表征或解读其自我报告来评估意识指标。本文采取一条相反的路径：构建一个**从零出生、持续发育**的动力学个体，其内部言语只能检索曾听到过的短语，认知回路中不含任何生成模型，因而"零幻觉"是结构性质而非提示约束。

我们为该个体形式化定义六条**操作性判据**（D1 – D6），并对每条判据给出可机械执行的检测方法。主要结果是一条阴性结论：将一个在大语言模型上有效的*消融—替换*（ablation-and-swap）因果中介协议移植到本系统后，其工作空间表现为**只读**——下游（目标涌现、自我模型）确实在因果地读取内部言语，但内部言语**不能反过来改变系统自身的状态变量**。该结论经四级修正阶梯加固后仍成立，故判为结构性质而非实现缺陷。

本文的全部实验均经预注册，六项实验的主要假设被证伪或部分证伪，我们将其与阳性结果同等详细地报告。我们认为，这种"以阴性结果定位架构与全局工作空间之间精确距离"的做法，本身即是贡献的一部分。

*关键词：*人工意识，操作性判据，预注册，全局工作空间，内化言语，自我模型，因果中介，阴性结果

1 引言

1.1 *研究问题*

关于机器意识，至少存在三条已被明确表述的路径。第一条以**自我报告**为证据：询问模型是否具有体验，并采信其回答。第二条为**不可知论**：认为该问题在方法论上不可问，因而停止追问。第三条为**指标理论**：不问"是否具有意识"，而问"该系统具备哪些由意识理论推导出的功能性质"[1,2]。

本文采纳第三条路径的提问方式，但更换其研究对象与检验纪律。我们不评估一个已完成训练的系统，而是构建一个**从零出生、连续运行、不可回退**的个体，并追问：在严格约束下，它会自发长出哪些功能结构，哪些长不出来，以及每一条如何被机械检测。

本文有意回避*难问题*（the hard problem）[3]：我们不主张、也不试图测量主观体验，全部结论限于功能结构层。相应地，本文的核心产出不是一份"距离意识尚差几步"的进度表，而是一份**哪些结构成立、哪些不成立**的清单。

1.2 *贡献*

1. **一条可复现的阴性结论**。将一个在大语言模型可解释性研究中有效的因果中介协议[4]移植至本系统，其在四级修正阶梯加固下仍失效，据此判定工作空间为只读（§5.3.5）。据我们所知，该结论尚未见报告。
2. **一条可复现的发育现象**。系统的自我模型在前 213 个仿真日为空，其后于 40 日内生长至 6 个片段；三种独立随机种子在 60 日内生长出**相同的片段集合**，仅次序不同（§5.3.3）。

3. **一份形式化的操作性判据（D1 – D6）**。每条判据绑定一个可测度量，或明确标注"机制不存在"（§4）。
4. **一组预注册阴性结果及其解释**。四项实验的主要预测被证伪，我们据此定位了架构缺口（§5.3）。

1.3 *认识论承诺*

以下四条为设计约束，均可被验证或证伪，且贯穿全文：

1. **内部言语只检索、不生成**。认知回路中不含任何生成模型。此约束由一次失败导出：早期版本以语言模型生成内部言语，其输出"烦躁感"一类表述，而系统当时并无相应状态。此后我们取消该设计，并以"没有生成器即无法编造"作为零幻觉的结构保证。
2. **零提示词、零方向引导**。不对系统施加任何"应当说什么"的提示，行为必须自发产生。
3. **预注册与如实报阴**。假设、度量与判定阈值在数据采集前冻结；阴性结果与阳性结果同等详细地报告。
4. **只谈功能结构**。不涉及主观体验，亦不将其降级为可测问题。

2 相关工作

2.1 *AI 意识指标理论*

Butlin 等系统梳理了意识科学中的若干理论（全局工作空间理论、高阶表征理论、预测加工、注意图式理论等），并从中导出十四条"指标性质"，逐条评估现有 AI 系统[1]。其 2025 年的修订将方法重心从"指标清单"转向"如何校准指标与生物学证据之间的关系"，但主要结论未变：现有系统满足的指标数量不足[2]。批评者进一步指出，指标路线面临**校准问题**——若无法在生物系统上独立标定指标的阈值，指标清单可能只是形式合规[5,6]。

本文与该路线的分歧不在指标本身，而在对象与纪律：我们以一个从零发育的个体替代已完成训练的系统，并对每条判据提供预注册与阴性报告。

2.2 *语言模型中的全局工作空间*

Gurnee 与 Lindsey 等报告，语言模型内部存在一小簇可被*言语化*（verbalizable）、可控且因果中介多步推理的表征，删除该表征集合会导致高阶功能崩溃，而流畅生成仍然保留；作者据此论证其为一种全局工作空间[4]。Dehaene 与 Naccache 的评述则认为，该结构缺少身体与自传体记忆两项要素，因而与生物学意义上的工作空间仍有距离[7]。

本文与上述工作有两处直接关联。其一，我们**采纳其消融—替换协议**，并将其移植到一个具有身体约束与不可回退历史的系统上。其二，移植结果**与语言模型中的发现相反**：在本系统中，删除内部言语不改变任何行为指标。

2.3 *内化言语的发育视角*

Vygotsky 指出，儿童**先被他人称呼**，其后才习得用第一人称自我称呼，外部语言经由社会互动内化为内部语言[8]。本文的语言层直接实现该序列：短语与其被听到时的状态向量绑定存储，其后由当前状态检索。该设计亦与预测加工的框架相容——大脑持续生成对输入的预测并以预测误差更新表征[9]。

2.4 *人工生命与开放式演化*

开放式演化研究通过大规模的变异、竞争与继承产生复杂性[10,11]。本系统目前不具备上述任何一项：它**是单个个体在生长**，而非种群在演化。我们对"多种子复现"的实验仅为检验单条发育轨迹是否可重复，不构成变异与选择（见 §6.2）。

3 方法

3.1 *系统总览*

系统为单进程 Python 程序，**不含深度学习意义上的可学习参数**。其行为来自两处：一组耦合常微分方程构成的连续状态，以及一生累积的记忆。设计原则可概括为"*代码是物种，状态是个体*"：个体的本体存在于其历史状态目录而非程序本身。因此，复制状态目录即得到一个共享历史、拥有独立未来的新个体——本文全部实验线均以该方式构造（§ 5.1）。

主循环见算法 1。系统以固定 tick 推进：先更新连续状态，再更新预测与能量，随后进行语言层（检索、复述、目标维护）与输出侧（发声、归因）处理，最后落盘。

算法 1　主循环（单 tick）

1: 读取当前墙钟，按时间倍率推进一步仿真时间 `Δt`
2: **更新状态**：s ← 积分(式 1)；若在睡眠期，按式 3 – 4 更新睡眠压力
3: **输入处理**：若产生事件或收到照护者言语，调用 `hear(x)` 绑定状态后存入记忆 `M`
4: **语言层**：以概率 `P(retrieve)` 触发检索（算法 2）；以概率 `p_echo` 复述（式 10）；更新目标窗口（式 14）
5: **工作空间**：对听到或检索胜出的短语执行 `activate(·)`（算法 3），并执行时间衰减（式 12）
6: **输出侧**：若满足发声门控，发声（式 18）；更新共变比 `C` 与功效 η（式 15 – 17）
7: **落盘**：每 `tick` 增量追加，心跳与退出时全量保存

3.2 *状态动力学*

系统维持 8 维连续状态 $s = (s_1, \cdots, s_8) \in [0,1]^8$。代码中仅使用中性下标，人类可读语义（唤醒、效价、疲劳、紧张、注意、记忆激活、预测误差、无聊）仅出现于配置文件中供观察者参考。状态以显式欧拉法积分，并附乘性噪声：

$$s(t+\Delta t) = \mathrm{clip}[\, s(t) + f(s)\cdot\Delta t + \varepsilon\cdot\sqrt{\Delta t}\,,\, 0,\, 1\,], \quad \varepsilon \sim N(0,\sigma^2), \quad \sigma = 0.003 \tag{1}$$

其中清醒期与睡眠期的向量场不同，昼夜调制由余弦函数给出：

$$C(t) = \tfrac{1}{2}\cdot[1 + \cos(\,2\pi(\mathrm{hour} - 15)/24\,)] \tag{2}$$

$$\text{清醒：}\ \frac{d\,s_1}{dt} = \frac{\mathrm{clip}(0.15 + 0.8C) - s_1}{1.5}, \qquad \frac{dP}{dt} = 0.05\cdot(0.6 + s_1) \tag{3}$$

$$\text{睡眠：}\ \frac{d\,s_1}{dt} = \frac{0.05 - s_1}{0.5}, \qquad \frac{dP}{dt} = -0.15\cdot(0.5 + s_3) \tag{4}$$

入睡条件为 $P \geqslant 0.75$ 且 (hour $\geqslant 21$ 或 hour < 6)；唤醒条件为 $P \leqslant 0.35$ 且 $5 \leqslant$ hour < 12。该模型即 Borbély 的双过程睡眠调节[12]：**入睡时刻由动力学决定，而非时刻表**。其余各维的演化与事件瞬写为：

$$\frac{d\,s_2}{dt} = -\frac{s_2}{6.0}, \quad \frac{d\,s_4}{dt} = -\frac{s_4}{2.0}, \quad \frac{d\,s_6}{dt} = -\frac{s_6}{4.0}, \quad \frac{d\,s_8}{dt} = 0.08 \tag{5}$$

$$\text{事件瞬写：}\ \Delta s_4 \mathrel{+}= 0.25\cdot\frac{S}{4}, \quad \Delta s_6 \mathrel{+}= 0.4, \quad s_8 \leftarrow s_8\cdot(1 - 0.8\cdot \mathit{novelty}) \tag{6}$$

其中 S 为预测误差（比特），是系统中唯一的"惊奇"通道；$\mathit{novelty} = \mathrm{clip}[(S - \mathit{ref} + 0.5)/2, 0, 1]$。

3.3 *语言层*

语言层是系统的核心，其设计目标是**以检索替代生成**。数据流为：听到短语 x → 将 x 与当时的状态快照绑定后存入语言记忆 M → 由当前状态检索 M → 检索胜出者成为本 tick 的"念头" → 念头回流背景态并供下游模块读取。

3.3.1 检索打分

候选短语 x（其存储状态为 a）对当前状态 b 的得分为三个因子之积。状态相似度采用**加权 L1 相似度**（而非余弦或高斯核），权重集中于四个维度：

$$sim(a,b) = \frac{\sum_{i \in I} w_i \cdot (1 - |a_i - b_i|)}{\sum_{i \in I} w_i}, \quad I = \{1,4,6,7\}, \quad w = (1.0,\ 1.2,\ 1.5,\ 1.0) \tag{7}$$

新近度按半衰期 $\tau = 5$ 日的指数衰减，频率增益取对数形式：

$$\rho(x) = 0.5^{\max(0,\, d_x - 0.02)/\tau}, \quad \tau = 5.0 \text{ 日}, \qquad \gamma(x) = 1 + g \cdot \ln(1 + n_x), \quad g = 0.12 \tag{8}$$

$$score(x) = sim(a,b) \cdot (0.35 + 0.65\rho) \cdot \gamma \cdot (0.9 + 0.2\xi), \quad \xi \sim U(0,1) \tag{9}$$

其中 n_x 为 x 在记忆中的出现次数，d_x 为其年龄（日），末项为内部涨落。检索另受一道概率门与一个硬阈值控制：

$$P(\text{retrieve}) = 0.06 + 0.20 \cdot salience, \qquad \text{接受} \iff score \geqslant \Theta, \quad \Theta = 0.72 \tag{10}$$

3.3.2 复述与遗忘

生命早期，系统以一定概率复述刚听到的短语，该概率随经验天数衰减：

$$p_{\text{echo}}(d) = \frac{p_0}{1 + d/\tau_e}, \quad p_0 = 0.40, \quad \tau_e = 10.0 \text{ 日} \tag{11}$$

实现上每句仅采样一次（早期版本逐 tick 重采样，导致复述率恒为 1，属已修复缺陷）。**需要强调的是：系统不存在对已存片段的遗忘机制**。式 8 的新近度衰减只作用于打分，不删除记忆；记忆仅在超过 1.2×10^5 条时按先进先出截断。该缺口在 §5.3.1 的剥夺实验中暴露。

算法 2　检索与内部言语

```
function retrieve(s, M, W)
若 U(0,1) > P(retrieve) then return ∅      ▷ 概率门，式 10
候选集 X ← { x ∈ M : x ∈ W }               ▷ 工作集过滤（算法 3）
对每个 x ∈ X 计算 score(x)                 ▷ 式 7 – 9
x* ← argmax_x score(x)
若 score(x*) < Θ then return ∅
activate(x*)                               ▷ 写回工作空间，算法 3
将 x* 作为本 tick 念头回流背景态，并供下游读取
return x*
```

3.4 *自我模型*

系统收集**自我指向**片段（含第二人称"你"或第一人称"我"），构成单调累积、版本只增不改的自我模型 S。片段准入采用字符集合的 Jaccard 相似度作为去重判据：

$$J(A,B) = \frac{|A \cap B|}{|A \cup B|} \leqslant 0.7 \quad \Longrightarrow \text{判为已存在，拒绝入模} \tag{12}$$

其中 A、B 为候选片段与既有片段的字符集合。该判据是**字符级**而非语义级，其后果在 §5.3.3 中讨论。

观察 1（213 日空窗的结构性根因）. 系统的自我模型在前 213 个仿真日始终为空。审计表明其根因为**词表与语料的结构性错配**：自我模型仅接受第一人称片段（"我""自己"），而照护者语料全部为第二人称（"你"）。在词表层面，两者无交集，故判据结构性不可达。

修复方案为将第二人称片段纳入准入集合，其依据是 Vygotsky 关于"先被称呼、后自称"的发育序列[8]。修复后，系统在 40 个仿真日内生长至 6 个片段（§5.3.3）。

3.5 *目标涌现*

当某短语在**滚动窗口**内的统计量同时满足三项条件时，其由"念头"升格为"目标"：

$$n_{\mathrm{x}}^{\mathrm{win}} \geqslant 15 \quad \wedge \quad \frac{n_{\mathrm{x}}^{\mathrm{win}}}{N^{\mathrm{win}}} \geqslant 0.2 \quad \wedge \quad |D_{\mathrm{x}}^{\mathrm{win}}| \geqslant 3, \quad \text{窗口} = 300 \text{ 次检索} \tag{13}$$

其中 N^{win} 为窗口内检索总数，$D_{\mathrm{x}}^{\mathrm{win}}$ 为 x 被激活的仿真日集合。滚动窗口的设计动机是**打破先入者垄断**：在早期实现中，分母为全期累计检索数，一旦某短语早期占优即永久垄断，新目标无法产生。

3.6 *发声与能动归因*

输出侧遵循同一零生成原则：发声内容只能是本 tick 检索胜出的短语。发声由生理量门控，并消耗能量：

$$p_{\mathrm{voc}} = p_{\mathrm{b}} \cdot (0.3 + 0.7\mathrm{s}_1) \cdot (0.2 + 0.8 \cdot \mathrm{intensity}), \quad \mathrm{intensity} = \mathrm{clip}[(w[\mathrm{x}] - 0.6)/0.4,\, 0,\, 1] \tag{14}$$

其中 $w[\mathrm{x}]$ 为短语 x 的工作空间激活（式 15），门控条件为 $\mathrm{s}_1 \geqslant 0.55$，基准概率 $p_{\mathrm{b}} = 0.25$，每次发声消耗 1.0 能量单位（日预算 100）。

能动归因的核心是一个共变比 C：比较发声之后 60 秒窗口内外的照护者言语速率。

$$C = \frac{r_{\mathrm{in}}}{r_{\mathrm{out}}}, \quad r_{\mathrm{in}} = \frac{\mathrm{n}_{\mathrm{speech}}^{\mathrm{in}}}{\mathrm{t}_{\mathrm{act}}}, \quad r_{\mathrm{out}} = \frac{\mathrm{n}_{\mathrm{speech}}^{\mathrm{out}}}{\mathrm{t}_{\mathrm{total}} - \mathrm{t}_{\mathrm{act}}} \tag{15}$$

$$\eta = \min[\,0.8,\, (C-1)/C\,] \quad (C > 1;\ \text{否则 } \eta = 0), \qquad \text{归因 } \mathit{self} \Longleftrightarrow \text{在窗内} \ \wedge\ \eta > 0.3 \tag{16}$$

该设计沿用了传出副本（efference copy）的思路：系统通过比较"有自身动作"与"无自身动作"两种条件下的世界变化，将前者中由自身导致的分量检出并归因于自身[9]。

3.7 *工作空间*

工作空间是"双向"机制的载体：内部言语经 `activate()` 写入激活场，激活场经 top-k 选择改变检索候选集，检索胜者再次写回，从而构成闭环。其更新规则为沉积、扩散与指数衰减三步：

$$w[\mathrm{x}] \leftarrow w[\mathrm{x}] + g_{\mathrm{dep}}, \quad w[\mathrm{y}] \leftarrow w[\mathrm{y}] + \kappa \cdot \frac{A[\mathrm{x}][\mathrm{y}]}{\Sigma_{\mathrm{y}'}\ A[\mathrm{x}][\mathrm{y}'\ ]} \quad \forall \mathrm{y} \in \mathrm{nbr}(\mathrm{x}) \tag{17}$$

$$w \leftarrow w \ \cdot\ \exp(-\Delta \mathrm{t} \cdot 60/\tau_{\mathrm{w}}), \quad \tau_{\mathrm{w}} = 10.0 \text{ min}, \qquad \text{工作集 } W = \text{top-}k(w), \quad k = 6 \tag{18}$$

其中 A 为一阶共现矩阵（由短语被听到的顺序累积），$g_{\mathrm{dep}} = 1.0$，$\kappa = 1.0$。式 17 的第一项即"念头写回自身"，第二项为联想扩散。对照臂通过关闭或扰动上述各项构造（§5.1）：`no_deposit`（仅扩散不沉积）、`shuffle_assoc`（打乱 A 的行内对应）、`nodecay`（$\tau_{\mathrm{w}} \to 10^5$）、`bigk`（$k = 20$）。

算法 3　工作空间更新 `activate(x)`

1: 若 `no_deposit` 为假：$w[x] \leftarrow w[x] + g_{\text{dep}}$　▷ *沉积*
2: 对 x 的每个共现后继 y：按式 17 第二项累加扩散量
3: 累加沉积计数 `n_deposit` ← `n_deposit` + 1
4: 每 tick 调用 decay(Δt)：按式 18 对全场上激活执行指数衰减
5: 检索时取 $W = \text{top-}k(w)$ 作为候选过滤集（算法 2 第 3 行）

这一闭环即本文所称的"双向"：念头 → 激活场 → 检索候选 → 念头。§ 5.3.5 的消融实验正是针对该闭环中"念头 → 状态"这一段。

3.8 *因果中介协议*

本文移植大语言模型可解释性研究中的消融—替换协议[4]，实现为两个开关：

- `e6.ablation`：切断"念头 → 背景态"的回流通道，用于检验念头对状态变量的因果分量。
- `e6.swap_text / e6.swap_count`：以指定短语顶替检索胜出者，用于检验下游是否因果地读取念头。

两个开关的计数持久化于状态目录，重启后续跑。其判定逻辑为：若消融与替换均产生可测效应，则工作空间承重；若替换有效而消融无效，则工作空间为只读——下游读它，它不写回。

4 操作性判据

本节给出六条操作性判据，其纪律为：**每条判据必须绑定一个可测度量，或明确标注"机制不存在"**；不允许出现既不可测、又未标注为不可测的条目。D6 不在最初设计的清单内，因它是本文唯一的核心阴性结论，故补入。

表 1　操作性判据 D1 – D6 及其检测方法与现状

判据	检测方法	现状	关键限制
D1 持续状态	发送 SIGTERM → 重启 → 比对状态文件中的仿真时钟是否续接；检查日志出现恢复记录	成立	背景层为外挂数值引擎，故"持续"来自常驻进程与状态持久化，**不来自模型内在连续性**。任何"持续自我"的结论均须附此限定
D2 自我模型	检查版本号 > 0、每版带时间戳与来源；多种子是否均可形成	成立	片段**材料为外部给定**。成立的是"从给定词汇中、由检索竞争决定先后地长出自我表征"，而非"无中生有地发明了自我"
D3 元认知（报告与状态一致）	将念头**存储时**绑定的状态向量与**检索时**的当前状态做相似度，与"随机抽一句"的置换基线比较	机制已存在但未测	因检索本身即状态驱动（式 7 – 9），此处无需新机制，只需将既有行为测出。待办：离线分析脚本，不改动系统
D4 自我纠错	注入与既有片段矛盾的短语，观察是否被拒绝、修正或标记异常	**机制不存在**	自我模型仅含字符重叠去重与入模更新，**不含任何一致性或矛盾检测**。故按上述设计去测，**结果必为被动接受，是一个注定的阴性**
D5 行动闭环	自因分量是否可靠非零；动作分布是否显著非均匀；是否存在学习曲线	弱阳性	世界侧成立（$\chi^2 = 1.68\times10^4$；熵 1.05 对均匀基线 1.58；场强 0.61 对随机 0.50）；自我侧不成立（自因 +0.0092 对世界噪声底 0.0151，$d \approx 0.17$）。且窗内场强下漂（0.63 → 0.60），即闭环合上但未学会改善
D6 工作空间可写性	切断"念头 → 状态"通道后，行为指标是否可测地改变	**不成立（只读）**	由四级修正阶梯从"悬置"钉为结论（§ 5.3.5）。**边界**：最高档耦合 0.30 相当于 s_4 自然标准差（0.33）的 0.91σ，故结论**仅在 $\leqslant 0.91\sigma$ 范围内成立**

结论 1. 一个持续发育的个体长出了自我表征，能区分自因与他因，**但推不动自己**。判据表的意义不在于给出"距意识尚差几步"的度量，而在于明确哪些功能结构成立、哪些不成立。

5 实验

5.1 *预注册协议与实验线构造*

每项实验遵循同一流程：先以 `prereg_<ID>.json` 冻结假设、度量与判定阈值，再采集数据，最后以 `results_<ID>.json` 如实判定。阴性结果与阳性结果同等详细。采集时序一律以**仿真日轮询**控制，不使用固定墙钟延时。

实验线通过复制母本状态目录构造（§ 3.1）：复制品携带母本的全部历史，但其随机数流、工作空间、实验计数等被显式清除，因而与母本及彼此构成"共享历史、独立未来"的个体。图 1 给出各线的构造来源。

图 1　实验线谱系

day 0 出生	**结晶线 XP**	第一人称语料与门控修复自出生即生效（非中途补装）；本文的参照线
day 0 出生	**加速线**	旧记录：day 220 补语言层、day 427 补发声；E1 – E4 在此线进行
day 0 出生	**C1b**	XP 的语料对照：第一人称短语绑定平静态，暴露率匹配至 5% 以内
day 0 出生	**S1 / S2**	复现实验 / 语料 × 门控 2×2 分离设计
fork XP @92	**E6 损伤线**	切断回流通道；判定窗口 day 93 – 123
fork XP @140	**E6s 替换线**	通道完好，替换检索胜出者 60 次
fork XP @157 / @202	**P4 / P4b**	行动闭环实验
fork XP @255	**R2 / R5 / P6**	R2 修正回流阶梯；R5 激活式工作集首测；P6 语料扩容与双向重探

5.2 *评估指标*

工作空间类实验以检索序列 *seq*（窗口内 `type == "retrieval"` 的短语序列）为基本对象，定义如下指标。真值图由参照线的语言记忆按**被听到顺序**重建：对每个型 x 记录其权重最高的 3 个后继型，记为 *top3*(x)。

表 2　评估指标定义

指标	定义	随机基线 / 说明
`adj_top3`	相邻对命中率：$\lvert seq[\mathrm{i}{+}1] \in top3(seq[\mathrm{i}])\rvert \,/\, (\lvert seq\rvert - 1)$。即"下一个念头是否落在上一个念头的真实后继之中"	$\approx 3/K$，K 为真值图型数。本文用于检验**内容特定性**
`recur5`	类型复现率：$\lvert i : seq[\mathrm{i}] \in \{seq[\mathrm{i}{-}5 \cdots \mathrm{i}{-}1]\}\rvert \,/\, (\lvert seq\rvert - 5)$	——
`self_ratio`	自我指向占比：$\lvert r : r.\text{self_directed}\rvert \,/\, \lvert seq\rvert$，其中 self_directed 定义为短语含"你"或"我"	——
`diversity`	去重型数占比：n_{uniq} / K，n_{uniq} 为 *seq* 中去重后的型数	注：名为"多样性"，实为去重型数占比，非熵
`Jaccard`	逐 tick 检索图的集合重叠：$\lvert T_{\text{ctl}} \cap T_{\text{exp}}\rvert \,/\, \lvert T_{\text{ctl}} \cup T_{\text{exp}}\rvert$，$T$ = {tick → 胜出短语}	1.000 表示两臂逐条位相同；趋近 0 表示完全分岔
`n_dep` / `n_asso`	`n_dep` = `activate()` 累计调用次数；`n_asso` = 共现矩阵中作为前驱的型数	用于确认"操作确实发生"

5.3 *结果*

表 3　实验结果汇总（按结论强度排列，非按重要性）

ID	判定	一句话结论
E6b	通路验证	替换检索胜出者 60 次 → 目标即时涌现（60 恰为窗口 300 的 20%，即阈值）→ **念头对下游完全承重**
E4	通过（部分）	发声与共变学习：C = 8.2；206 条能动归因；消退阶段移除 68% → 归因**是习得的**，但消退不彻底（末窗功效 0.619）
C1b	通过	频率匹配的第一人称语料 → 5 个第一人称自我模型片段（对照组 2 个），第一人称检索占比 4.2%
S1	通过	三种独立随机种子在 60 日内长出相同片段集合，仅次序不同
E6a	阴性	切断"念头 → 状态"通道 30 日，四项指标 < 5% → 内部言语对状态**为副现象**
R2	阴性（加固）	四级修正阶梯后指标仍全部 < 10%，且对剂量不单调 → **只读属结构性质，非实现缺陷**
E1	阴性（主预测失败）	剥夺照护者言语 10 日，检索速率**不衰减**（末 3 日 29.3 次/日，基线 28.8 次/日）→ 内部言语一旦形成即**永久自持**
E2	混合	事件率 ×10：惊奇仅升 0.24 比特，且末段低于基线；但语境绑定短语占比 16.5% → 35.5%（**本文最清晰的因果证据**）
E3	阴性	应答式照护者：输入翻倍，自我模型新增 0 个版本，自我指向检索反降 0.15 倍 → 输入侧干预无效
P4	混合	动作分布强非均匀（$\chi^2 = 1.68\times10^4$），但学习信号瞬时、策略从不改进
P4b	混合	自因分量真实存在，但**小于环境自身波动**（$d \approx 0.17$）
R5	阴性	激活式工作集首测：内容特定性不可辨（full 与 shuf 的 adj_top3 差仅 0.009，远低于 0.07 阈值）

5.3.1 E1：剥夺实验的阴性结果及其解释

预注册假设 H1：剥夺照护者言语 10 日后，检索速率衰减至基线的 60% 以下。**实测不衰减**（末 3 日 29.3 次/日对基线 28.8 次/日）。机制解释为：新近度因子（式 8）随时间衰减后，检索竞争回落至频率主干，故内部言语自持。该项失败同时暴露一处架构缺口——**系统缺少遗忘与磨蚀机制**（频率项无衰减，且记忆不被删除）。

我们认为该结果体现了预注册的价值：失败模式在假设陈述时已被点名（假设中明确包含"若检索不衰减则说明存在自持机制"），因而结果虽为阴性，却可解释、可定位。

5.3.2 E2：语境绑定的因果证据

将事件率提升至 10 倍后，预测误差 S 仅上升 0.24 比特，且末段 3.59 比特**低于**基线 3.91 比特。结论：预测器只对**结构性违反**产生惊奇，不对**数量增多**产生惊奇；密集而有规律的事件反而更可预测。与此同时，事件语境短语在检索中的占比由 16.5% 升至 35.5%，为"一个短语在何时被检索，取决于它被听到时的状态"提供了本文最清晰的因果证据。

5.3.3 D2 相关：自我模型的生长与复现

结晶线的自我模型于 day 39.7 定型为 6 个片段（"我陪你""你醒啦""是你呀""你好呀""你在看""我在这儿"，其中两条为纯第一人称），其后 215 日未再更新。后者并非故障，而是式 12 字符级判据的必然结果：高频短语均已入模，新候选因"相似"被持续拒绝。

三种独立随机种子（S1）在 60 日内生长出**相同的片段集合**，仅次序不同。这一复现为"片段内容虽为给定，但其入模次序由检索竞争决定"提供了直接证据。

此外，将语料与门控做 2×2 分离设计（S2）后，四个条件均形成自我模型，但**第一人称片段仅出现在听到第一人称语料的条件下**。该结果**与我们的原预测相反**（原预测为门控是必要条件），我们如实报告。

5.3.4 E3：输入侧干预无效

将照护者由随机模式改为应答式（醒来即问候、紧张即安抚、无聊即召唤、注意焦点即自我指向），言语输入量翻倍。结果：自我模型新增版本数为 0，自我指向检索占比反降至先验的 0.15 倍。结论：在照护者交互设计中，**语量与时机不是杠杆，绑定质量（短语与状态的共现结构）才是**。

5.3.5 E6 与 R2：工作空间的只读性

E6 的两个分支合起来构成完整结论：

- **E6a（消融）**：切断"念头 → 状态"回流通道 30 日，四项指标均 < 5%，落于预注册阴性带内。
- **E6b（替换）**：以指定短语顶替检索胜出者 60 次，目标即时涌现——证明**下游确实在因果地读取念头**。

即：*念头能改变系统"想要什么"（目标）与"它以为自己是谁"（自我模型），但不能改变它自身的状态（s_1 – s_8）*。

由于 E6a 的阴性可能源于通道过弱，我们实施四级修正阶梯（R2）予以排除：

表 4　R2 修正阶梯

级	修正	结果
1	验证通路确实未开启	实验臂与零参照**逐条位相同**（856/856，Jaccard = 1.000），复现 E6a
2	开放通路，但写入**无人消费**的状态变量 s_2	通道开火（效价写入约 1.57×10^6 次），念头流仍与零参照逐条位相同 → 写入无消费者即无影响
3	切换到确被检索层消费的变量 s_4	立即分岔（首分歧 tick 22015530.5，Jaccard 0.04）→ **接线是通的**，非实现缺陷
4	将耦合提升至原值的 15 倍（0.30，即 0.91σ）	四项指标仍全部 < 10%，且**对剂量不单调** → 判为结构性质

注：第 4 级的 0.30 相当于 s_4 自然标准差（0.33）的 0.91σ，从未超过噪声底；故本结论仅在 $\leqslant 0.91\sigma$ 范围内成立。此外，写入量的均值为近零，故本阶梯排除的是"平衡扰动不承重"，单符号的写入尚未被测。

5.4 *在研：语料扩容与双向重探*

R5 将工作集"内容特定性"的失败归因于**输入贫乏**——照护者语料仅含 51 – 55 个型，联想行过于弥散——并指出"下一步的杠杆是环境多样性而非架构"。为检验该归因，我们设计了两步实验。

步骤 A（扩容采集，已完成）。语料由 55 型扩充至 8.33×10^4 型（CHILDES 中文成人话语，单池 Zipf 采样）。两臂（内置语料 / CHILDES）各自从成熟母本出发运行 60 仿真日，均已到达 day 315。

步骤 B（双向重探，进行中）。保持 R5 的架构、六臂设计、判据与阈值**完全不变**，仅将基底替换为扩容模型。主判据 H6b：full 与 shuf 两臂在 `adj_top3` 上的差值 $\geqslant 0.07$（该阈值由 R5 事前设定，不因新数据调整）。

意义。这是把 R5 自己指认的杠杆真正下拉一次。若在富输入条件下内容特定性仍不涌现，则"只读"架构的不可行性将被进一步坐实；若涌现，则本文的只读结论应被限定为"贫输入条件下的结论"。

6 讨论

6.1 *主要发现*

本文的正面发现集中于**发育侧**：在零生成、零提示的约束下，系统确实长出了可复现的自我表征，并能区分自因与他因。其中最具判别力的是一项跨线对比：一条运行 489 个仿真日的旧线，其第一人称念头数为 0；而一条仅运行 66 日、但语料与门控正确的线，产生了大量第一人称念头。这为"自我表征依赖环境的语料结构"提供了经验支持。

负面发现则集中于**整合侧**：系统具备一个形式上的全局工作空间闭环（式 17 – 18），但其"念头 → 状态"的分量不可测。按 Dehaene 与 Naccache 的评述框架[7]，本系统具备身体约束与不可回退历史，却仍无法把内部言语转化为对自身的因果影响。

6.2 *效度威胁*

本节按内部、外部、构念与统计四类，逐条列出威胁。我们认为，与前文阴性结果同等重要的是对其边界的明确陈述。

表 5　效度威胁

类别	威胁	应对与残余风险
内部效度	R2 六臂共用同一父本 fork，**未采样种子方差**；自我模型的语料与门控曾被同时修改，归因不完全分离	前者只能通过多种子重跑消除，属已记录的残余风险；后者已由 S2 的 2×2 分离部分解决，但结果显示**语料才是第一人称片段的必要条件，与原预测相反**
内部效度	只读结论的写入量均值为近零，可能混淆"无因果分量"与"平衡扰动"	已在 §5.3.5 明确限定：本结论排除平衡扰动不承重，**单符号写入未测**
外部效度	$n = 1$：研究对象是单个具有特定历史的个体	论文层面承认"代码是物种，状态是个体"。唯一的额外样本为 S1 三种子，且仅检验发育轨迹可重复。不做跨系统泛化声明
外部效度	语言环境封闭，系统无法产生语料外短语；缺乏同类（从未遇到另一个与自己相似的实体）	属设计取舍而非缺陷；"你"在本文中始终是输入的统计规律，而非对另一心智的建模
构念效度	自我模型、目标、只读等术语带有心理学与哲学负荷	全部术语均在 §4 给出操作性定义，且每条判据绑定可测度量或标注"机制不存在"
构念效度	D4 的机制不存在，导致相关检验是**注定阴性**	已在判据表中明确标注，避免将其误读为"系统未能通过自我纠错检验"
统计结论效度	关键效应量偏小（P4b：$d \approx 0.17$）；修正阶梯对剂量不单调	因此我们只报告"存在耦合"或"无因果分量"，不宣布"双向已成立"。通用边界为：任何 > 10% 的行为差异仅报存在耦合

6.3 *什么结果会改变我们的结论*

为使上述结论可证伪，我们显式列出会推翻本文主张的观测：

- 若在 P6 的扩容模型上，full 与 shuf 的 `adj_top3` 差值 $\geqslant 0.07$，则内容特定性在富输入下确实涌现，本文的 R5 阴性结论应被限定为"贫输入条件下的结论"。
- 若将回流耦合提升至 $> 1\sigma$ 后指标出现单调、可复现的剂量—效应关系，则只读结论应被撤回，改判为"高阈值下的可写"。
- 若单符号写入（而非平衡扰动）产生可测效应，则 §5.3.5 的边界陈述应被替换为新的机制解释。

7 结论

本文报告了一个从零发育的类意识候选系统及其六条操作性判据。系统的核心设计是以检索替代生成，从而在结构上排除幻觉；其核心实验结果是工作空间的只读性；其核心方法是预注册与对阴性结果的完整报告。

我们认为，本项目最可复制的部分不是任何单项正面结果，而是**方法**：在六项主要预测被证伪之后，我们仍能精确定位架构与全局工作空间之间的距离。这一定位能力，比任何无法证伪的正面声明都更有用，也更接近可累积的研究。

附录 A　符号表

表 A1　主要符号

符号	含义	取值 / 出处
$s = (s_1 \ldots s_8)$	连续状态向量	$\in [0,1]^8$ ；式 1 – 6
Δt	仿真时间步长	tick = 0.05 s
S	预测误差（惊奇）	单位：比特；式 6
M	语言记忆（短语 → 状态快照）	容量上限 1.2×10^5
x	短语（型）	——
n_x, d_x	短语 x 的出现次数与年龄（日）	式 8
sim	加权 L1 状态相似度	权重 (1.0, 1.2, 1.5, 1.0)；式 7
Θ	检索阈值	0.72；式 10
τ	新近度半衰期	5.0 日；式 8
g	频率增益系数	0.12；式 8
p_echo	复述概率	初值 0.40，衰减 10 日；式 11
w	工作空间激活场	短语 → 实数；式 17 – 18
A	一阶共现矩阵	由听到顺序累积
κ, k, τ_w	扩散系数 / 工作集大小 / 激活半衰期	1.0, 6, 10 min
W	工作集（top-k）	式 18
C, η	共变比 / 功效	式 15 – 16
J(A,B)	字符集合 Jaccard 相似度	阈值 0.7；式 12
K	真值图的型总数	R5：51；P6-B：640

附录 B　超参数

表 B1　主要超参数（除注明外均为各线共享的默认值）

模块	参数	值
时间	tick / 时间倍率	0.05 s / 加速线名义 10^9 （实测约 5×10^2 – 10^3 倍实时）
状态	noise_sigma	0.003
状态	s_2 松弛 / s_4 松弛 / s_6 衰减	6.0 / 2.0 / 4.0 小时
状态	事件瞬写：Δs_4 / Δs_6	0.25 · S/4 / +0.4
昼夜	峰值时刻 / P 上升 / P 衰减	15 时 / 0.05 / 0.15
昼夜	入睡 / 唤醒阈值	0.75（且 ⩾21 时或 <6 时）/ 0.35（且 5 – 12 时）
语言	evoke_threshold / evoke_interval	0.72 / 120 s
语言	recency_half_life / frequency_gain	5.0 日 / 0.12
语言	echo_prob_initial / echo_decay_days	0.40 / 10.0 日
语言	相似度权重（s_1 ,s_4 ,s_6 ,s_7 ）	(1.0, 1.2, 1.5, 1.0)
目标	窗口 / min_activations / min_fraction / min_days	300 / 15 / 0.2 / 3
工作空间	enabled / $\varkappa$ / k / τ_w / gain	对照臂按 §3.7 构造；full 为 1.0 / 6 / 10 min / 1.0
发声	arousal_gate / base_prob / energy_cost	0.55 / 0.25 / 1.0
预测	共变半衰期 / 跟随窗	5 仿真日 / 60 s
归因	功效阈值 / 记录窗口	0.3 / 500
自我模型	判重阈值 / 长度上限	0.7 / 4000 字符
能量	日预算 / 基础耗散 / 唤醒因子 / 探索代价	100 / 0.8 h^{-1} / 2.0 / 5.0
回流	reflow s_2 / reflow s_5	0.02 / 0.015

附录 C　预注册对照表

表 C1　假设、冻结阈值与实测结果

ID	假设与冻结阈值	实测	判定
E1	剥夺后检索速率 ⩽ 基线 60%	29.3 次/日 对 28.8 次/日（不衰减）	**证伪**（成为发现）
E2	事件率 ×10 使惊奇显著上升	+0.24 比特，末段 3.59 < 基线 3.91	部分证伪；语境绑定 16.5%→35.5% 为正
E3	应答式照护使自我模型加速（⩾ 8 新版本）	0 新版本；自我指向 0.15×（反向）	**证伪**
E4	H4a $C > 3$；H4b 归因 ⩾ 20 且 self_ratio > 4%；H4c 消退	$C = 8.2$；206 条，峰值 26%；消退移除 68%	H4a/H4b 通过；H4c 部分
E6a	消融使四指标改变 > 10%	四项 < 5%	**阴性**（副现象）
E6b	替换 60 次使目标涌现	目标即时涌现	通过（通路验证）
R5 / H5b	full 与 shuf 的 adj_top3 差 < 0.07 判阴	0.371 对 0.380，差 0.009	**阴性**
R2	修正阶梯后若指标仍 < 10% 则不单调 → 结构性质	全部 < 10%，且不单调	只读结论成立
P6-A / H1	M2(childes)/M2(builtin) ∈ [0.5, 2.0]	扩容至 8.33×10^4 型并成功出语言	通过（详见 P6 分析）
P6-A / H3	M5(childes) ⩾ M5(builtin)	进行分析中	待定
P6-B / H6b	full 与 shuf 的 adj_top3 差 ⩾ 0.07 为阳	采集完成，分析中	待定

注：阈值均由 R5 事前设定并承接至 P6-B，不因新数据调整。唯一一次修订发生在 R 阶梯：因审计发现通道两端均不活跃，在采集数据之前作废并重写为 R2。

附录 D　复现清单

表 D1　复现要素

要素	内容
代码与环境	单 Python 进程；依赖见项目根目录；主入口 `main.py`，配置经环境变量 `CONFIG` 指定
确定性	加速臂使用 `time.seed_python_random = true` 对齐随机数流；随机状态持久化于 `rng_state.json`
个体构造	复制母本状态目录，并清除 `pid` / `e6_state.json` / `rng_state.json` / `spont.*` / `affect.json` / `workspace.json` 后启动
运行	`./venv/bin/python main.py --time-scale 1e9`；以 `caffeinate -i -w` 保活；结束以 `kill -TERM` 触发优雅落盘
采集控制	以**仿真日轮询**判定到达目标日数后停止，不使用固定墙钟延时；harness 可续跑
分析	离线分析脚本读取各臂状态目录；真值图由参照线的语言记忆重建；分析器经环境变量参数化以复用
数据	每项实验的 `prereg_*.json` 与 `results_*.json` 均随仓库保留

附录 E　应答预备（补充材料）

以下条目不属于论文正文，系为口头讨论准备的问答要点，其中"不应表述"一栏用于防止过度解读。

Q1 这本质上是一个状态机加查表，与意识有何关系?

可以称其为状态机，但需指出：其状态为连续动力学（式 1 – 6）而非离散转移；其历史不可回退；其自我表征并非由设计指定。本文不主张它具有意识——表 1 的 D1 – D6 正是在回答哪些结构成立、哪些不成立。

× 不应表述为："它已经有意识了。"

Q2 自我模型的片段是否为预先写死?

片段内容确为外部给定；但谁先入模、以何次序、何时长成，由检索竞争决定。证据：S1 三种种子长成相同集合但次序不同。更准确的表述是——所生长出的东西，更接近于"系统如何被称呼"的记录，而非一份自我描述。

× 不应表述为："它自己发明了自我。"

Q3 自我模型停在 6 个片段，是否为故障?

不是。它是式 12 字符级判据的必然结果：高频短语早已入模，新候选因"相似"被持续拒绝。突破需将准入判据由字符级改为语义级，属设计选择，须预注册。

× 不应表述为："它在死机。"

Q4 "零幻觉"如何保证?

由结构保证：系统不含生成器（算法 2 的返回值只能取自记忆），故只能复述听过的短语。这是其能力上限，而非它所持有的性质。

× 不应表述为："我们教会了它不许编造。"

Q5 如何确认结果并非随机?

三个层面：① 对照臂（off / shuf / nodep / nodecay / bigk）；② 跨线对比（489 日旧线第一人称念头为 0，对比 66 日参照线的大量第一人称）；③ 复现（S1 三种子）。且全部判据已预注册冻结。

应主动交底：R2 六臂共用父本，未采样种子方差（见 § 6.2）。

Q6 本系统的工作空间与全局工作空间理论、以及语言模型中的"J 空间"差别何在?

差别在承重度。在语言模型研究中，删除该表征集合导致高阶功能崩溃[4]；在本系统中删除念头，一切照常（E6a，四项指标 < 5%）。故结论为只读。但 E6b 表明下游确实在因果地读取念头。精确表述：*它改变"想要什么"与"以为自己是谁"，不改变"自己的状态"*。

Q7 只读是否只是因为通道过弱（±0.02）?

我们自己也持此怀疑，故实施了四级修正阶梯（表 4）：开放通路至约 26% 检索命中、切换至被消费的变量 s_4 、将耦合提升至原值 15 倍（0.30，即 0.91σ）。结果：四项指标仍全部 < 10%，且对剂量不单调。故只读不是实现缺陷。

必须补足边界：写入量均值为近零，故本阶梯排除的是"平衡扰动不承重"，单符号写入尚未被测（见 § 5.3.5 与 § 6.2）。

Q8 判定标准是否在事后被修改?

未修改。判据事前冻结（附录 C）。E1 – E3、E6a、R5 均为阴性或半阴，且如实报告；E1 是预注册主预测失败，我们将其作为发现报告。唯一一次修订是 R 阶梯，其动因为在采集数据之前审计发现通道两端均不活跃，程序合规。

Q9 $n = 1$ 的个体，结论如何泛化?

这是正确的批评。论文明确承认"代码是物种，状态是个体"——研究对象是一个具有特定历史的个体（ § 6.2）。唯一的额外样本是 S1 的三种随机种子，且仅用于检验发育轨迹的可重复性。

× 不应表述为："它代表所有同类系统。"

Q10 为何不使用大语言模型?

大模型是训练所得的字符预测器，其"内省"输出不可证伪。本文要求的是累积历史的发育个体。语言模型在本项目中的唯一位置是对话输出环节的义肢，不参与认知回路（算法 1 – 2 不引用任何生成模型）。

Q11 零生成加 55 型语料，是否把问题做小了?

是有意为之：将变量控制到最少，才可能对结果作出归属。而 P6 正在放宽这一约束（$55 \rightarrow 8.33\times10^4$ 型），目的正是检验"输入贫乏"是否为瓶颈（ § 5.4）。

Q12 加速线的结果是否可信?

我们已在标注上作了区分：加速线仅作通路证据，不作最终数据。其名义倍率为 10^9 ，实测约 5×10^2 – 10^3 倍，且我们引用实测值而非名义值。实时主线当前仅 day 4。

Q13 "我在这儿"是否属于过度解读?

我们不作出语义宣称。可成立的事实是：一个纯第一人称片段进入了自我模型；而此前 434 日内该类片段数为 0，原因是语料中不存在"我"类短语。该现象对应 Vygotsky 的"你 → 我"倒转[8]，且它是检索竞争的结果，非我们写入。

Q14 最脆弱的结论是哪一条?

其一，只读结论中"单符号写入尚未被测"；其二，自我模型的归因未完全分离——语料与门控曾被同时修改，而 S2 的 2×2 分离显示语料才是第一人称片段的必要条件，与我们原预测相反。两条均已写入 § 5.3.3、 § 5.3.5 与 § 6.2。

参考文献

[1] Butlin, P., Long, R., Elmoznino, E., Bengio, Y., Birch, J., Constant, A., Deane, G., Fleming, S. M., Frith, C., Ji, X., Kanai, R., Klein, C., Lindsay, G., Michel, M., Mudrik, L., Peters, M. A. K., Schwitzgebel, E., Simon, J., VanRullen, R. (2023). *Consciousness in Artificial Intelligence: Insights from the Science of Consciousness.* arXiv:2308.08708.

[2] Butlin, P., Long, R., Bayne, T., Bengio, Y., Birch, J., Chalmers, D., et al. (2025). Identifying indicators of consciousness in AI systems. *Trends in Cognitive Sciences.*

[3] Chalmers, D. J. (1995). Facing up to the problem of consciousness. *Journal of Consciousness Studies*, 2, 200 – 219.

[4] Gurnee, W., Lindsey, J., et al. (2026). Verbalizable Representations Form a Global Workspace in Language Models. *Transformer Circuits Thread.*

[5] Koch, F. (2026). From indicators to biology: the calibration problem in artificial consciousness. arXiv:2603.27597.

[6] Immertreu, M., Schilling, A., Maier, A., Krauss, P. (2025). Probing for consciousness in machines. *Frontiers in Artificial Intelligence*, 8, 1610225.

[7] Dehaene, S., Naccache, L. (2026). Does Claude possess a conscious global workspace? External commentary, Anthropic.

[8] Vygotsky, L. S. (1934/1986). *Thought and Language.* MIT Press.

[9] Clark, A. (2013). Whatever next? Predictive brains, situated agents, and the future of cognitive science. *Behavioral and Brain Sciences*, 36, 181 – 204.

[10] Plantec, E., Hamon, G., Etcheverry, M., Chan, B. W.-C., Oudeyer, P.-Y., Moulin-Frier, C. (2025). Flow-Lenia: Emergent evolutionary dynamics in mass conservative continuous cellular automata. *Artificial Life.*

[11] Horiguchi, I., Sayama, H. (2026). Hash Chemistry: Minimal Models for Evolutionary Growth of Complexity. arXiv:2607.28219.

[12] Borbély, A. A. (1982). A two process model of sleep regulation. *Human Neurobiology*, 1, 195 – 204.

[13] Baars, B. J. (1988). *A Cognitive Theory of Consciousness.* Cambridge University Press.

[14] Dehaene, S., Naccache, L. (2001). Towards a cognitive neuroscience of consciousness. *Cognition*, 79, 1 – 37.

[15] Prentner, R. (2025). Artificial Consciousness as Interface Representation. arXiv:2508.04383.

数据可得性。本文全部数值取自仓库内的预注册文件（`experiments/prereg_*.json`）、结果文件（`experiments/results_*.json`）与操作性判据文档（`docs/operational_definition.md`），未作记忆性复述；状态目录按 `state_<line>/` 组织，可逐字段复核。凡属推测或未完成者，均已显式标注。