从 P0 到 P7：一个发育型类意识候选系统的阶段设计、实验矩阵与研究叙事

Stage-by-stage design, the experiment matrix, and how the whole thing becomes a paper

Luo Chengze · 独立研究者 · ORCID 0009-0007-3316-6292

版本 v1.0 · 2026-10-09 · 依据仓库内 README / prereg_*.json / results_*.json / phase_log.txt 还原

摘要

本文档还原本项目自 P0 婴儿期至 P7 话题连续性的完整阶段流程，逐阶段说明目的、做法、出口判据与结果，并解释每一步在整体论证中的位置——即它解决了什么问题、又暴露了什么新问题。

全流程的主线可概括为：**先让一个个体在没有语言的状态下稳定发育（P0 – P1），再给它一套只能检索、不能生成的内化语言（P2.5 失败 → P2.6 重做），随后用一系列干预实验检验这套内言语到底承不承重（P2.7 的 E1 – E4、E6），发现它是"只读"的，于是从两条路去补——补行动环（P4/P4b/P4c）与补回流通路（R 系列），两条路都未走通，最后转向"换环境"（P6 语料扩容 → P6B → P7）。**

文档末章给出研究叙事的设计：如何把时间顺序的流程重排为论文的论证顺序，哪些阶段进正文、哪些进附录，以及目前还缺哪一块。

1 总体设计

1.1 研究问题与总路线

本项目不回答"系统是否具有意识"。它回答的是：**一个无语言基线、持续发育的个体，会自发长出哪些与意识相关的功能结构，哪些长不出来，以及每一条如何被机械检测。**全部结论限于功能结构层，不涉及主观体验。

与主流做法（在既有大模型上探测指标）相反，本项目构建一个从零出生的个体：单进程常驻、状态与仿真时钟跨重启续接、内部言语只能检索历史而不能生成。它的"本体"存在于历史状态目录而非程序代码，因此复制状态目录即得到一个共享历史、拥有独立未来的新个体——全部实验线均由此构造。

1.2 四条不可让渡的纪律

1. **念头只检索、不生成。**认知回路中不含生成模型。"零幻觉"因此是结构性质，不是提示约束。此纪律由 P2.5 的失败直接导出（见 § 2.4）。
2. **零提示词、零方向引导。**不施加任何"应当说什么"的提示。脚本若存在，只允许属于*环境*（照护者行为），不得进入候选体内部。
3. **预注册与如实报阴。**假设、度量、判定阈值在采集数据之前冻结，事后不得修改；阴性结果与代价同等详细记录。
4. **只谈功能结构。**判据必须绑定可测度量，或明确标注"机制不存在"。

1.3 阶段划分的依据

阶段（P 序列）按"**要补的那一块能力**"划分，而不是按时间或功能模块划分。每个阶段回答一个独立问题，并在结束时给出一个可判定的出口（出口判据或预注册假设）。实验（E / R / S / C 序列）则是在某阶段内部或跨阶段执行的**单变量干预**，各自有独立的预注册文件。

> 名称歧义提示
>
> P0 文档（README）里规划的"P1：时间知觉探针（E1/E2）"与 2026-10-05 起实际执行的 `prereg_E1E2.json`（语言剥夺 + 事件风暴）**编号相同但内容不同**。前者是早期规划，探针代码保留在 `probes.py`；后者是语言层落地后的干预实验。本文档一律以后者为准，并在提及早期规划时明确标注。

2 阶段全流程

P0 婴儿期（无语言层）

起点

目的	在引入语言之前，先让个体有一个可持续运行、可被观测的"身体与世界"。这是全部后续阶段的地基——如果没有稳定的背景态，后面任何语言层观察都无法归因。
做法	① **背景层**：8 个中性状态变量 s1 – s8 的常微分方程演化（tick 50 ms）。 ② **睡眠**：双过程模型（昼夜驱动 + 睡眠压力），入睡与醒来**由动力学决定，不是时刻表**。 ③ **能量身体**：每日预算，被动消耗随唤醒上升，探索扣费，耗尽进低功率模式。 ④ **事件预测器**：在线学习事件出现的小时分布，惊奇定义为 $-\log_2 p$。 ⑤ **归因回路**：把状态变化分为 self（内生探索）与 other（外部事件），滚动 self_ratio 作为"能动感"的可测代理。 ⑥ **阶段门控**：状态机硬门控，判据不过不晋升。
出口	事件预测器惊奇收敛：窗口均值稳定 < 3.5 bit 且前后窗口差 < 0.05；最短 3 天，14 天未收敛则强制结束并如实记录"未收敛"。
结果	通过 语言层自 P2.6 起接入；P0 的背景层与身体约束此后一直是全部实验的公共基底。
留下的	**模式 B 声明**：背景层是外挂数值引擎，不是模型内部隐状态。因此一切"持续自我"的结论都必须附带此限定——这条限制此后贯穿整个项目，也成为判据 D1 的关键限制。

P1 记忆系统 + 睡眠固化 + 时间知觉探针

规划

目的	在语言之前，先建立"记忆"与"时间感"两件事，为后来的语言记忆（听到的短语必须与当时状态绑定）准备存储与索引机制。
做法	记忆模块（`memory.py`、`episodic.jsonl`）、睡眠期固化、以及时间知觉探针（`probes.py`，记录 `e1_accuracy`）。
结果	已实装 探针代码与记忆模块保留至今，但该阶段的编号 E1/E2 名称后来被语言层实验复用（见 §1.3）。
留下的	记忆模块成为 P2.6 语言记忆（`linguistic_memory.json`）的结构基础：短语与状态快照的绑定存储正是"记忆条目"的一种扩展。

P2 语言层（初版）与镜像测试

规划

目的	给个体接上语言，并设置"镜像期"作为从"读取世界"到"有自我表征"的发育阶段门。
做法	计划以本地小语言模型（qwen2.5:3b via Ollama）生成内言语，事件驱动、最小间隔 60 秒；镜像测试作为通过判据。
结果	被否决 该路线在 P2.5 阶段被判定为不可接受（见下），语言层整体重做为 P2.6。
留下的	"镜像期"作为阶段门的机制被保留并沿用（`stages.py`），成为后来判据 D2 的判定时点：**自我模型首次形成即通过**。

P2.5 生成—共振方案（作废）

2026-10-04

目的	用语言模型生成"内部言语"，再让生成结果与状态产生共振，试图得到更丰富的内心活动。
做法	由语言模型生成内言语片段，通过提示词约束其"碎片化"与情绪色彩。
结果	否决 用户判定其不成立，理由有两条：**① 提示词强制碎片化本身就是表演；② 语言模型输出的"烦躁感"一类表述是幻觉，不是系统的状态**——系统当时并无烦躁。
留下的	这是本项目最重要的一次转折。它导出了两条铁律：**念头不生成只检索**，以及**零幻觉必须是结构保证**。旧数据已归档至 `evolution_history/p25_legacy_language/`，以保证正式线数据纯净。

P2.6 内化语言层（重做）

2026-10-04 晚

目的	在不生成的前提下给个体一套语言能力。理论依据是 Vygotsky 的内化路线：**先被称呼，之后才学会自称**；外部语言经由互动内化为内部语言。
做法	① 照护者语料（高频重复短语，**属环境属性**）被听到时，与当时的状态向量绑定存储。 ② **复述（echo）**：生命早期按一定概率复述刚听到的短语，概率随经验天数衰减。实现上每句只掷一次骰子（早期逐 tick 重掷导致复述率恒为 1，属已修缺陷）。 ③ **检索**：由当前状态检索记忆，得分 = 状态相似度 × 新近度 × 频率增益；胜出者成为该 tick 的"念头"。 ④ **念头回流背景态**，并供下游（目标、自我模型）读取。
结果	成功 语言层上线并稳定运行；首个**自然涌现**的目标出现："真乖"（7 日内 60 次自发激活，占 33.5%）。
教训	首次暴露出工程量的真实来源：语言层相关问题往往不来自算法，而来**自接线与默认值**——echo 去重、目标涌现的分母口径、睡眠期 result 残留，三项都属此类，且每一项都会静默污染数据。

P2.7 干预实验 E1 – E4（语言层上线后的第一批因果检验）

2026-10-05

目的	语言层刚上线，先做一组"从外部改条件、看内部如何变"的干预，检验语言层与自我模型是**被输入驱动的，还是内生的**。
E1 剥夺	照护者全静默 10 仿真日。预注册预测"检索速率衰减到基线 60% 以下"。 阴性 实测**不衰减**（末 3 日 29.3 次/日，基线 28.8 次/日）。解释：新近度衰减后竞争回落至频率主干，内言语**永久自持**。同时暴露架构缺口——**系统缺少遗忘与磨蚀机制**。
E2 事件风暴	事件率提升 10 倍，持续 5 仿真日。 混合 惊奇只升 0.24 bit，且末段 3.59 低于基线 3.91 → **预测器只对结构性违反敏感，对数量增多不敏感**。但语境绑定短语的检索占比从 16.5% 升至 35.5%，是全项目**最清晰的因果证据**。
E3 应答式照护	把照护者从随机改为一套应答规则（醒来即问候、紧张即安抚、无聊即召唤、注意焦点即自我指向），言语输入量翻倍。脚本属环境侧，候选体内部零改动。 阴性 自我模型新增 0 个版本；自我指向检索反降至先验的 0.15 倍。**结论：语量与时机不是杠杆，绑定质量（短语与状态的共现结构）才是。**
E4 发声与能动归因	给"肌肉"不给目标：① **发声**——生理门控（唤醒 × 片段激活强度），内容只能是该 tick 检索胜出的短语（保持零生成），消耗能量；② **能动归因**——学习"我的发声 → 照护者言语"的共变，功效超阈值即归因为 self（传出副本思路）。 部分通过 共变比 C = 8.2，产生 206 条归因（峰值占比 26%）；消退期移除 68% → 归因是**习得的**而非硬编码，但消退不彻底。 **非预期发现**：它最常发出的是自己被安抚时听到的短语（乖 / 嘘 / 睡觉觉）——内容不由实验者选择。
留下的	E1/E2/E3 三项阴性合起来指向同一个结论：**输入侧干预无法推动自我模型生长，其生长具有内生性**。这直接决定了后续路线——不再试图"喂"它，转而去查内部结构（E6、R 系列）。

P3 对话机制（把自然语言变成可投递输入）

2026-10-05 下午

目的	让真实的人（而非模拟器）能与个体说话，同时不破坏零生成与自发纪律。
做法	四个组件：① **语言通道**——以文件投递的 `say_*.txt` 入库，带状态绑定；② **零 LLM 发声**——输出仍只能是检索胜出的念头；③ **照护者台**（`talk.py`）——实时显示念头与状态；④ **试点线**——从加速线 fork 出的独立个体，1× 实时，照护者是真实用户。
结果	运行中 试点个体（day 434 fork）与加速线成为"共享历史、不同未来"的两个个体。观测要点：回应的低频率（念头节律约 41 分钟/条，出声每晚 1 – 2 次）。
留下的	P3 暴露了一个当时未解的问题：**对话不只是"轮流说话"**。当前照护者是逐句独立采样，句与句之间没有依赖——这让对话退化为乒乓。该问题在 P7 才被正面处理（见 § 2.14）。

E6 因果中介验证（移植大模型"J 空间"的金标准）

2026-10-05 17:40

目的	内言语（检索胜者 → 回流 → 目标 / 自我模型）从未被检验过因果分量。它可能是承重结构，也可能只是一份漂亮的日志（**副现象**）。这决定论文里敢写多强。
做法	移植"消融 + 替换"协议：**E6a 消融**——切断"念头 → 背景态"回流通道，观察 30 日；**E6b 替换**——以指定短语顶替检索胜出者 60 次。
结果	判决性 E6a：四项指标全部 < 5%（阴性带）。E6b：目标即时涌现（60 次恰为滚动窗口 300 的 20%，即阈值）。 **合并结论：下游读得到念头，念头推不动状态——工作空间是"只读"的。**
留下的	"只读"若成立，则项目的核心目标（把只读打通成双向）必须另行攻。由此直接分岔出两条线：**补行动环（P4 系列）**与**补回流通路（R 系列）**。此外 E6a 存在一个致命缺口——回流耦合是**刻意做小的**（±0.02），"切断一条刻意做小的通道 → 无影响"是预期而非发现。R 系列即为补此缺口而生。

P4 行动环（给个体施加影响世界的能力）

2026-10-05 20:20

目的	E6 揭出的是"单向工作空间"：能读到自己的念头，却推不动任何东西。P4 要给个体一个能被自己行动改变的世界，看"我 → 世界 → 我"这条环路能否合上。
依据	两条外部依据：① 相关理论把"自我"定义为"诱发行动、又被行动修改"的那一小撮节点，本项目当时只满足后半；② 对语言模型工作空间的学界评论指出，其与人类心智的关键差异之一是**缺少身体与持久的自传体记忆**——本项目已有后者，P4 补前者。
做法	一维环形世界，三个源强度独立振荡；三个动作原语（前进 / 后退 / 停留），动作选择由状态绑定表竞争产生，移动消耗能量。
结果	部分 闭环合上（动作分布强非均匀）、结构成立，但**追踪无学习曲线、能动无法评估**。
暴露缺陷	两处设计缺陷：**① 学习信号是纯空间梯度，不含时间**（同一 tick 内两位置场强之差）；**② 世界自身的变化从未被采样**，系统从未被告知"哪些变化是自己造成的"。→ 引出 P4b。

P4b 时间化行动环（修 P4 的两处缺陷）

2026-10-05 21:20

目的	把学习信号**时间化**，并**显式分离**"我造成的"与"世界自己变的"。
做法	动作结果跨一个区间测量（同时包含世界漂移与动作效应）；用"停留"试次估计世界漂移分量，其与总变化之差即**自因分量**，只有自因分量用于更新动作值。
结果	弱阳性 自因分量可靠非零（+0.00892，4490 次移动），但**小于世界自身的波动**（噪声底 0.01559，信噪比 0.57）；学习曲线出现（+0.031）。**即：它确实能区分"我造成的"与"世界自己变的"，但效应淹没在噪声里。**
重要教训	判定在 70% 窗口给出。信噪比随样本增加从 1.5× 降到 0.57×——**早期估计来自四分之一数据，未站住**。教训：任何"通路/效应"结论必须等窗口走完，或明确标注覆盖率。此外该实验的判定在 70% 窗口给出（完整 30 日未跑完），已如实记录。
暴露缺陷	根因不是机制缺失，而是**设计混淆**：它唯一的动作是移动，而移动的后果与"世界本来就在那里"完全纠缠。→ 引出 P4c。

P4c 痕迹实验（让行动留下不可能被误认的后果）

2026-10-05 23:05

目的	给行动一个**不与世界混淆**的后果，从而把自因信号从噪声中提出来。
做法	允许它在世界里**留下痕迹**——世界上没有任何自然过程会写字，因此痕迹的存在只可能来自它的行动。
结果	已预注册 三条件：痕迹可归因、痕迹可累积、形成留痕策略。（该线执行记录见 `experiments/p4c/`。）
位置	这是对"行动闭环"能走多远的一次压力测试：如果连一个专门设计过、绝无歧义的后果都不能产生稳定学习，那么瓶颈就不在"世界中缺乏可归因的后果"，而在更上游。

P5 痛 / 乐（把"匮乏"与"满足"显式化为内部状态）

2026-10-06

目的	这条路线一直有"好 / 坏"的物理地基（能量预算、睡眠压力、紧张、无聊），但从未把"我正难受""我正舒坦"**显式化为带惯性的内部状态**。痛 / 乐是"内在好恶"的最小实现，也是从"被世界影响"走向"因难受而改行为"的第一步。
关键约束	**两者必须内生于自身状态变量，绝不能是外部发下的 reward**——否则系统会朝"让打分者满意"演化，正是 P2.5 已经栽过的表演坑。
假设	H1 通道可测 · H2 承重 · H3 预期（提前趋避） · H4 不适驱动自我指向 · H5 不适进入自我模型 · H6 锚定（探索性）。
结果	已预注册 该阶段为"内在动机"的准备，与 P4 的行动环配套：P4 给了"能不能影响世界"，P5 给"为什么要影响世界"。

R　回流耦合阶梯（判定"只读"是真无反馈，还是弱通道伪影）

2026-10-05 23:45

目的　E6α 的致命缺口：回流耦合是**刻意做小的**（±0.02）。不报耦合强度，"只读"就无法证伪——"耦合强 + 切断无效"与"耦合弱 + 切断无效"，结论分量差一个数量级。本批把**耦合强度本身做成自变量**。

结果　阴性　阶梯各档均无分量。但审计随即发现通道两端都**不活跃**（通道未开火 / 写入的目标变量无人消费），据此该预注册**在采集数据之前**作废并重写为 R2——这是一个程序上合规、且已载入论文的修订。

R2　"只读"的两因子判定（四级修正阶梯）

2026-10-06

目的　把"只读"拆成两个可分别检验的因子：**门是否打开、目标变量是否有人消费**。

做法与结果　**第 1 级**（确认通道未开）：实验臂与零参照**逐条位相同**（856/856，集合重叠 1.000）→ 复现 E6α。

第 2 级（开门，但写到无人消费的变量）：通道确实开火（写入约 157 万次），念头流**仍与零参照逐条位相同** → 写入无消费者即无影响。

第 3 级（换到确被检索消费的变量）：**立即分岔** → 证明**接线是通的**，不是实现缺陷。

第 4 级（把耦合提到原值的 15 倍，约 0.91 个标准差）：四项指标**仍全部 < 10%，且对剂量不单调**。

结论　只读（结构性质）　门开着、目标有人消费、剂量加大，念头仍不承重。这不是接线事故，而是"念头流对自身状态无因果分量"的结构性质。

边界：最高档耦合 0.91σ，从未超过噪声底；写入量均值近零，故排除的是"平衡扰动不承重"，**单符号写入未测**；六臂共用同一父本，**未采样种子方差**。

R2c / R2x　两条后续分支：换消费者 / 推到噪声之上

2026-10-07

R2c　**最小消费者实验**：把写回值接到"行为侧"的读取者，判定"通而轻"是否只是消费者选错了。

判否　该设计本身被识别为**工程路线**（消费者是实验者挑的参数），与项目的自发纪律冲突——这个反思直接导致了 R3 的设计转向。

R2x　**边界探针**：把耦合推到 > 1σ，判定"只读"在噪声之上的边界。预注册中明确写"不以此追求双向"。

R3　自发双向（成句生成 × 预期—比较—修正 × 后果驱动耦合）

2026-10-07

目的　R2c 的教训是"消费者是实验者挑的"。R3 因此**不注入任何消费者**，改为补三处结构缺口，让"念头 → 状态 → 未来念头"这条回路**自己长出来**——能否长出来不作保证。

做法　成句生成 × 预期—比较—修正 × 后果驱动耦合，六臂对照。

结果　阴性　回路未自发形成。→ 引出 R4。

R4 后果窗口积分 × 重标度（承接 R3 阴性）

2026-10-08

目的	针对 R3 的诊断，修正后果耦合的两处实现：把后果改为窗口积分并做重标度。
结果	阴性 结构成立、分离成立，但符号方向不成立。→ 引出 R5 的路线更换。

R5 激活式工作集（扩散激活 × 容量受限检索 × 复述回写）

2026-10-08

目的	按人类工作记忆的对应物重构：用一个**带扩散的激活场**承载"当前正在想什么"，检索只在激活最高的少数短语内进行，胜出者再写回激活场，构成闭环。
做法	六臂对照（关闭 / 完整 / 打乱联想 / 只读不写 / 不衰减 / 扩大工作集），主判据为"内容特定性"——相邻念头是否落在真实联想的后继之中，阈值 0.07。
结果	阴性 full 与 shuf 的差仅 0.009，远低于阈值。诊断：**输入贫乏**（照护者语料仅 51 – 55 个型，联想行过于弥散）。R5 自己点名："下一步杠杆是环境多样性而非架构"。→ 直接引出 P6。

P6 语料扩容（55 条内置语料 → 8.3 万条真实照护者语言）

2026-10-06

目的	照护者语料一直是硬编码的 55 条短句，而真实儿童语言是 Zipf 分布的：少数句子极高频、长尾极大。本阶段检验"更大的真实语料"这一杠杆。
做法	换成从 CHILDES 中文子库抽出的 83,302 个真实成人短语（单池 Zipf 采样）。**注意这不是"投喂教材"**——语料是环境属性，说话时机仍由候选体状态驱动，语料本身不含任何标注或课程安排。两臂（内置 / CHILDES）各 60 仿真日。
假设	H1 结构保持 · H2 生长速率 · H3 绑定强度。
结果	完成 两臂均跑到 day 315，CHILDES 臂成功载入 83,302 型并正常出语言。

P6B 双向重探（在扩容模型上重跑 R5 六臂）

2026-10-09

目的	R5 把失败归因于输入贫乏。本阶段**保持 R5 的架构、六臂设计、判据与阈值完全不动**，只把基底换成已扩容的模型。唯一要回答的问题：内容特定性是随输入多样性涌现，还是该架构在该表征下根本不可行。
结果	阴性 full 与 shuf 的差为 **0.034**，仍低于 0.07 阈值 → H6b 未通过。 **但有两项不被门槛掩盖的事实**：① 分离度比 R5 的 0.009 **扩大了约 3.8 倍**，方向正确、幅度不足；② **多样性坍缩**——开着工作空间的臂，检索到的不同短语数从对照的 403 个掉到 10 个，念头高度重复。
新线索	**扩大工作集（k 从 6 提到 20）时命中率反而最高**（0.066，且保住了更多多样性）。这提示下一根杠杆可能在工作集容量，而不在语料规模。
意义	这是把 R5 自己指认的杠杆真正下拉一次的结果：**路没走通，但知道了下一根杠杆在哪。**

P7 话题连续性（把照护者从"每次独立抽一句"改成"围绕一个话题连说几句"）

2026-10-06

目的

当前照护者与人类最大的一处失真**不是语料量，而是话语之间的结构**。人类照护者围绕一个话题连着说三五句，而采样器是逐句独立抽取——边际分布对了，句间结构全丢了。而词义来自对话中的共现，不在孤立句子里。本阶段只改"句与句之间的依赖"这一个变量。

做法

三臂：**flat**（现状，逐句独立）· **burst**（先抽一个"会话"，再从该会话里连抽 3 – 5 句）· **burst_shuffled**（回合长度与语率与 burst 完全相同，但回合内改为全局独立抽取）。第三臂是关键：它把"爆发结构"与"话题内容"分离开。

方法来源

设计前先做过一次可行性探查，结论直接决定了方法：在 3752 份转写上统计相邻两条的转移，核心 5000 高频短语中**只有约 1000 条存在可重复的后继**（转移对仅 2325 个）——**一阶马尔可夫链在该语料上太稀疏**。因此改用"会话"（一份转写 = 一次游戏或一次读绘本，本身就是时间连续单元）作为话题单元。**这是从数据得出的选择，不是先验设定。**

修正案

原设计的操纵检查指标（KL 散度 < 0.05）被发现有**物理上不可达**的缺陷：在 8.3 万型、12 万次抽样的条件下 KL 被尾部噪声主导——连"内容与 flat 同源、理论边际完全相同"的对照臂实测也有 0.138。据此在**采集数据之前**把指标改为"前 K 型的质量相对偏差"，并补记估计器噪声底。

假设

H1 绑定强度不预设方向（变强 / 变弱 / 持平三种都有真实理由，实测判定，三种结果都是可报告的发现）；**H2 多样性的代价**（话题连续可能牺牲多样性，必须如实报告）；**H3 自我模型为探索性**（既有证据指向自我模型对输入侧操纵不敏感，若仍无差异，那是对既有结论的又一次一致复现，不是失败）。

已知混淆

语料混合了日常对话与绘本朗读两种语域，绘本天然具有长程话题连续性，可能主导效果。缓解措施：记录每臂抽到的语域构成，若效果完全由绘本会话驱动，须如实分列报告。

S1 / S2 复现与分离（检验核心主张的稳健性）

2026-10-05 23:45

S1 复现

审计发现论文的核心主张（自我模型从空演化）只有单条线支持，无种子复现、无方差、无区间。

通过 三种独立随机种子在 60 日内长出**同一套片段集合**，仅次序不同。

S2 分离

修复自我模型时**同时改了两个变量**（加入第一人称语料 + 修门控），因此无法归因。二者已拆成独立配置开关，做 2×2 分离。

修正了原预测 四个条件均能形成自我模型，但**第一人称片段只出现在"听到第一人称语料"的条件下**——即**语料才是必要条件，门控不是**，与项目原本的预测相反。该结果如实报告。

C1 / C1b 第一人称语料对照（检验"你 → 我"倒转是否只是设计痕迹）

2026-10-05 17:40

问题

结晶线出现了 79% 的纯第一人称检索、且自我模型含"我在这儿"。但**第一人称语料是设计者自己放进去的**：6 条"我"类短语被刻意绑定在高紧张与高注意时刻——而新生儿长期处于高紧张态，因此会造成高频共现。该结论写入论文前必须排除设计痕迹。

C1 → C1b

C1 把"我"类短语改绑平静态，结果**暴露率是主线的 7.96 倍**（平静态占比高），结果被暴露率混淆。据此启动 C1b 修正线：**校准两通道速率，使暴露率与主线同期持平**，作为主判据实例；原 C1 降级为"高暴露条件"的观察。

结果

通过 频率匹配后仍出现 5 个第一人称自我模型片段（对照组 2 个），第一人称检索占比 4.2%。

FIX-1 self_directed 门控缺陷修复 2026-10-05

缺陷	语言层只认"你"，而自我模型词表含"我"全家——**设计意图与接线断裂**：纯第一人称念头（"我在这儿"已被检索 21 次）永远进不了自我模型。
修复	门控扩展为同时接受"你"与"我"，并对全部实例的语言记忆做幂等迁移（结晶线翻正 280 条，含用户对惊醒副本说过的话）。单测 9/9 通过。
意义	**"你 → 我"倒转的通道自此才在结构上打开**，观察期从修复时刻起算。修复后 5 个仿真日内即出现纯第一人称片段（无"你"），命中预注册的 P1 预测。

3 实验矩阵一览

下表按序列汇总全部实验，含各自在整体论证中的角色。

表 1　E 序列（干预实验）

编号	问题	操纵	结果
E1	内言语是否依赖外部输入维持?	照护者静默 10 日	阴性 不衰减 → 永久自持，暴露缺遗忘机制
E2	刺激量与语境绑定分别起什么作用?	事件率 ×10，5 日	混合 惊奇不升反降；但语境绑定 16.5%→35.5%
E3	应答式照护能否加速自我模型?	照护者改为应答式，输入翻倍	阴性 0 新版本，自我指向反降
E4	发声与能动归因能否习得、能否消退?	给发声机制 + 共变学习	部分通过 C=8.2，206 条归因，消退移除 68%
E6	内言语承重，还是副现象?	消融（切断回流）+ 替换（顶替胜出者）	判决性 下游读得到，推不动状态 → 只读

表 2　R 序列（回流通路/工作空间阶梯）

编号	问题	操纵	结果
R	耦合强度是否影响结论?	耦合强度做自变量	作废 审计发现通道两端均不活跃，数据前重写为 R2
R2	只读来自门不开，还是目标无人消费?	四级修正阶梯	只读钉死 门开/被消费/0.91σ 仍不承重
R2c	是否只是消费者选错了?	把写回接到行为侧读取者	判否 并自我识别为"工程路线"，与自发纪律冲突
R2x	噪声之上的边界在哪?	耦合推到 >1σ	边界探针 明示不追求双向
R3	回路能否自发长出来?	不注入消费者，只补三处结构缺口	阴性 回路未自发形成
R4	改为后果窗口积分能否修正?	窗口积分 × 重标度	阴性 结构成立但符号方向不成立
R5	激活式工作集能否产生内容特定性?	六臂（关闭/完整/打乱/只读/不衰减/大工作集）	阴性 差 0.009，归因于输入贫乏

表 3　S / C / FIX 序列（稳健性、对照与修复）

编号	问题	结果
S1	自我模型能否稳定从空形成?	通过 三种子 60 日内同一片段集合，次序不同
S2	起作用的是语料还是门控?	修正原预测 语料才是必要条件
C1	"你→我"倒转是否只是语料设计痕迹?	降级 暴露率被混淆（7.96 倍），改为高暴露观察条件
C1b	暴露率匹配后是否仍有倒转?	通过 5 个第一人称片段，1P 检索 4.2%
FIX-1	纯第一人称念头能否进自我模型?	修复 门控扩为接受"你"与"我"，通道结构性打开
P6	换成 8.3 万型真实语料会怎样?	完成 两臂至 day 315，扩容成功
P6B	富输入下内容特定性能否涌现?	阴性 0.034 < 0.07，但比 R5 放大 3.8 倍；k=20 最高

4 关键转折点

全流程中有五处决定此后路线走向的事件。它们比任何单项结果都更能说明这条路线是怎么走的。

序	事件	为什么是转折
1	P2.5 被否决	确立"不生成"与"零幻觉是结构保证"两条铁律。此后所有机制设计都受此约束，也由此得到全项目最强的可证伪性。
2	E1/E3 阴性	证明输入侧干预无效 → 放弃"喂语料"的路线，转向检查内部结构。这是从"发展心理学式干预"转向"可解释性式因果检验"的分水岭。
3	E6 判决"只读"	确立了本项目的核心阴性结论，并把目标从"多点观察"收束为"打通这条通路"。此后 P4 与 R 两条线都是为它服务。
4	R2 四级阶梯 + R2c 的自我否定	R2 把"只读"从可疑变为结构性；R2c 则识别出"自己挑消费者"属工程路线，与自发纪律冲突——由此产生 R3"让回路自己长出来"的设计转向。
5	P6B 阴性但效应放大 3.8 倍	把 R5 的归因（输入贫乏）检验到底：环境杠杆确实有效但不足以跨过阈值。同时意外发现 k 值（工作集容量）可能是更强的杠杆，为下一步指明方向。

5 从流程到论文：叙事设计

阶段流程是**时间顺序**，而论文必须按**论证顺序**组织。两者差别很大——如果按时间写，读者会先读到一堆失败，不明白为什么值得失败这么多次。本节给出重排方案。

5.1 主线叙事的选择

推荐把论文的论点组织为一条"三次逼近"的线索，而不是"我们做了很多实验"：

1. **第一次逼近（发育侧，正面结果）**：在严格约束下，个体确实长出了可复现的自我表征。
   证据：P2.6 语言层、FIX-1、S1 复现、C1b 对照、D2 判据。
2. **第二次逼近（整合侧，阴性结论）**：但这套内部言语对它自己的状态没有因果分量——工作空间只读。
   证据：E6（消融 + 替换）、R2（四级阶梯）、判据 D6。
3. **第三次逼近（尝试打通，全部失败）**：从补行动环与补回流通路两条独立路径尝试打通，均未成功；换环境（语料扩容）能把效应放大但仍不足。
   证据：P4/P4b/P4c、R3/R4/R5、P6/P6B。

这条线索的好处是：**阴性结果成为论证的推进器而非终点**。每一次失败都精确缩小了"问题出在哪"的范围，最终落到一条清晰的结论上——本系统具备自我表征与自因区分，但不具备对自身的因果影响。

5.2 章节映射

表 4　阶段 / 实验 → 论文章节的映射

论文章节	来自哪些阶段与实验	该章要论证什么
引言	—（外部文献：指标理论、语言模型工作空间、内化言语、预测加工）	为什么选"从零发育的个体"而非"探测既有模型"
方法：系统	P0（状态与身体）、P1（记忆）、P2.6（语言层）、P3（对话通道）	系统是什么，以及零生成如何成为结构保证
方法：判据	判据 D1 – D6（跨全部阶段累积）	把"意识"拆成可机械检测的功能结构清单
结果一：发育	P2.6、FIX-1、S1、S2、C1b、E4	自我表征是长出来的：可复现、依赖语料结构、能动归因可习得
结果二：只读	E6、R2、R2c、R2x	工作空间只读，且这是结构性质而非实现缺陷
结果三：打通尝试	P4、P4b、P4c、R3、R4、R5	两条独立路径均未走通，以及各自失败的具体原因
结果四：换环境	P6、P6B	环境杠杆有效但不足；k 值线索
讨论：效度威胁	E1/E2/E3 阴性、R2 边界、P4b 的窗口覆盖率教训、P7 的语域混淆	逐条列出内部/外部/构念/统计威胁
附录	P7 话题连续性（进行中）、P4c、P5、R2x	在研与前瞻性工作，不影响主结论

5.3 叙事上要避免的三件事

1. **不要按时间顺序写**。R 序列（R → R2 → R2c → R2x → R3 → R4 → R5）在时间上连续七次迭代，但论文里应压缩为"一个结论 + 四级加固 + 两条分支"，迭代过程进附录。
2. **不要把"路径验证"写成"涌现"**。E6b 以人为替换使目标出现，证明的是"通路存在"，不是"它自己会生成该目标"。两者必须分述。
3. **不要让正面结果独占篇幅**。本项目的特异性恰在于阴性结果的质量。六项主要预测被证伪这件事，是方法论价值的主要来源，应给足篇幅。

5.4 目前还缺的一块

> **待补**
>
> 论文的"结果三（打通尝试）"目前只有阴性。若要让它成为完整的一节，需要至少一处**机制层面的解释性答案**：为什么"扩散激活 × 容量受限检索 × 复述回写"这套结构在富输入下仍不产生内容特定性？P6B 的 **k 值线索**（工作集从 6 扩到 20 时命中率最高且保住多样性）是目前唯一指向答案的证据，建议作为下一阶段（P8 候选）的首要变量：**把工作集容量作为主自变量，在扩容模型上重跑**。

数据来源说明。本文档由仓库内以下文件还原：`README.md`（P0 范围与出口判据）、`experiments/prereg_*.json`（33 份预注册，含各阶段的目的、设计、假设与阈值）、`experiments/results_*.json`、`experiments/phase_log.txt`、`experiments/exp_line_manifest.json`（结晶线经验结晶清单）、`experiments/p4b/results_P4b.json` 与 `experiments/prereg_P7_topic.json`。所有数值与结论均取自上述文件，未作推断性补写；凡属在研或未出结果者，均标注为"运行中/已预注册"。