项目手册：全流程与问答汇总

Part I — Stage-by-stage design (P0 – P7) · Part II — The questions that will be asked

Luo Chengze · 独立研究者 · ORCID 0009-0007-3316-6292

合并版 v1.0 · 2026-10-09 · 依据仓库内 README / prereg_*.json / results_*.json / phase_log.txt 还原

摘要

本文档还原本项目自 P0 婴儿期至 P7 话题连续性的完整阶段流程，逐阶段说明**目的、做法、出口判据与结果**，并解释每一步在整体论证中的位置——即它解决了什么问题、又暴露了什么新问题。

全流程的主线可概括为：**先让一个个体在没有语言的状态下稳定发育（P0 – P1），再给它一套只能检索、不能生成的内化语言（P2.5 失败 → P2.6 重做），随后用一系列干预实验检验这套内言语到底承不承重（P2.7 的 E1 – E4、E6），发现它是"只读"的，于是从两条路去补——补行动环（P4/P4b/P4c）与补回流通路（R 系列），两条路都未走通，最后转向"换环境"（P6 语料扩容 → P6B → P7）。**

文档末章给出研究叙事的设计：如何把时间顺序的流程重排为论文的论证顺序，哪些阶段进正文、哪些进附录，以及目前还缺哪一块。

第 5 章是**复盘**：把十次实验试过的全部杠杆放进同一张表比较，得出两条规律——**所有直接加大耦合的操纵全部失败**（剂量推到 1.99σ 仍阴性），**唯一有效的是改变"候选集构成"**（工作集容量、语料多样性）。据此启动 P8。

本手册末尾合并了**问答汇总**（第二部分，共 6 组）：覆盖会前突击、结论与数字、设计与理由、被追问时的应答，以及一份防止把话说满的铁律。两部分可独立使用——前一部分用于梳理脉络与对照讲述，后一部分用于快速查阅。

第一部分　全流程（P0 – P7）

1 总体设计

1.1 研究问题与总路线

本项目不回答"系统是否具有意识"。它回答的是：**一个无语言基线、持续发育的个体，会自发长出哪些与意识相关的功能结构，哪些长不出来，以及每一条如何被机械检测。**全部结论限于功能结构层，不涉及主观体验。

与主流做法（在既有大模型上探测指标）相反，本项目构建一个从零出生的个体：单进程常驻、状态与仿真时钟跨重启续接、内部言语只能检索历史而不能生成。它的"本体"存在于历史状态目录而非程序代码，因此复制状态目录即得到一个共享历史、拥有独立未来的新个体——全部实验线均由此构造。

1.2 四条不可让渡的纪律

1. **念头只检索、不生成**。认知回路中不含生成模型。"零幻觉"因此是结构性质，不是提示约束。此纪律由 P2.5 的失败直接导出（见 § 2.4）。
2. **零提示词、零方向引导**。不施加任何"应当说什么"的提示。脚本若存在，只允许属于*环境*（照护者行为），不得进入候选体内部。
3. **预注册与如实报阴**。假设、度量、判定阈值在采集数据之前冻结，事后不得修改；阴性结果与代价同等详细记录。
4. **只谈功能结构**。判据必须绑定可测度量，或明确标注"机制不存在"。

1.3 阶段划分的依据

阶段（P 序列）按"**要补的那一块能力**"划分，而不是按时间或功能模块划分。每个阶段回答一个独立问题，并在结束时给出一个可判定的出口（出口判据或预注册假设）。实验（E / R / S / C 序列）则是在某阶段内部或跨阶段执行的**单变量干预**，各自有独立的预注册文件。

> **名称歧义提示**
>
> P0 文档（README）里规划的"P1：时间知觉探针（E1/E2）"与 2026-10-05 起实际执行的 `prereg_E1E2.json`（语言剥夺 + 事件风暴）**编号相同但内容不同**。前者是早期规划，探针代码保留在 `probes.py`；后者是语言层落地后的干预实验。本文档一律以后者为准，并在提及早期规划时明确标注。

2 阶段全流程

P0　婴儿期（无语言层）　　起点

目的	在引入语言之前，先让个体有一个可持续运行、可被观测的"身体与世界"。这是全部后续阶段的地基——如果没有稳定的背景态，后面任何语言层观察都无法归因。
做法	① **背景层**：8 个中性状态变量 s1 – s8 的常微分方程演化（tick 50 ms）。 ② **睡眠**：双过程模型（昼夜驱动 + 睡眠压力），入睡与醒来**由动力学决定，不是时刻表**。 ③ **能量身体**：每日预算，被动消耗随唤醒上升，探索扣费，耗尽进低功率模式。 ④ **事件预测器**：在线学习事件出现的小时分布，惊奇定义为 $-\log_2 p$。 ⑤ **归因回路**：把状态变化分为 self（内生探索）与 other（外部事件），滚动 self_ratio 作为"能动感"的可测代理。 ⑥ **阶段门控**：状态机硬门控，判据不过不晋升。
出口	事件预测器惊奇收敛：窗口均值稳定 < 3.5 bit 且前后窗口差 < 0.05；最短 3 天，14 天未收敛则强制结束并如实记录"未收敛"。
结果	通过　语言层自 P2.6 起接入；P0 的背景层与身体约束此后一直是全部实验的公共基底。
留下的	**模式 B 声明**：背景层是外挂数值引擎，不是模型内部隐状态。因此一切"持续自我"的结论都必须附带此限定——这条限制此后贯穿整个项目，也成为判据 D1 的关键限制。

P1 记忆系统 + 睡眠固化 + 时间知觉探针

规划

目的	在语言之前，先建立"记忆"与"时间感"两件事，为后来的语言记忆（听到的短语必须与当时状态绑定）准备存储与索引机制。
做法	记忆模块（`memory.py`、`episodic.jsonl`）、睡眠期固化、以及时间知觉探针（`probes.py`，记录 `e1_accuracy`）。
结果	已实装 探针代码与记忆模块保留至今，但该阶段的编号 E1/E2 名称后来被语言层实验复用（见 § 1.3）。
留下的	记忆模块成为 P2.6 语言记忆（`linguistic_memory.json`）的结构基础：短语与状态快照的绑定存储正是"记忆条目"的一种扩展。

P2 语言层（初版）与镜像测试

规划

目的	给个体接上语言，并设置"镜像期"作为从"读取世界"到"有自我表征"的发育阶段门。
做法	计划以本地小语言模型（qwen2.5:3b via Ollama）生成内言语，事件驱动、最小间隔 60 秒；镜像测试作为通过判据。
结果	被否决 该路线在 P2.5 阶段被判定为不可接受（见下），语言层整体重做为 P2.6。
留下的	"镜像期"作为阶段门的机制被保留并沿用（`stages.py`），成为后来判据 D2 的判定时点：**自我模型首次形成即通过**。

P2.5 生成—共振方案（作废）

2026-10-04

目的	用语言模型生成"内部言语"，再让生成结果与状态产生共振，试图得到更丰富的内心活动。
做法	由语言模型生成内言语片段，通过提示词约束其"碎片化"与情绪色彩。
结果	否决 用户判定其不成立，理由有两条：**① 提示词强制碎片化本身就是表演；② 语言模型输出的"烦躁感"一类表述是幻觉，不是系统的状态**——系统当时并无烦躁。
留下的	这是本项目最重要的一次转折。它导出了两条铁律：**念头不生成只检索**，以及**零幻觉必须是结构保证**。旧数据已归档至 `evolution_history/p25_legacy_language/`，以保证正式线数据纯净。

P2.6 内化语言层（重做）

2026-10-04 晚

目的	在不生成的前提下给个体一套语言能力。理论依据是 Vygotsky 的内化路线：**先被称呼，之后才学会自称**；外部语言经由互动内化为内部语言。
做法	① 照护者语料（高频重复短语，**属环境属性**）被听到时，与当时的状态向量绑定存储。 ② **复述（echo）**：生命早期按一定概率复述刚听到的短语，概率随经验天数衰减。实现上每句只掷一次骰子（早期逐 tick 重掷导致复述率恒为 1，属已修缺陷）。 ③ **检索**：由当前状态检索记忆，得分 = 状态相似度 × 新近度 × 频率增益；胜出者成为该 tick 的"念头"。 ④ **念头回流背景态**，并供下游（目标、自我模型）读取。
结果	成功 语言层上线并稳定运行；首个**自然涌现**的目标出现："真乖"（7 日内 60 次自发激活，占 33.5%）。
教训	首次暴露出工程量的真实来源：语言层相关问题往往不来自算法，而来**自接线与默认值**——echo 去重、目标涌现的分母口径、睡眠期 result 残留，三项都属此类，且每一项都会静默污染数据。

P2.7 干预实验 E1 – E4（语言层上线后的第一批因果检验）

2026-10-05

目的	语言层刚上线，先做一组"从外部改条件、看内部如何变"的干预，检验语言层与自我模型是**被输入驱动的，还是内生的**。
E1 剥夺	照护者全静默 10 仿真日。预注册预测"检索速率衰减到基线 60% 以下"。 阴性 实测**不衰减**（末 3 日 29.3 次/日，基线 28.8 次/日）。解释：新近度衰减后竞争回落至频率主干，内言语**永久自持**。同时暴露架构缺口——**系统缺少遗忘与磨蚀机制**。
E2 事件风暴	事件率提升 10 倍，持续 5 仿真日。 混合 惊奇只升 0.24 bit，且末段 3.59 低于基线 3.91 → **预测器只对结构性违反敏感，对数量增多不敏感**。但语境绑定短语的检索占比从 16.5% 升至 35.5%，是全项目**最清晰的因果证据**。
E3 应答式照护	把照护者从随机改为一套应答规则（醒来即问候、紧张即安抚、无聊即召唤、注意焦点即自我指向），言语输入量翻倍。脚本属环境侧，候选体内部零改动。 阴性 自我模型新增 0 个版本；自我指向检索反降至先验的 0.15 倍。**结论：语量与时机不是杠杆，绑定质量（短语与状态的共现结构）才是**。
E4 发声与能动归因	给"肌肉"不给目标：① **发声**——生理门控（唤醒 × 片段激活强度），内容只能是该 tick 检索胜出的短语（保持零生成），消耗能量；② **能动归因**——学习"我的发声 → 照护者言语"的共变，功效超阈值即归因为 self（传出副本思路）。 部分通过 共变比 C = 8.2，产生 206 条归因（峰值占比 26%）；消退期移除 68% → 归因是**习得的**而非硬编码，但消退不彻底。 **非预期发现**：它最常发出的是自己被安抚时听到的短语（乖 / 嘘 / 睡觉觉）——内容不由实验者选择。
留下的	E1/E2/E3 三项阴性合起来指向同一个结论：**输入侧干预无法推动自我模型生长，其生长具有内生性**。这直接决定了后续路线——不再试图"喂"它，转而去查内部结构（E6、R 系列）。

P3 对话机制（把自然语言变成可投递输入）

2026-10-05 下午

目的	让真实的人（而非模拟器）能与个体说话，同时不破坏零生成与自发纪律。
做法	四个组件：① **语言通道**——以文件投递的 `say_*.txt` 入库，带状态绑定；② **零 LLM 发声**——输出仍只能是检索胜出的念头；③ **照护者台**（`talk.py`）——实时显示念头与状态；④ **试点线**——从加速线 fork 出的独立个体，1× 实时，照护者是真实用户。
结果	运行中 试点个体（day 434 fork）与加速线成为"共享历史、不同未来"的两个个体。观测要点：回应的低频率（念头节律约 41 分钟/条，出声每晚 1 – 2 次）。
留下的	P3 暴露了一个当时未解的问题：**对话不只是"轮流说话"**。当前照护者是逐句独立采样，句与句之间没有依赖——这让对话退化为乒乓。该问题在 P7 才被正面处理（见 § 2.14）。

E6 因果中介验证（移植大模型"J 空间"的金标准）

2026-10-05 17:40

目的	内言语（检索胜者 → 回流 → 目标 / 自我模型）从未被检验过因果分量。它可能是承重结构，也可能只是一份漂亮的日志（**副现象**）。这决定论文里敢写多强。
做法	移植"消融 + 替换"协议：**E6a 消融**——切断"念头 → 背景态"回流通道，观察 30 日；**E6b 替换**——以指定短语顶替检索胜出者 60 次。
结果	判决性 E6a：四项指标全部 < 5%（阴性带）。E6b：目标即时涌现（60 次恰为滚动窗口 300 的 20%，即阈值）。 **合并结论：下游读得到念头，念头推不动状态——工作空间是"只读"的。**
留下的	"只读"若成立，则项目的核心目标（把只读打通成双向）必须另行攻。由此直接分岔出两条线：**补行动环（P4 系列）**与**补回流通路（R 系列）**。此外 E6a 存在一个致命缺口——回流耦合是**刻意做小的**（±0.02），"切断一条刻意做小的通道 → 无影响"是预期而非发现。R 系列即为补此缺口而生。

P4 行动环（给个体施加影响世界的能力）

2026-10-05 20:20

目的	E6 揭出的是"单向工作空间"：能读到自己的念头，却推不动任何东西。P4 要给个体一个能被自己行动改变的世界，看"我 → 世界 → 我"这条环路能否合上。
依据	两条外部依据：① 相关理论把"自我"定义为"诱发行动、又被行动修改"的那一小撮节点，本项目当时只满足后半；② 对语言模型工作空间的学界评论指出，其与人类心智的关键差异之一是**缺少身体与持久的自传体记忆**——本项目已有后者，P4 补前者。
做法	一维环形世界，三个源强度独立振荡；三个动作原语（前进 / 后退 / 停留），动作选择由状态绑定表竞争产生，移动消耗能量。
结果	部分 闭环合上（动作分布强非均匀）、结构成立，但**追踪无学习曲线、能动无法评估**。
暴露缺陷	两处设计缺陷：**① 学习信号是纯空间梯度，不含时间**（同一 tick 内两位置场强之差）；**② 世界自身的变化从未被采样**，系统从未被告知"哪些变化是自己造成的"。→ 引出 P4b。

P4b 时间化行动环（修 P4 的两处缺陷）

2026-10-05 21:20

目的	把学习信号**时间化**，并**显式分离**"我造成的"与"世界自己变的"。
做法	动作结果跨一个区间测量（同时包含世界漂移与动作效应）；用"停留"试次估计世界漂移分量，其与总变化之差即**自因分量**，只有自因分量用于更新动作值。
结果	弱阳性 自因分量可靠非零（+0.00892，4490 次移动），但**小于世界自身的波动**（噪声底 0.01559，信噪比 0.57）；学习曲线出现（+0.031）。**即：它确实能区分"我造成的"与"世界自己变的"，但效应淹没在噪声里。**
重要教训	判定在 70% 窗口给出。信噪比随样本增加从 1.5× 降到 0.57×——**早期估计来自四分之一数据，未站住**。教训：任何"通路/效应"结论必须等窗口走完，或明确标注覆盖率。此外该实验的判定在 70% 窗口给出（完整 30 日未跑完），已如实记录。
暴露缺陷	根因不是机制缺失，而是**设计混淆**：它唯一的动作是移动，而移动的后果与"世界本来就在那里"完全纠缠。→ 引出 P4c。

P4c 痕迹实验（让行动留下不可能被误认的后果）

2026-10-05 23:05

目的	给行动一个**不与世界混淆**的后果，从而把自因信号从噪声中提出来。
做法	允许它在世界里**留下痕迹**——世界上没有任何自然过程会写字，因此痕迹的存在只可能来自它的行动。
结果	已预注册 三条件：痕迹可归因、痕迹可累积、形成留痕策略。（该线执行记录见 `experiments/p4c/`。）
位置	这是对"行动闭环"能走多远的一次压力测试：如果连一个专门设计过、绝无歧义的后果都不能产生稳定学习，那么瓶颈就不在"世界中缺乏可归因的后果"，而在更上游。

P5 痛 / 乐（把"匮乏"与"满足"显式化为内部状态）

2026-10-06

目的	这条路线一直有"好 / 坏"的物理地基（能量预算、睡眠压力、紧张、无聊），但从未把"我正难受""我正舒坦"**显式化为带惯性的内部状态**。痛 / 乐是"内在好恶"的最小实现，也是从"被世界影响"走向"因难受而改行为"的第一步。
关键约束	**两者必须内生于自身状态变量，绝不能是外部发下的 reward**——否则系统会朝"让打分者满意"演化，正是 P2.5 已经栽过的表演坑。
假设	H1 通道可测 · H2 承重 · H3 预期（提前趋避） · H4 不适驱动自我指向 · H5 不适进入自我模型 · H6 锚定（探索性）。
结果	已预注册 该阶段为"内在动机"的准备，与 P4 的行动环配套：P4 给了"能不能影响世界"，P5 给"为什么要影响世界"。

R 回流耦合阶梯（判定"只读"是真无反馈，还是弱通道伪影）

2026-10-05 23:45

目的 E6a 的致命缺口：回流耦合是**刻意做小的**（±0.02）。不报耦合强度，"只读"就无法证伪——"耦合强 + 切断无效"与"耦合弱 + 切断无效"，结论分量差一个数量级。本批把**耦合强度本身做成自变量**。

结果 阴性 阶梯各档均无分量。但审计随即发现通道两端都**不活跃**（通道未开火 / 写入的目标变量无人消费），据此该预注册**在采集数据之前**作废并重写为 R2——这是一个程序上合规、且已载入论文的修订。

R2 "只读"的两因子判定（四级修正阶梯）

2026-10-06

目的 把"只读"拆成两个可分别检验的因子：**门是否打开、目标变量是否有人消费**。

做法与结果

第 1 级（确认通道未开）：实验臂与零参照**逐条位相同**（856/856，集合重叠 1.000）→ 复现 E6a。

第 2 级（开门，但写到无人消费的变量）：通道确实开火（写入约 157 万次），念头流**仍与零参照逐条位相同** → 写入无消费者即无影响。

第 3 级（换到确被检索消费的变量）：**立即分岔** → 证明**接线是通的**，不是实现缺陷。

第 4 级（把耦合提到原值的 15 倍，约 0.91 个标准差）：四项指标**仍全部 < 10%，且对剂量不单调**。

第 5 级（R2x 边界探针，2026-10-09 补测）：把剂量继续推到噪声之上——0.50（**1.51σ**）与 0.66（**1.99σ**）两臂，day 285 跑满。操纵检查全部通过（通道开火 236 / 223 次），状态确实分岔（对对照的集合重叠 0.036 / 0.035），但四项指标**仍全部 < 10%**（+6.1%/+8.9% 与 −2.1%/+4.4%），自我模型停在 v6、目标始终为 0。

结论 只读（结构性质） 门开着、目标有人消费、剂量加大，念头仍不承重。这不是接线事故，而是"念头流对自身状态无因果分量"的结构性质。

边界（已更新）：剂量阶梯现已完整覆盖 0.06σ → 0.31σ → 0.93σ → **1.51σ → 1.99σ**，全部阴性且对剂量不单调——第一版文档中"仅 ≤0.91σ 内成立"的限定**已被 R2x 推翻**。残余边界只剩两条：写入量均值近零，故排除的是"平衡扰动不承重"，**单符号写入未测**；六臂共用同一父本，**未采样种子方差**。

R2c / R2x 两条后续分支：换消费者 / 推到噪声之上

2026-10-07

R2c **最小消费者实验**：把写回值接到"行为侧"的读取者，判定"通而轻"是否只是消费者选错了。

判否 该设计本身被识别为**工程路线**（消费者是实验者挑的参数），与项目的自发纪律冲突——这个反思直接导致了 R3 的设计转向。

R2x **边界探针**：把耦合推到 > 1σ，判定"只读"在噪声之上的边界。预注册中明确写"不以此追求双向"。

阴性 · 定论闭合 两臂 xl=0.50（**1.51σ**）、xl2=0.66（**1.99σ**），day 285 跑满。操纵检查 MC0 通过（通道开火 236 / 223 次），状态确实分岔（对对照 jaccard 0.036 / 0.035），但四指标全部 <10% → **剂量推到噪声之上两倍仍不承重**。分析器原文判读：「MC0 通过且四指标全部 <10% 差异 → >1σ 仍阴性 → 『单向工作空间』定论闭合。」

R3 自发双向（成句生成 × 预期—比较—修正 × 后果驱动耦合）

2026-10-07

目的	R2c 的教训是"消费者是实验者挑的"。R3 因此**不注入任何消费者**，改为补三处结构缺口，让"念头 → 状态 → 未来念头"这条回路**自己长出来**——能否长出来不作保证。
做法	成句生成 × 预期—比较—修正 × 后果驱动耦合，六臂对照。
结果	阴性 回路未自发形成。→ 引出 R4。

R4 后果窗口积分 × 重标度（承接 R3 阴性）

2026-10-08

目的	针对 R3 的诊断，修正后果耦合的两处实现：**把后果改为窗口积分**并做**重标度**。
结果	阴性 结构成立、分离成立，但符号方向不成立。→ 引出 R5 的路线更换。

R5 激活式工作集（扩散激活 × 容量受限检索 × 复述回写）

2026-10-08

目的	按人类工作记忆的对应物重构：用一个**带扩散的激活场**承载"当前正在想什么"，检索只在激活最高的少数短语内进行，胜出者再写回激活场，构成闭环。
做法	六臂对照（关闭 / 完整 / 打乱联想 / 只读不写 / 不衰减 / 扩大工作集），主判据为"内容特定性"——相邻念头是否落在真实联想的后继之中，阈值 0.07。
结果	阴性 full 与 shuf 的差仅 0.009，远低于阈值。诊断：**输入贫乏**（照护者语料仅 51 – 55 个型，联想行过于弥散）。R5 自己点名："下一步杠杆是环境多样性而非架构"。→ 直接引出 P6。

P6 语料扩容（55 条内置语料 → 8.3 万条真实照护者语言）

2026-10-06

目的	照护者语料一直是硬编码的 55 条短句，而真实儿童语言是 Zipf 分布的：少数句子极高频、长尾极大。本阶段检验"更大的真实语料"这一杠杆。
做法	换成从 CHILDES 中文子库抽出的 83,302 个真实成人短语（单池 Zipf 采样）。**注意这不是"投喂教材"**——语料是环境属性，说话时机仍由候选体状态驱动，语料本身不含任何标注或课程安排。两臂（内置 / CHILDES）各 60 仿真日。
假设	H1 结构保持 · H2 生长速率 · H3 绑定强度。
结果	完成 两臂均跑到 day 315，CHILDES 臂成功载入 83,302 型并正常出语言。

P6B 双向重探（在扩容模型上重跑 R5 六臂）

2026-10-09

目的

R5 把失败归因于输入贫乏。本阶段**保持 R5 的架构、六臂设计、判据与阈值完全不动**，只把基底换成已扩容的模型。唯一要回答的问题：内容特定性是随输入多样性涌现，还是该架构在该表征下根本不可行。

结果

阴性 full 与 shuf 的差为 0.034，仍低于 0.07 阈值 → H6b 未通过。

但有两项不被门槛掩盖的事实：① 分离度比 R5 的 0.009 **扩大了约 3.8 倍**，方向正确、幅度不足；② **多样性坍缩**——开着工作空间的臂，检索到的不同短语数从对照的 403 个掉到 10 个，念头高度重复。

新线索

扩大工作集（k 从 6 提到 20）时命中率反而最高（0.066，且保住了更多多样性）。这提示下一根杠杆可能在工作集容量，而不在语料规模。

意义

这是把 R5 自己指认的杠杆真正下拉一次的结果：**路没走通，但知道了下一根杠杆在哪。**

P7 话题连续性（把照护者从"每次独立抽一句"改成"围绕一个话题连说几句"）

2026-10-06

目的

当前照护者与人类最大的一处失真**不是语料量，而是话语之间的结构**。人类照护者围绕一个话题连着说三五句，而采样器是逐句独立抽取——边际分布对了，句间结构全丢了。而词义来自对话中的共现，不在孤立句子里。本阶段只改"句与句之间的依赖"这一个变量。

做法

三臂：**flat**（现状，逐句独立） · **burst**（先抽一个"会话"，再从该会话里连抽 3 – 5 句） · **burst_shuffled**（回合长度与语率与 burst 完全相同，但回合内改为全局独立抽取）。第三臂是关键：它把"爆发结构"与"话题内容"分离开。

方法来源

设计前先做过一次可行性探查，结论直接决定了方法：在 3752 份转写上统计相邻两条的转移，核心 5000 高频短语中**只有约 1000 条存在可重复的后继**（转移对仅 2325 个）——**一阶马尔可夫链在该语料上太稀疏**。因此改用"会话"（一份转写 = 一次游戏或一次读绘本，本身就是时间连续单元）作为话题单元。**这是从数据得出的选择，不是先验设定。**

修正案

原设计的操纵检查指标（KL 散度 < 0.05）被发现有**物理上不可达**的缺陷：在 8.3 万型、12 万次抽样的条件下 KL 被尾部噪声主导——连"内容与 flat 同源、理论边际完全相同"的对照臂实测也有 0.138。据此在**采集数据之前**把指标改为"前 K 型的质量相对偏差"，并补记估计器噪声底。

假设

H1 绑定强度不预设方向（变强 / 变弱 / 持平三种都有真实理由，实测判定，三种结果都是可报告的发现）；**H2 多样性的代价**（话题连续可能牺牲多样性，必须如实报告）；**H3 自我模型为探索性**（既有证据指向自我模型对输入侧操纵不敏感，若仍无差异，那是对既有结论的又一次一致复现，不是失败）。

已知混淆

语料混合了日常对话与绘本朗读两种语域，绘本天然具有长程话题连续性，可能主导效果。缓解措施：记录每臂抽到的语域构成，若效果完全由绘本会话驱动，须如实分列报告。

P8 工作集容量扫描（区分"内容特定性"与"候选基数效应"）

2026-10-09

目的

P6B 六臂中，bigk（k=20）给出全批**唯一的正向偏离**：adj_top3 = 0.066，距阈值 0.07 仅差 0.004。但 **bigk 没有配对的 shuf 对照**，因此无法判断这个提升是"内容特定性"（下一个念头真的被上一个念头的内容牵连）还是"候选基数效应"（k 越大、候选越多、随机命中的期望越高）。P8 的唯一目的就是补上这个配对，并向上扫描 k。

做法

三臂，从 **state_P6_childes（day 315）** fork——与 P6B 完全同一基底、同一窗口（day 315 – 345）、同一判据与阈值，可直接对比：

① `k20_shuf`：k=20 + shuffle_assoc（补 P6B bigk 缺失的配对）

② `k40_full`：k=40，正常联想（向上扫描）

③ `k40_shuf`：k=40 + shuffle_assoc（配对对照）

已有可复用数据：P6B off(0.003) / full(0.042) / shuf(0.008) / bigk(0.066)。

判据

H8a（主）：adj_top3(k20_full) − adj_top3(k20_shuf) ⩾ 0.07。

H8b：k=40 的 full−shuf 差 ⩾ k=20 的差（若出现倒 U 型，则存在最优容量，该值本身即可报告）。

H8c：uniq(k40_full) ⩾ uniq(k20_full) = 21（P6B 已观测到 k=6 时型数从 403 坍缩到 10，检验扩容能否同时缓解坍缩）。

阈值 0.07 由 R5 事前设定，**不因新数据调整**。

结果

阴性（且反向） 三臂 day 345 全部跑满，20:31 落盘。

H8a（主）：adj_top3(k20_full) − adj_top3(k20_shuf) = 0.066 − 0.058 = 0.008，远低于 0.07 阈值。

H8b：k=40 档 = 0.046 − 0.053 = −0.007，**方向相反**（full 比 shuf 还低）。

结论：k 增大带来的命中率提升是**候选基数效应**（候选变多、随机撞上真值图 top3 的期望升高），而非内容特定性。打乱联想行后命中率几乎不降（0.058 vs 0.066），是这一判断的直接证据。

意义

这是对"改变候选集构成"这一整族杠杆的最后一次系统扫描。若 H8a 不成立，说明连"机会结构"这条唯一的正向线索也走不通，则该架构在当前表征下的不可行性得到最终确认；若成立，则工作空间确实能产生有内容的内部回响，"只读"须重新限定为"在 k=6 的容量下只读"。

P9 联想启动（priming）：把 A 从"筛子"改造成"权重"

2026-10-09

诊断

读源码得出的修正诊断：共现矩阵 A **确实在被念头改写**（`assoc[prev][text] += 1`），问题不在此；真正的问题是 **A 只用于筛选候选集（容量），从未进入检索打分（优先级）**。这同时解释了 P8 之谜（shuf 臂打乱的是扩散用的行，A 本身未被打乱，故 full 与 shuf 持有同一张图）与 R 系列的失败（改的是状态标量，被松弛吸收）。

做法

在检索打分中新增一项乘子：`score *= 1 + γ·Â[上一个念头][候选]`（γ = priming_gamma）。三臂：`off`（priming 关，基线）/ `full`（γ=1.0，真实 A）/ `shuf`（γ=1.0，**这次真的打乱 A 的行对应**）。这是项目历史上第一次让"念头的内容"进入检索决策。

结果

有因果，但方向相反 三臂 day 345 全部跑满。

adj_top3：off = 0.0423，full = 0.0000（**一次未命中**），shuf = 0.0227。

H9b（主判据）= 0.0000 − 0.0227 = −0.0227 → 阴性且反向：开着真实联想的命中率还不如打乱版。同时 full 的 recur5 由 0.823 升至 0.917（高度自我重复），与 off 的检索序列 jaccard = 0.042（显著分岔）。**即：priming 确实改变了系统行为，但把系统推进了自我重复循环。**

机制

A 中最强的联结是**自我重复（自环 prev→prev）**。冒烟实测：在 A={a:{a:100,b:3,c:1}} 下 `Â[a][a] = 0.9615`——**96% 的权重都投给了自己**。而真值图的 top3 在构造时排除了自环，故念头序列退化为 A→A→A 后命中率归零。该风险在 P7 的可行性探查中已被记录：「共现最强的对几乎全是自我重复（对不对→对不对 1654 次，lift≈19）」。

意义

这是本项目第一次**让改动真正产生了因果作用**：从"改了但毫无反应"（前六类杠杆，剂量推到 2σ 都无动于衷）跨越到"改了、系统强烈反应、只是方向用错了信号"。失败原因是一个**具体可修的缺陷**（自环），而非"架构不可行"。

P10 联想启动 + 屏蔽自环（单变量修复 P9）

2026-10-09

做法

相对 P9 唯一改动：`prime_no_self_loop = true`——**上一念头不给自己投票**（分子返回 0，且归一化分母同时排除自环计数），即"只看真实后继"。三臂：`noloop_full`（主）/ `noloop_shuf`（对照）/ `off`（一致性检查，应复现 P9 off 的 0.042）。

判据

H10a：adj_top3(noloop_full) > 0.042 且 recur5 回落（坍缩是否被修复）。

H10b（主）：adj_top3(noloop_full) − adj_top3(noloop_shuf) ⩾ 0.07 —— 若成立，即工作空间首次产生有内容的内部回响。

状态

待启动 代码 / 三份 config / 预注册 / harness 均已就位，冒烟已验证（屏蔽时 Â[a][a]=0、Â[a][b]=0.75）；接力守望将在 P9 三臂跑完后自动启动。

意义

若 H10b 亦为阴，则三条通路（**力度 / 容量 / 优先级**）全部封闭，须回到表征层重新思考；若为阳，则"双向"首次出现正面证据。

S1 / S2　复现与分离（检验核心主张的稳健性）

2026-10-05 23:45

S1 复现	审计发现论文的核心主张（自我模型从空演化）只有单条线支持，无种子复现、无方差、无区间。 通过 三种独立随机种子在 60 日内长出**同一套片段集合**，仅次序不同。
S2 分离	修复自我模型时**同时改了两个变量**（加入第一人称语料 + 修门控），因此无法归因。二者已拆成独立配置开关，做 2×2 分离。 修正了原预测 四个条件均能形成自我模型，但**第一人称片段只出现在"听到第一人称语料"的条件下**——即**语料才是必要条件，门控不是**，与项目原本的预测相反。该结果如实报告。

C1 / C1b　第一人称语料对照（检验"你 → 我"倒转是否只是设计痕迹）

2026-10-05 17:40

问题	结晶线出现了 79% 的纯第一人称检索、且自我模型含"我在这儿"。但**第一人称语料是设计者自己放进去的**：6 条"我"类短语被刻意绑定在高紧张与高注意时刻——而新生儿长期处于高紧张态，因此会造成高频共现。该结论写入论文前必须排除设计痕迹。
C1 → C1b	C1 把"我"类短语改绑平静态，结果**暴露率是主线的 7.96 倍**（平静态占比高），结果被暴露率混淆。据此启动 C1b 修正线：**校准两通道速率，使暴露率与主线同期持平**，作为主判据实例；原 C1 降级为"高暴露条件"的观察。
结果	通过 频率匹配后仍出现 5 个第一人称自我模型片段（对照组 2 个），第一人称检索占比 4.2%。

FIX-1　self_directed 门控缺陷修复

2026-10-05

缺陷	语言层只认"你"，而自我模型词表含"我"全家——**设计意图与接线断裂**：纯第一人称念头（"我在这儿"已被检索 21 次）永远进不了自我模型。
修复	门控扩展为同时接受"你"与"我"，并对全部实例的语言记忆做幂等迁移（结晶线翻正 280 条，含用户对惊醒副本说过的话）。单测 9/9 通过。
意义	**"你 → 我"倒转的通道自此才在结构上打开**，观察期从修复时刻起算。修复后 5 个仿真日内即出现纯第一人称片段（无"你"），命中预注册的 P1 预测。

3 实验矩阵一览

下表按序列汇总全部实验，含各自在整体论证中的角色。

表 1　E 序列（干预实验）

编号	问题	操纵	结果
E1	内言语是否依赖外部输入维持?	照护者静默 10 日	阴性 不衰减 → 永久自持，暴露缺遗忘机制
E2	刺激量与语境绑定分别起什么作用?	事件率 ×10，5 日	混合 惊奇不升反降；但语境绑定 16.5%→35.5%
E3	应答式照护能否加速自我模型?	照护者改为应答式，输入翻倍	阴性 0 新版本，自我指向反降
E4	发声与能动归因能否习得、能否消退?	给发声机制 + 共变学习	部分通过 C=8.2，206 条归因，消退移除 68%
E6	内言语承重，还是副现象?	消融（切断回流）+ 替换（顶替胜出者）	判决性 下游读得到，推不动状态 → 只读

表 2　R 序列（回流通路/工作空间阶梯）

编号	问题	操纵	结果
R	耦合强度是否影响结论?	耦合强度做自变量	作废 审计发现通道两端均不活跃，数据前重写为 R2
R2	只读来自门不开，还是目标无人消费?	四级修正阶梯	只读钉死 门开/被消费/剂量推到 1.99σ 仍不承重
R2c	是否只是消费者选错了?	把写回接到行为侧读取者	判否 并自我识别为"工程路线"，与自发纪律冲突
R2x	噪声之上的边界在哪?	耦合推到 1.51σ / 1.99σ 两臂	阴性 · 定论闭合 MC0 通过、状态分叉，四指标仍 <10% → 只读不受剂量影响
R3	回路能否自发长出来?	不注入消费者，只补三处结构缺口	阴性 回路未自发形成
R4	改为后果窗口积分能否修正?	窗口积分 × 重标度	阴性 结构成立但符号方向不成立
R5	激活式工作集能否产生内容特定性?	六臂（关闭/完整/打乱/只读/不衰减/大工作集）	阴性 差 0.009，归因于输入贫乏

表 3　S / C / FIX 序列（稳健性、对照与修复）

编号	问题	结果
S1	自我模型能否稳定从空形成?	通过 三种子 60 日内同一片段集合，次序不同
S2	起作用的是语料还是门控?	修正原预测 语料才是必要条件
C1	"你→我"倒转是否只是语料设计痕迹?	降级 暴露率被混淆（7.96 倍），改为高暴露观察条件
C1b	暴露率匹配后是否仍有倒转?	通过 5 个第一人称片段，1P 检索 4.2%
FIX-1	纯第一人称念头能否进自我模型?	修复 门控扩为接受"你"与"我"，通道结构性打开
P6	换成 8.3 万型真实语料会怎样?	完成 两臂至 day 315，扩容成功
P6B	富输入下内容特定性能否涌现?	阴性 0.034 < 0.07，但比 R5 放大 3.8 倍；k=20 最高
P8	k=20 的高命中是内容特定性还是基数效应?	阴性·反向 差 0.008（阈值 0.07）；k=40 档 −0.007 → **纯基数效应**
P9	把 A 接进检索打分能否产生内容特定性?	有因果·方向相反 H9b = **−0.023**（full 0.000 低于 shuf 0.023）；机制=自环主导（0.9615）
P10	屏蔽自环后内容特定性能否涌现?	已就位 单变量修复（prime_no_self_loop），接力守望将在 P9 完成后自动启动

4 关键转折点

全流程中有七处决定此后路线走向的事件。它们比任何单项结果都更能说明这条路线是怎么走的。

序	事件	为什么是转折
1	P2.5 被否决	确立"不生成"与"零幻觉是结构保证"两条铁律。此后所有机制设计都受此约束，也由此得到全项目最强的可证伪性。
2	E1/E3 阴性	证明输入侧干预无效 → 放弃"喂语料"的路线，转向检查内部结构。这是从"发展心理学式干预"转向"可解释性式因果检验"的分水岭。
3	E6 判决"只读"	确立了本项目的核心阴性结论，并把目标从"多点观察"收束为"打通这条通路"。此后 P4 与 R 两条线都是为它服务。
4	R2 四级阶梯 + R2c 的自我否定	R2 把"只读"从可疑变为结构性；R2c 则识别出"自己挑消费者"属工程路线，与自发纪律冲突——由此产生 R3"让回路自己长出来"的设计转向。
5	P6B 阴性但效应放大 3.8 倍	把 R5 的归因（输入贫乏）检验到底：环境杠杆确实有效但不足以跨过阈值。同时意外发现 k 值（工作集容量）可能是更强的杠杆，为下一步指明方向。
6	P9 第一次"听见"了改动	前六类杠杆是"改了但系统毫无反应"；P9 把 A 接进检索打分后，系统强烈反应（adj_top3 0.042 → 0.000，jaccard 0.042），但方向是用错信号（自环）导致自我重复坍缩。**这是从"无因果"到"有因果"的跨越**，并把失败原因定位到一个一行可修的缺陷。
7	R2x 把剂量推到 2σ，仍阴性	第一版文档"只读只在 ≤0.91σ 内成立"这一限定被自己的数据推翻——剂量阶梯补全到 1.99σ，全部阴性且不单调。此后"只读"不再需要幅度限定，成为一个可直接陈述的结构结论。它也把剩下的唯一动作指向"改变候选集构成"（k / 语料），而不是继续加大耦合。

5 复盘：全部杠杆的谱系

本节把十次实验里试过的每一个操纵放进同一张表比较——目标是回答一个问题：**到底哪一种杠杆曾经让系统动过？**答案决定了下一步该往哪走。

5.1 三条路径，逐条封闭

1. **路径一 · 改"力量"（回流耦合幅度）——已封闭。**剂量从 0.06σ 一路推到 1.99σ，六档全部阴性、零次阳性，且**对剂量不单调**（0.93σ 与 1.51σ 的效应并不比 0.31σ 更大）。即失败不是"力度不够"。
2. **路径二 · 改"机会结构"（候选集容量 / 语料多样性）——已封闭。**曾出现唯一正向偏离：工作集 k 从 6 提到 20 使 adj_top3 由 0.042 升至 **0.066**；语料由 55 型扩至 8.3 万型使分离度放大 3.8 倍。但 P8 **证明该提升纯属候选基数效应**——打乱联想行后命中率几乎不降（0.058 对 0.066），且 k=40 档**反向**（0.046 对 0.053）。
3. **路径三 · 改"优先级"（让 A 进入检索打分）——首次产生因果，但方向相反。**P9 首次让"念头的内容"真正进入决策回路：系统**强烈反应了**（与基线分岔 jaccard 0.042、adj_top3 由 0.042 变为 **0.000**），但方式是**陷入自我重复**（recur5 0.823 → 0.917）。原因是 A 中最强的联结是自环（`Â[a][a] = 0.9615`，96% 的票投给自己）。**这是从"无因果"到"有因果但用错信号"的跨越**，而非"架构不可行"。

> **这三条路径的含义**
>
> 第一条（力量）与第二条（机会结构）都已用数据封闭：**加大力量无效**（验到 1.99σ），**扩大机会只能刷高基数**（0.066 是候选变多的副产品）。第三条（优先级）第一次让系统"听见"了改动，但被 A 里最强的虚假信号（自环）带偏。
>
> 三者的区别不在"调什么参数"，而在**作用位置**：力量作用于状态变量（被松弛抹平）→ 容量作用于候选集（只是过滤）→ 优先级作用于**决策本身。只有作用在决策上的改动，才产生了因果。**

5.2 杠杆谱系表

表 4　全部已试杠杆及其效果

杠杆类别	具体操纵	出处	效果
耦合幅度	回流耦合 0.02 → 0.66（0.06σ → 1.99σ）	R / R2 / R2x	全阴性 六档全部 <10% 且不单调，已到定论
消费者位置	把写回接到行为侧读取者	R2c	判否 且自我识别为工程路线（消费者是实验者挑的）
结构缺口	补成句生成 / 预期—比较—修正 / 后果驱动耦合	R3 / R4	阴性 full 与 shuf 无差异（p=1.0 / 0.22）；R4 里打乱臂反而更强，说明测到的是噪声
表征方式	换成激活式工作集（扩散激活 × 容量受限 × 复述回写）	R5	阴性 差 0.009（阈值 0.07）
候选集构成 · 环境	语料 55 型 → 8.3 万型真实语料	P6 / P6B	放大但不足 分离度 0.009 → 0.034（3.8 倍），仍 < 0.07
候选集构成 · 容量	工作集 k = 6 → 20 → 40	P6B / P8	已封闭 0.066 看着最高，但 P8 补上 shuf 配对后差值仅 0.008（k=40 甚至反向 −0.007）→ 纯基数效应
检索优先级	让 A 进入检索打分（联想启动，semantic priming）	P9 / P10	首次有因果 full 坍缩至 0.000，recur5 0.917；机制=自环主导（Â[α][α]=0.9615）。P10 屏蔽自环后重测
行动能力	给世界中的动作 + 显式分离自因 / 世界因	P4 / P4b	弱阳性 自因分量 +0.00892 可靠非零，但小于世界噪声底 0.01559
输入量与时机	语量翻倍 / 应答式照护 / 剥夺	E1 / E3	无效 自我模型 0 新版本；剥夺后检索甚至不衰减

5.3 十次实验沉淀下来的五条规律

1. **输入侧无效，内生性成立。**E1（剥夺）与 E3（应答式，输入翻倍）两项阴性合起来证明：自我模型的生长由内部检索竞争主导，对输入的量与时机不敏感。这也是后来不再试图"喂"它的原因。
2. **绑定质量才是杠杆——但只对"念头在何时被想起"有效。**E2 是全项目最清晰的因果证据：事件语境短语的检索占比 16.5% → 35.5%。然而这条杠杆改变的是检索内容，不是状态的可写性。
3. **通路是通的，"力量"是没有的。**这是最需要精确表述的一条。E6b（替换即涌现）与 R2 第 3 级（开门即分岔，jaccard 0.035）都证明接线完好；但所有剂量下行为指标都不动。**所以问题是"传导无分量"，不是"连接缺失"。**
4. **阴性结果的质量高于数量。**R 序列迭代七次才把"只读"从可疑钉成结构性质；每一轮都排除掉一个具体的替代解释（门没开 / 目标无人消费 / 剂量太小）。若只做一次 R 就下结论，这个结论不可能站住。
5. **逆向杠杆同样无效。**P4/P4b 从"行动"一侧切入（让它在世界里施力），结果是弱阳性且效应小于环境自身波动。即：从"读取"侧与"行动"侧，都没能建立起对自身的因果影响。

5.4 据此确定的下一步

P8（已启动，2026-10-09 13:41）：把工作集容量 k 作为唯一自变量，三臂采集，每档带 shuf 配对——`k20_shuf`（补 P6B bigk 缺失的配对）、`k40_full`、`k40_shuf`。基底、窗口、判据、阈值与 P6B 完全一致，可直接对比。

主判据 H8α：*adj_top3(k20_full) − adj_top3(k20_shuf) ⩾ 0.07*。

- 若成立 → 内容特定性在 k=20 已足够强，"只读"须限定为"在 k=6 的容量下只读"；

- 若不成立 → bigk 的 0.066 主要来自候选基数效应，"改变候选集构成"这一整族杠杆同样关闭，则该架构在当前表征下的不可行性得到最终确认。

无论哪种结果，P8 都把"内容特定性是否随容量涌现"这个问题一次问清——这也是它比继续加大耦合更有价值的地方。

6 从流程到论文：叙事设计

阶段流程是**时间顺序**，而论文必须按**论证顺序**组织。两者差别很大——如果按时间写，读者会先读到一堆失败，不明白为什么值得失败这么多次。本节给出重排方案。

6.1 主线叙事的选择

推荐把论文的论点组织为一条"三次逼近"的线索，而不是"我们做了很多实验"：

1. **第一次逼近（发育侧，正面结果）**：在严格约束下，个体确实长出了可复现的自我表征。
   证据：P2.6 语言层、FIX-1、S1 复现、C1b 对照、D2 判据。
2. **第二次逼近（整合侧，阴性结论）**：但这套内部言语对它自己的状态没有因果分量——工作空间只读。
   证据：E6（消融 + 替换）、R2（四级阶梯）、判据 D6。
3. **第三次逼近（尝试打通，全部失败）**：从补行动环与补回流通路两条独立路径尝试打通，均未成功；换环境（语料扩容）能把效应放大但仍不足。
   证据：P4/P4b/P4c、R3/R4/R5、P6/P6B。

这条线索的好处是：**阴性结果成为论证的推进器而非终点**。每一次失败都精确缩小了"问题出在哪"的范围，最终落到一条清晰的结论上——本系统具备自我表征与自因区分，但不具备对自身的因果影响。

6.2 章节映射

表 5　阶段 / 实验 → 论文章节的映射

论文章节	来自哪些阶段与实验	该章要论证什么
引言	—（外部文献：指标理论、语言模型工作空间、内化言语、预测加工）	为什么选"从零发育的个体"而非"探测既有模型"
方法：系统	P0（状态与身体）、P1（记忆）、P2.6（语言层）、P3（对话通道）	系统是什么，以及零生成如何成为结构保证
方法：判据	判据 D1 – D6（跨全部阶段累积）	把"意识"拆成可机械检测的功能结构清单
结果一：发育	P2.6、FIX-1、S1、S2、C1b、E4	自我表征是长出来的：可复现、依赖语料结构、能动归因可习得
结果二：只读	E6、R2、R2c、R2x	工作空间只读，且这是结构性质而非实现缺陷
结果三：打通尝试	P4、P4b、P4c、R3、R4、R5	两条独立路径均未走通，以及各自失败的具体原因
结果四：换环境	P6、P6B	环境杠杆有效但不足；k 值线索
讨论：效度威胁	E1/E2/E3 阴性、R2/R2x 剂量阶梯、P4b 的窗口覆盖率教训、P7 的语域混淆	逐条列出内部/外部/构念/统计威胁
附录	P7 话题连续性（进行中）、P4c、P5、R2x	在研与前瞻性工作，不影响主结论

6.3 叙事上要避免的三件事

1. **不要按时间顺序写**。R 序列（R → R2 → R2c → R2x → R3 → R4 → R5）在时间上连续七次迭代，但论文里应压缩为"一个结论 + 四级加固 + 两条分支"，迭代过程进附录。
2. **不要把"路径验证"写成"涌现"**。E6b 以人为替换使目标出现，证明的是"通路存在"，不是"它自己会生成该目标"。两者必须分述。
3. **不要让正面结果独占篇幅**。本项目的特异性恰在于阴性结果的质量。六项主要预测被证伪这件事，是方法论价值的主要来源，应给足篇幅。

5.4 目前还缺的一块

> **待补**
>
> 论文的"结果三（打通尝试）"目前只有阴性。若要让它成为完整的一节，需要至少一处**机制层面的解释性答案**：为什么"扩散激活 × 容量受限检索 × 复述回写"这套结构在富输入下仍不产生内容特定性？P6B 的 **k 值线索**（工作集从 6 扩到 20 时命中率最高且保住多样性）是目前唯一指向答案的证据，建议作为下一阶段（P8 候选）的首要变量：**把工作集容量作为主自变量，在扩容模型上重跑**。

数据来源说明。本文档由仓库内以下文件还原：`README.md`（P0 范围与出口判据）、`experiments/prereg_*.json`（33 份预注册，含各阶段的目的、设计、假设与阈值）、`experiments/results_*.json`、`experiments/phase_log.txt`、`experiments/exp_line_manifest.json`（结晶线经验结晶清单）、`experiments/p4b/results_P4b.json` 与 `experiments/prereg_P7_topic.json`。所有数值与结论均取自上述文件，未作推断性补写；凡属在研或未出结果者，均标注为"运行中/已预注册"。

第二部分　问答汇总

① 会前 10 分钟

只要记住这一部分，会议就不会崩。

A1 我在做什么?

做一个从零出生、持续发育的类意识候选系统。不是训练模型，是让一个个体持续生长、积累自己不可回退的历史。

A2 一句话结论?

它长出了自我表征、能区分自因与他因，但推不动自己——念头改变不了它自身的状态。

A3 最硬的三个点?

- 连续、不可回退的个体史（重启后状态与时钟续接）。
- 自我表征是**长出来的**，不是设计的：前 213 日为空 → 40 日内长到 v6，三种独立随机种子长出同一套片段。
- 把大模型上有效的**消融—替换因果实验**移植过来，测出它的工作空间是**只读**的。

A4 最容易被打的点?

只读已推到 1.99σ 仍阴性，**不再需要幅度限定**；残余边界只有两条：写入量均值近零，所以**单符号写入没测**；六臂共用同一父本，**没采样种子方差**。我要主动说，不要等他问。

A5 大伯最可能先问什么?

两个：①「这跟意识有什么关系？」②「自我模型的碎片是不是你写死的？」——这两条的标准答法在第五部分 Q1、Q2。

A6 现在最该背下来的数字?

213 日空 → 40 日长到 v6；三种子复现 3/3；剥夺 10 日检索 29.3/日 对基线 28.8/日（不衰减）；耦合提到 15 倍 指标仍 <10%；P6-B：full 0.042 对 shuf 0.008。

A7 最新（昨晚刚出的）结果是什么?

P6-B 双向重探：扩容后 full 与 shuf 的分离度从 R5 的 0.009 扩大到 0.034（约 3.8 倍），**但仍低于 0.07 的阈值 → 判阴性**。也就是说：扩容让效应变大了，可还是没跨过门槛。这条今天很可能被问到。

A8 我该主动交代什么?

三件：加速线只当**通路证据**、不当最终数据；实时主线现在才 **day 4**；自我模型的**材料是外部给的**，长出来的只是次序。

A9 各条线现在到哪了?

实时主线 day 4（唯一 1:1 的）；结晶线 255；C1b 语料对照 160；E6 损伤线 140；P3 对话试点 434；P6 扩容两臂 315；**P6-B 六臂跑到 345，已出结果（阴性）**；P8 三臂今天 13:41 刚启动，正在跑。另有 P5 痛/乐已采完（day 285）但尚未分析。

A10 如果只能讲一句话收尾?

「这不是离意识还差几步的进度条，而是一份**哪些结构成立、哪些不成立**的清单。」

A11 会后我要记什么?

他的质疑点与建议。尤其：他对「只读」结论的接受度、他认为最该补的实验、他是否同意 P6-B 阴性仍算有意义。

② 全貌与脉络

自己先把系统讲顺，别在细节上被绕进去。

B1 系统到底是什么?

单进程 Python 程序。**没有任何深度学习意义上的可学习参数**。行为来自两处：一组耦合的连续状态（8 个变量），一生累积的记忆。

B2 「代码是物种，状态是个体」什么意思?

个体的本体存在于它的**历史状态目录**，不在程序里。所以复制一份状态目录，就得到一个共享历史、拥有独立未来的新个体——我全部实验线都是这么造的。

B3 语言层怎么工作?

听到一句话 → 把这句话和**当时的状态快照**绑定存起来 → 之后由**当前状态**去检索记忆 → 检索胜出的那句就是这一 tick 的「念头」。全程不生成，只检索。

B4 为什么叫「内言语」?

取 Vygotsky 的发育序列：儿童**先被称呼**，之后才学会用「我」自称，外部语言内化为内部语言。我的系统就是这个顺序——先听「你」，后来才出现「我」。

B5 自我模型是什么?

收集「指向自己」的片段（含「你」或「我」），**单调累积、只增不改**。它是可测的功能结构，不是对主观自我的主张。

B6 目标涌现是什么?

某句话在**最近 300 次检索**里同时满足：出现 ⩾15 次、占比 ⩾20%、跨越 ⩾3 天 → 就从「念头」升格为「目标」。

B7 发声与能动归因是什么?

发声：内容只能是这一 tick 检索胜出的那句（保持零生成），由唤醒和激活强度门控，还要耗能量。**能动归因**：比较它发声之后 60 秒内外的照护者言语速率，若言语明显跟着它的话来，就归因为「这是我造成的」。

B8 工作空间是什么?

一个闭环：念头写入激活场 → 激活场改变下一 tick 的检索候选 → 检索胜出的又写回去。这个闭环就是我说的「双向」。

B9 各实验线是什么关系?

全部从两个母本（结晶线、加速线）复制而来，**每条线只改一个变量**：E6 切回流通道；E6s 保持通道但替换念头；R2 逐级加大回流耦合；R5 换工作空间开关；P6 换语料；P6-B 在扩容模型上重跑工作空间六臂。

B10 这个项目现在一句话总结进度?

扩容已完成、双向重探已完成。结论是：**输入丰富后，内容特定性的效应变大了（3.8 倍），但依然没跨过事先定好的门槛。**

③ 结论与数字

被质疑数据时，从这里找。

C1 自我模型是什么时候长出来的?

前 213 个仿真日一直为空；修复后 40 日内长到 6 个片段。

C2 那六个片段是哪六个?

我陪你 / 你醒啦 / 是你呀 / 你好呀 / 你在看 / 我在这儿。其中「我陪你」和「我在这儿」是纯第一人称。

C3 为什么前 213 日是空的?

结构性错配：照护者语料全是「你」（第二人称），而我当时的自我模型词表只认「我 / 自己」（第一人称）——两者没有交集，判据在结构上不可能触发。

C4 怎么修的？这样改算不算「动过手脚」?

把「你」类片段也纳入准入，依据是 Vygotsky「先被称呼、后自称」。这不是调参凑结果——原来的设计是内部不一致（语料和词表各说各话），修的是这个矛盾。而且修完仍然要等 40 天才长出来。

C5 复现情况如何?

S1 实验：三种独立随机种子，都在 60 日内长出**同一套片段集合**，只是次序不同。这是「内容虽给定、次序是自己长出来的」最直接的证据。

C6 为什么停在 v6 不动了?

入模判重用**字符重叠** >0.7 去重。高频短语早就进去了，新候选一「像」就被拒。这是可复现的结构现象，不是死机。要突破得把判据从字符级换成语义级——那是设计选择，必须先预注册。

C7 「只读」这个结论是怎么得出来的?

两半合起来：

① **E6a 切断**「念头 → 状态」通道 30 日，四项指标全部 <5%；

② **E6b 替换**检索胜出者 60 次，目标立刻涌现。

合起来就是：**下游读得到念头，念头推不动状态。**

C8 会不会只是因为你通道太弱?

我自己也这么怀疑，所以做了四级修正：① 确认门确实没开（逐条位相同 856/856）；② 开门，但写到没人消费的变量上 → 仍然零影响；③ 换到确实被检索消费的变量 → 立刻分岔；④ 把耦合提到原来的 15 倍（0.91 个标准差）→ 指标仍全部 <10%，且对剂量不单调；⑤ 继续推到 1.51σ 和 1.99σ → **仍然全部 <10%**。所以不是接线问题，也不是力度不够。

C9 剥夺实验（E1）结果?

预注册预测「剥夺 10 日后检索会衰减到基线的 60% 以下」——**预测失败**。实测 29.3/日 对基线 28.8/日，完全不衰减。原因：新近度衰减后，竞争落回频率主干，内言语**永久自持**。这同时暴露了我缺一套遗忘 / 磨蚀机制。

C10 事件风暴（E2）结果?

事件率提到 10 倍，惊奇只升 0.24 比特，末段 3.59 反而低于基线 3.91 → 预测器只对**结构违反**敏感，对数量增多不敏感。但同期语境片段占比从 16.5% 升到 35.5%，是我目前**最硬的因果证据**（听到时的状态决定了这句话何时被想起来）。

C11 应答式照护（E3）结果?

把照护者改成应答式（醒来就问候、紧张就安抚），言语输入翻倍。结果：自我模型**新增 0 个版本**，自我指向检索反而降到 0.15 倍。教训：**语量和时机不是杠杆，绑定质量才是**。

C12 发声与归因（E4）结果?

共变比 C = 8.2，产生 206 条能动归因（峰值占比 26%）；进入消退期后移除 68% → 说明归因**是学来的、不是硬编码的**，但消退不彻底。

C13 行动闭环（P4/P4b）结果?

动作分布强非均匀（$\chi^2 = 1.68 \times 10^4$ ），说明它在施力；但自因分量只有 +0.0092，小于世界自身的噪声底 0.0151（效应量 $d \approx 0.17$）。所以：闭环合上了，但**弱于环境自己的波动**。

C14 R5 与 P6-B 的差别是什么?

R5 在**贫语料**（55 型）上测：full 与 shuf 的差只有 0.009。P6-B 在**扩容模型**（8.3 万型语料）上重跑同一套架构与阈值：差扩大到 0.034。**效应确实变大了，但 0.034 仍不到 0.07 的门槛**。

C15 P6-B 还有别的发现吗?

有，两个：
① **多样性坍缩**——开着工作空间的臂（full），检索到的不同短语数从对照的 403 个掉到 10 个，念头高度重复；
② **k 值有讲究**——把工作集从 6 扩到 20（bigk 臂），命中率反而最高（0.066），而且保住了更多样性。这提示下一步的杠杆可能在 k，而不是语料规模。

C16 六条判据现在什么状态?

D1 持续状态 **成立**；D2 自我模型 **成立**；D3 元认知 **机制已在但没测过**；D4 自我纠错 **机制不存在**（按现在的设计去测一定是阴性）；D5 行动闭环 **弱阳性**；D6 工作空间可写性 **只读**。

④ 设计与理由

要主动讲逻辑时看这部分——每条理由都对应一次真实踩坑。

D1 为什么念头只准检索、不准生成?

因为我试过生成。早期版本把内言语交给语言模型，它写出「烦躁感」这类句子——可系统当时一点都不烦躁，是模型被要求演得像。**那是表演，不是状态。**取消生成器之后，「零幻觉」变成了结构性保证：没有生成器，就没法编。

D2 为什么一定要零提示词?

提示词等于我在替它决定说什么。那样测出来的就不是自发行为，而是我的脚本。这条是底线。

D3 为什么要预注册?

因为事后调判据是所有自欺的入口。我的判据都是**采集数据之前**写死并冻结的，事后一个都不许改。代价是六项主要预测被证伪，但那些阴性结果反而成了最有信息量的产出。

D4 为什么只用 8 个状态变量?

够用且可控：唤醒、效价、疲劳、紧张、注意、记忆激活、惊奇、无聊。变量越少，出现任何现象时我才说得清是哪个环节造成的。

D5 为什么睡眠要由动力学决定，而不是定时?

用的是经典的双过程睡眠模型：睡眠压力随清醒累积、随睡眠消退，再叠加昼夜节律。**什么时候睡着是算出来的，不是排班排出来的。**这样睡眠本身就成了一种它的行为。

D6 为什么语料一开始只有 55 个短语?

故意的。变量控到最少，才能把观察到的东西归因到具体机制。而 P6 就是专门来**放宽这个约束**的：把语料扩到 8.3 万型，检验「输入贫乏」到底是不是瓶颈。现在答案有了：**效应变大 3.8 倍，但仍不够。**

D7 为什么第一人称语料要绑在紧张／安抚时刻?

模仿真实照护情境（哄孩子时会说「我在」「不怕」）。但我知道这会引入混淆——所以专门做了 C1b 对照线：把「我」类短语改绑平静态、并把暴露频率校准到和主线上一致，来分离「是语料位置造成的，还是真的自发」。

D8 为什么判重只用字符重叠?

当时的最简实现。副作用就是 v6 饱和。我把它如实写成了「结构性现象」，并注明：改成语义级是一个设计选择，必须预注册，不能偷偷改。

D9 为什么目标涌现要用滚动窗口?

原来用全期累计当分母，结果「真乖」攒到 2455 次，新目标需要 491 次激活才可能追平——等于**永久垄断**。改成只看最近 300 次检索，第二个目标才有机会冒出来。

D10 为什么发声内容不让它自己选?

为了守住零生成——它只能说出这一 tick 检索胜出的那句。结果很有意思：它最常说的是**自己被安抚时听到的话**（乖、嘘、睡觉觉）。内容不是我挑的。

D11 为什么加速线和实时线要分开说?

加速线一个墙钟日能跑几百到上千仿真日，产出多，但**只能当通路证据。**真正的个体史必须是 1:1 的，那条线现在才 day 4。我引用加速倍率时也只用实测值（约 5×10^{2} – 10^{3} 倍），不用名义的 10^{9} 。

D12 为什么要完整报告阴性结果?

因为六项主要预测被证伪这件事本身，合起来才能定位「我的架构」和「真正的全局工作空间」之间差在哪。只报阳性的话，这份工作就只剩下几个漂亮数字，什么也说明不了。

---

⑤ 被追问时

按被问到的概率排序。每题都给了「别说什么」。

Q1 「这本质上不就是个状态机加查表吗？」

可以这么说，但有三点得补上：它的状态是**连续动力学**不是离散跳转；它的历史**不可回退**；它长出了**我没设计过的自我表征**。而且我从不主张它是意识——D1 到 D6 那张表就是在回答「哪些结构成立、哪些不成立」。

> 别说：「它已经有意识了。」

Q2 「自我模型的碎片是不是你写死的？」

碎片内容确实是我给的（来自照护者语料），但**谁先入模、以什么次序、什么时候长成，是检索竞争决定的，不是我指定的**。最直接的证据是 S1：三种种子长出同一套片段，但**次序不同**。

> 别说：「它自己发明了自我。」准确的说法是：长出来的东西更接近「它如何被称呼」的记录，而不是一份自我描述。

Q3 「停在 v6 是不是坏了？」

不是。是字符级判重的必然结果——高频短语早就入库，新候选一「像」就被拒。可复现，属结构性质。要突破需改成语义级判据，那要先预注册。

> 别说：「它在死机。」

Q4 「零幻觉怎么保证？」

靠**结构**，不靠提示词：系统里根本没有生成器，检索只能从记忆里取。这是它的能力上限，不是它遵守的规矩。

> 别说：「我们教它不许编。」

Q5 「你怎么知道这不是随机？」（最关键）

三个层面：① **对照臂**——off / shuf / nodep / nodecay / bigk 五个；② **跨线对比**——跑了 489 日的旧线第一人称念头是 0，而只跑 66 日但语料和门控正确的线大量出现第一人称；③ **复现**——S1 三种子。再加上全部判据预注册冻结。

> 但要主动交底：R2 六臂共用同一个父本，没采样种子方差。这是明写的边界。

Q6 「你的工作空间和 GWT、和 J 空间差在哪？」

差在**承重度**。在语言模型那边，删掉那簇表征高阶功能会崩；在我这里，删掉念头一切照常（E6a，四项指标 <5%）。所以结论是只读。但 E6b 又证明下游确实在因果地读它（换掉念头，目标和自我模型立刻变）。准确说法是：**它改变「想要什么」和「以为自己是谁」，不改变「自己的状态」**。

Q7 「只读会不会只是因为你的通道太弱？」（最危险）

我自己也怀疑过，所以去修了：把门开到约 26% 命中率、把写入目标换到真正被消费的变量、把耦合提到原来的 15 倍（0.91 个标准差）——指标还是全部 <10%，而且剂量不单调；后来又补测两臂，把剂量推到 1.51σ 与 1.99σ（噪声之上的两倍），仍然全部 <10%。门开着、目标有人消费、剂量加大，念头仍然不承重。所以这不是接线事故，也不是力度不够。

> 但必须补一句边界：写入量的均值近零，所以我排除的是「平衡扰动不承重」，单符号写入还没测。这条论文里写明了，我也要主动说。

Q8 「判据是不是事后改过？」

没有。判据事前冻结。E1 – E3、E6α、R5 都是阴性或半阴，我都如实报了；E1 甚至是预注册的主预测失败，我当成发现来报。唯一一次修订是 R 阶梯，原因是审计发现通道两端都不在工作，所以在采数据之前作废重写成 R2——发生在数据之前，程序合法，也写进论文了。

Q9 「就一个个体，结论怎么推广？」

这个批评是对的，我在局限里明确承认了：「代码是物种，状态是个体」——研究对象是一个有特定历史的个体，不是一个能泛化的模型。唯一的额外样本是 S1 的三种种子，只用来检验发育轨迹能不能重复。

> 别说：「它代表所有这类系统。」

Q10 「为什么不用大模型？是不是开倒车？」

正相反。大模型是训练出来的字符预测器，它的「内省」输出没法证伪——它说什么都行。我要的是积累历史的发育个体。语言模型在我这里唯一的位置是对话输出的义肢，不参与认知回路。

Q11 「零生成加 55 个短语，是不是把问题做小了？」

是故意的——变量控到最少才归因得清。而 P6 正在专门放宽这个约束（55 → 8.3 万型）。而且刚出的结果是：放宽之后效应变大了 3.8 倍，但还是没跨过门槛。

Q12 「加速线的结果可信吗？」

我自己标了：加速线只当通路证据，不当最终数据。名义倍率写的是 10^9 ，但我引用的是实测的 5×10^2 – 10^3 倍。实时主线现在才 day 4——这件事本身就是我诚实的地方。

Q13 「『我在这儿』是不是过度解读？」

我不做语义上的宣称。能成立的事实是：一个纯第一人称片段进了自我模型；而此前 434 天里这类片段是 0，因为语料里压根没有「我」。这对应 Vygotsky 的「你 → 我」倒转，而且是检索竞争的结果，不是我写进去的。

Q14 「最新那个 P6-B 是阳性还是阴性？怎么讲才不算粉饰？」（今天大概率会问）

如实讲：判阴性，因为 0.034 没到预注册的 0.07 门槛。但同时要讲两件不被门槛掩盖的事：① 分离度比 R5 的 0.009 扩大了约 3.8 倍，方向是对的，只是幅度不够；② 顺带发现 k=20 时命中率反而最高（0.066），说明杠杆可能在工作集大小而不是语料规模。

换句话说：这条路没有走通，但我知道了下一根杠杆在哪。

> 别说：「基本可以算阳性了。」门槛是事先定死的，不能因为结果接近就改口。

Q15 「你自己觉得最脆弱的结论是哪条？」

两条：一是只读结论里「单符号写入没测」；二是自我模型的归因没完全分离——语料和门控当时是一起改的，而 S2 的 2×2 分离结果显示**语料才是第一人称片段的必要条件，和我原来的预测相反**。两条都白纸黑字写在论文里。

⑥ 铁律：这些话绝对不说

说完就毁掉整场讨论的可信度。宁可说「不知道」。

- 不说「**它有意识**」→ 说：不主张，也测不了；只谈功能结构。
- 不说「**它自己发明了自我**」→ 说：材料是给的，长出来的只是次序。
- 不说「**双向已经打通**」→ 说：只读；剂量已推到 1.99σ（噪声之上两倍）仍阴性，无幅度限定。
- 不说「**它在学习／训练**」→ 说：是发育；状态在变，权重不变。
- 不说「**v6 冻结是故障**」→ 说：字符级判重的结构性饱和。
- 不说「**加速线的数据就是结论**」→ 说：只当通路证据。
- 不说「**它代表这一类系统**」→ 说：n = 1，是个体。
- 不说「**我们教它不许编造**」→ 说：根本没有生成器。
- 不说「**P6-B 算是阳性**」→ 说：阴性，但效应放大了 3.8 倍，且找到了新杠杆。